mammoviz-tda

Acceso a datasets longitudinales de mamografía
(CSAW-CC, EMBED y alternativas investigadas)

Noviembre 2026

Resumen

Este documento recoge, para no tener que volver a investigarlo, los pasos concretos para solicitar acceso a los dos datasets longitudinales de mamografía identificados como candidatos para evaluar la hipótesis principal del TFG (issue #92 del repositorio), y las demás alternativas que se han investigado y por qué no resuelven el problema mejor que estas dos. Verificado el 9 de noviembre de 2026 contra las páginas oficiales de cada organización (no son suposiciones ni resúmenes de terceros sin contrastar).

1. Resumen rápido

- No existe ningún dataset longitudinal de mamografía de descarga directa sin solicitud. Los dos mejores candidatos siguen siendo **CSAW-CC** y **EMBED**; ninguna alternativa investigada es más fácil o más rápida.
- Recomendación: **solicitar acceso a ambos en paralelo** desde ahora, porque ninguno de los dos portales indica un plazo de respuesta, y no hay coste por solicitar a los dos.
- El dataset de Kaggle/RSNA (2023) es de descarga libre e inmediata, pero **no es longitudinal** (una sola exploración por caso): solo sirve como dataset adicional para la clasificación aislada (O3–O6 del TFG), no para la hipótesis principal (O7–O8).

2. CSAW-CC (Karolinska Institutet)

Gestionado a través del sistema **DORIS** de SND (Swedish National Data Service), no por la propia Karolinska.

1. Ficha del dataset: `https://researchdata.se/catalogue/dataset/2021-204-1/1` (DOI `10.5878/45vm-t798`). La licencia aparece como `NON_PUBLIC`/`restrictedAccess`: *"available upon request due to the size of the material"*.
2. Formulario de solicitud (no requiere login): `https://snd.se/en/research-data-support/data-access-requests`

3. Datos a rellenar: tus datos de contacto y una descripción del uso que le vas a dar. **Importante siendo estudiante**: el formulario también pide el nombre y email de tu tutor/director de TFG, a quien SND notifica para verificar la solicitud.

4. SND reenvía la solicitud a la organización responsable (Karolinska Institutet), que decide si te da acceso. No se indica plazo de respuesta en ninguna página oficial.

5. Contactos directos si el formulario falla o no hay respuesta:

   - Fredrik Strand (creador del dataset, Karolinska Institutet) — `fredrik.strand@ki.se`
   - Kevin Smith (KTH / SciLifeLab) — `ksmith@kth.se`

Nota sobre el CSAW original (no CC)

Existe un dataset "hermano"más grande, el CSAW original (499 807 mujeres, 2008–2015), del mismo grupo. Una página de un vendedor de datos de terceros afirma que un 20 % de CSAW está disponible en Kaggle sin solicitud, **pero esta afirmación no se ha podido confirmar contra ninguna fuente primaria** (ni la ficha de SND, ni Karolinska, ni una página oficial de Kaggle). No usar esta cifra sin verificarla de nuevo antes de dar por hecho que hay un atajo.

3. EMBED (Emory University)

Gestionado por el propio equipo de Emory (HITI Lab) a través de un portal dedicado, `data.hitilab.com`.

1. Portal de solicitud: https://data.hitilab.com/ → botón “Request access” (`/sign-up`).

2. Proceso (confirmado en la propia web):

   a) Enviar tu **propósito de investigación** y tu **afiliación institucional** para revisión.

   b) Si se aprueba, recibes credenciales de AWS **temporales**, con alcance limitado a ese dataset concreto.

   c) Descargas directamente del bucket S3 privado con esas credenciales.

3. Acceso limitado a investigadores académicos; usa tu correo institucional, no uno personal, al solicitar.

4. Licencia / acuerdo de uso de datos (revisar antes de solicitar): https://github.com/Emory-HITI/EMBED_Open_Data/blob/main/EMBED_license.md

5. Documentación general del dataset: https://github.com/Emory-HITI/EMBED_Open_Data

6. Contacto directo de respaldo: Hari Trivedi — `hari.trivedi@emory.edu`

Aclaración importante sobre el "20 % público"

El bucket de AWS Open Data de EMBED (`s3://embed-dataset-open/`) está marcado en el registro oficial de AWS como **"Controlled Access"**, no de acceso público. El "20 %" que aparece en varias páginas (incluida la propia ficha de AWS) se refiere al **tamaño relativo** de ese subconjunto frente al dataset completo (3.4M imágenes), **no** a que sea descargable sin pedir acceso. Se comprobó empíricamente (petición HTTP directa y `boto3` sin firmar) que el listado anónimo del bucket devuelve `AccessDenied`. Hay que pasar por el mismo portal `data.hitilab.com` tanto para el subconjunto "20 %" como para el dataset completo.

4. Alternativas investigadas (y por qué no resuelven el problema)

RSNA Screening Mammography Breast Cancer Detection (Kaggle, 2023)
Descarga **libre e inmediata**, sin solicitud — https://www.rsna.org/education/ai-resources-and-train ai-image-challenge/screening-mammography-breast-cancer-detection-ai-challenge.
Pero son **exploraciones puntuales** (screening de un solo momento por caso, con solo 2.1 % de casos positivos); no incluye pares de exploraciones sucesivas de la misma paciente con cambio de diagnóstico. Útil como dataset adicional para la clasificación aislada (base del TFG, O3–O6), no para O7–O8.

OPTIMAM / OMI-DB (Cancer Research UK + Royal Surrey NHS)
Es genuinamente longitudinal (cribados seriados durante 10 años, 172 282 mujeres a mayo de 2020) y por tanto el candidato más parecido en tamaño/calidad a CSAW-CC/EMBED. Pero el acceso es **más burocrático, no menos**: se gestiona como oportunidad de licencia comercial a través de **Cancer Research Horizons** (https://www.cancerresearchhorizons.com/licensing-opportunities/optimam-mammography-image-database-omi-db), con aprobación de un comité de acceso a datos y un acuerdo de compartición de datos (*data sharing agreement*) por proyecto. No parece razonable para el plazo de un TFG salvo que el tutor tenga ya una relación institucional con Cancer Research UK.

NYU Breast Cancer Screening Dataset (NYU Langone)
Prácticamente cerrado: es una base de datos privada de NYU Langone que, según sus propios autores, *no se puede hacer pública*. Solo ofrecen evaluar modelos de otros grupos sobre su partición de test, previa solicitud a `k.j.geras@nyu.edu` (respuesta en una semana, según un paper reciente que usa este dato, no verificado en una página oficial). No es una vía de acceso a las imágenes en bruto. Como alternativa parcial, el modelo ya entrenado por este mismo grupo (Wu et al. 2019) es público en https://github.com/nyukat/breast_cancer_classifier: no sirve para evaluar la hipótesis topológica, pero podría ser un baseline de comparación de *deep learning* sin necesitar sus datos.

Otros datasets de mamografía de descarga libre (INbreast, VinDr-Mammo, CMMD, MIAS)

Todos son de **una sola exploración por caso**; ninguno tiene estructura longitudinal (exploraciones repetidas de la misma paciente en distintas fechas). No son sustitutos para O7–O8.

5. Conclusión

Tras esta revisión, **CSAW-CC y EMBED siguen siendo las dos mejores (y únicas razonables) opciones** para evaluar la hipótesis de detección anticipada sobre datos reales. No hay ningún atajo de descarga directa que se haya podido confirmar. La recomendación práctica es solicitar acceso a ambos ya (Secciones 2 y 3), en paralelo, dado que:

- Ninguno de los dos indica un plazo de respuesta, así que cuanto antes se solicite, antes se puede empezar O8 en cuanto llegue la aprobación.
- No hay ningún coste ni exclusividad en solicitar a los dos a la vez; el que responda primero (o dé mejores condiciones) se usa para O8, y el otro queda como respaldo o para una comparación cruzada si ambos llegaran a concederse.
- Mientras se espera, el trabajo puede seguir avanzando con la validación sintética ya hecha (`tfg/capitulos/05-metodologia.tex`, sección "Metodología longitudinal") y con la ampliación del piloto real de CBIS-DDSM para la base de clasificación (issue #82), que no dependen de este trámite.