

UNIVERSIDAD DE ALICANTE

ESCUELA POLITÉCNICA SUPERIOR

Grado en Ingeniería Informática

Análisis Topológico de Datos aplicado a la clasificación y visualización de mamografías digitales

Trabajo de Fin de Grado

Autor:

Nombre Apellido Apellido

Tutor/es:

Nombre del tutor/a

17 de julio de 2026

Resumen

El cáncer de mama es el tumor de mayor incidencia entre las mujeres a nivel mundial, y la mamografía sigue siendo la prueba de cribado de referencia para su detección precoz. En los últimos años, las técnicas de *deep learning* han demostrado un gran potencial en el análisis automático de imagen médica, pero suelen comportarse como cajas negras y son sensibles al ruido y a la variabilidad de adquisición. El **Análisis Topológico de Datos** (TDA, por sus siglas en inglés) ofrece una perspectiva complementaria: cuantifica la *forma* de los datos mediante invariantes topológicos robustos frente al ruido, como la homología persistente.

Este Trabajo de Fin de Grado estudia la aplicación del TDA a la clasificación y visualización de mamografías digitales del conjunto de datos público CBIS-DDSM. Se extraen descriptores topológicos (diagramas de persistencia, códigos de barras e imágenes de persistencia) a partir de las imágenes y de las regiones de interés, se evalúa su capacidad discriminativa entre lesiones benignas y malignas, y se comparan y combinan con modelos de aprendizaje profundo. El objetivo último es obtener un sistema de apoyo al diagnóstico más *interpretable* sin sacrificar rendimiento.

Palabras clave: análisis topológico de datos, homología persistente, mamografía, cáncer de mama, aprendizaje profundo, imagen médica, CBIS-DDSM.

Abstract. Breast cancer is the most common malignancy among women worldwide, and mammography remains the reference screening test for its early detection. Deep learning has shown remarkable potential in medical image analysis, yet such models often behave as black boxes and are sensitive to noise and acquisition variability. **Topological Data Analysis** (TDA) provides a complementary viewpoint by quantifying the *shape* of the data through noise-robust topological invariants such as persistent homology. This bachelor's thesis investigates the application of TDA to the classification and visualisation of digital mammograms from the public CBIS-DDSM dataset.

Topological descriptors (persistence diagrams, barcodes and persistence images) are extracted and evaluated for their ability to discriminate benign from malignant lesions, and compared and combined with deep learning models, aiming at a more *interpretable* decision-support system.

Keywords: topological data analysis, persistent homology, mammography, breast cancer, deep learning, medical imaging, CBIS-DDSM.

Índice general

Resumen	I
1. Introducción	1
1.1. Motivación	1
1.2. Contexto del problema	1
1.3. Objetivos y alcance (resumen)	2
1.4. Estructura de la memoria	2
2. Objetivos y metodología	3
2.1. Objetivo general	3
2.2. Objetivos específicos	3
2.3. Metodología general	4
3. Estado del arte	5
3.1. Análisis automático de mamografías	5
3.1.1. Conjuntos de datos públicos	5
3.1.2. Limitaciones	6
3.2. Análisis Topológico de Datos en imagen médica	6
3.3. Síntesis y aportación de este trabajo	6
4. Fundamentos teóricos	7
4.1. Análisis Topológico de Datos	7
4.1.1. Complejos simpliciales y filtraciones	7
4.1.2. Homología y números de Betti	7
4.1.3. Homología persistente	8
4.1.4. Estabilidad y vectorización	8
4.2. Aprendizaje profundo (referencia)	8
4.2.1. Redes neuronales convolucionales	9
4.2.2. Transfer learning	9
5. Metodología propuesta	11
5.1. Visión general del <i>pipeline</i>	11

5.2. Conjunto de datos	11
5.2.1. Protocolo de evaluación y prevención de fuga de datos	12
5.3. Preprocesado de imágenes	12
5.4. Extracción de descriptores topológicos	12
5.5. Modelos de clasificación	13
5.6. Métricas de evaluación	13
6. Implementación	15
6.1. Herramientas y librerías	15
6.2. Organización del código	15
6.3. Extracción de descriptores topológicos	16
6.4. Reproducibilidad	16
6.5. Visualización	17
7. Experimentos y resultados	19
7.1. Diseño experimental	19
7.2. Configuración	19
7.2.1. Backend de homología persistente	20
7.3. Validación preliminar del <i>pipeline</i> con datos sintéticos	20
7.4. Resultados pendientes con el conjunto de datos real	22
7.4.1. Estado de los datos	23
7.5. Discusión	23
8. Conclusiones y trabajo futuro	25
8.1. Conclusiones	25
8.2. Grado de cumplimiento de los objetivos	26
8.3. Limitaciones	26
8.4. Trabajo futuro	27
Bibliografía	29
A. Material adicional	31
A.1. Instalación del entorno	31
A.2. Descripción de los campos de CBIS-DDSM	31
A.2.1. Manifiesto de TCIA (incluido en el repositorio)	31
A.2.2. CSV de descripción de casos (a descargar de TCIA)	32
A.3. Fragmentos de código adicionales	32
A.3.1. Selección automática de backend de homología persistente	32
A.3.2. Imagen de persistencia sin giotto-tda	33

Índice de figuras

5.1.	Esquema general del <i>pipeline</i> propuesto: de los datos crudos a las métricas clínicas, pasando por la extracción de descriptores topológicos. . . .	11
7.1.	Ejemplo de imagen sintética de cada clase: un <i>blob</i> redondeado y suave (benigno) frente a una masa con espículas y micro-motas (maligno), ambas con ruido gaussiano fuerte para evitar un problema trivial. . . .	21
7.2.	Matriz de confusión del <i>random forest</i> (mejor modelo por F1) sobre el conjunto sintético de test. Generada en <code>notebooks/01_pipeline_demo.ipynb</code>	22
7.3.	Diagramas de persistencia (backend <code>gudhi</code>) de un ejemplo benigno y uno maligno del conjunto sintético. H0 (componentes conexas) en azul, H1 (agujeros/ciclos) en naranja; la diagonal discontinua marca birth = death.	22

Índice de tablas

2.1. Trazabilidad entre objetivos específicos y capítulos de la memoria. . . .	4
6.1. Principales herramientas utilizadas.	15
7.1. Resultados sobre datos sintéticos (validación del <i>pipeline</i> , imagen de persistencia H0+H1, backend gudhi).	21
7.2. Resultados comparativos en el conjunto de test de CBIS-DDSM (plantilla, pendiente de completar).	23
8.1. Grado de cumplimiento de los objetivos específicos.	26
A.1. Campos relevantes del manifiesto de TCIA.	32

Capítulo 1

Introducción

1.1. Motivación

El cáncer de mama es la neoplasia más frecuente en mujeres y una de las principales causas de mortalidad por cáncer a nivel mundial. La detección precoz mediante programas de cribado con mamografía reduce de forma significativa la mortalidad, ya que permite identificar lesiones en estadios tempranos y más tratables. Sin embargo, la interpretación de mamografías es una tarea compleja, sujeta a variabilidad inter-observador y a una carga de trabajo elevada para los radiólogos.

En este contexto, los sistemas de diagnóstico asistido por computador (*Computer-Aided Diagnosis*, CAD) y, más recientemente, las técnicas de aprendizaje profundo (*deep learning*) se han convertido en herramientas de gran interés. Trabajos como el de Yala *et al.* [6] han demostrado que los modelos basados en mamografía pueden mejorar la predicción del riesgo de cáncer de mama. No obstante, estos modelos presentan limitaciones importantes: son difíciles de interpretar, requieren grandes cantidades de datos etiquetados y pueden ser sensibles al ruido y a las condiciones de adquisición.

El **Análisis Topológico de Datos** (TDA) surge como un enfoque complementario que caracteriza la *forma* intrínseca de los datos mediante herramientas de la topología algebraica. Su técnica principal, la *homología persistente*, es robusta frente al ruido y proporciona descriptores interpretables geoméricamente, lo que la hace especialmente atractiva para el análisis de imagen médica.

1.2. Contexto del problema

Una mamografía digital es una imagen de rayos X de la mama que revela estructuras como el tejido glandular, los conductos, las calcificaciones y posibles masas. La densidad mamaria (clasificada habitualmente según el sistema BI-RADS) y la morfología de las lesiones son factores clave en el diagnóstico. El conjunto de datos público

CBIS-DDSM [4] proporciona mamografías digitalizadas con anotaciones de lesiones (masas y microcalcificaciones), regiones de interés (ROI) segmentadas y etiquetas de patología (benigno/maligno), lo que lo convierte en un banco de pruebas adecuado para este trabajo.

1.3. Objetivos y alcance (resumen)

El objetivo general de este TFG es **estudiar y evaluar la aplicación del Análisis Topológico de Datos a la clasificación y visualización de mamografías**, comparándolo y combinándolo con técnicas de aprendizaje profundo. Los objetivos específicos se detallan en el Capítulo 2.

1.4. Estructura de la memoria

El resto de la memoria se organiza como sigue:

- El **Capítulo 2** formula los objetivos y la metodología general del trabajo.
- El **Capítulo 3** revisa el estado del arte en análisis de mamografías y en TDA aplicado a imagen médica.
- El **Capítulo 4** introduce los fundamentos teóricos de la homología persistente y del aprendizaje profundo.
- El **Capítulo 5** describe la metodología propuesta: datos, preprocesado, extracción de descriptores y modelos.
- El **Capítulo 6** detalla la implementación y las herramientas utilizadas.
- El **Capítulo 7** presenta y discute los resultados experimentales.
- El **Capítulo 8** recoge las conclusiones y las líneas de trabajo futuro.

Capítulo 2

Objetivos y metodología

2.1. Objetivo general

El objetivo general de este Trabajo de Fin de Grado es **investigar la aplicación del Análisis Topológico de Datos (TDA) a la clasificación y visualización de mamografías digitales**, evaluando su capacidad discriminativa entre lesiones benignas y malignas y su complementariedad con los modelos de aprendizaje profundo.

2.2. Objetivos específicos

Para alcanzar el objetivo general se plantean los siguientes objetivos específicos:

- O1. Revisar el estado del arte** en (i) análisis automático de mamografías y (ii) aplicaciones del TDA en imagen médica.
- O2. Preparar y preprocesar** el conjunto de datos CBIS-DDSM: descarga, limpieza de metadatos, extracción de ROIs y normalización de las imágenes.
- O3. Extraer descriptores topológicos** (diagramas de persistencia, códigos de barras e imágenes de persistencia) a partir de las mamografías mediante homología persistente.
- O4. Entrenar y evaluar clasificadores** sobre los descriptores topológicos (p. ej. SVM, *random forest*) para la tarea benigno/maligno.
- O5. Comparar** el enfoque topológico con un modelo de *deep learning* de referencia (CNN con *transfer learning*) y **explorar su combinación** (fusión de características).
- O6. Desarrollar herramientas de visualización** que hagan interpretables los resultados topológicos para su uso como apoyo al diagnóstico.

2.3. Metodología general

El desarrollo del trabajo sigue una metodología incremental e iterativa, estructurada en las siguientes fases, alineadas con los objetivos anteriores:

1. **Fase de documentación** (O1): estudio de la bibliografía y de las herramientas disponibles.
2. **Fase de datos** (O2): construcción de un *pipeline* reproducible de preparación de datos.
3. **Fase de extracción de características** (O3): implementación de la extracción de descriptores topológicos.
4. **Fase de modelado** (O4, O5): entrenamiento, validación y comparación de modelos, evitando la fuga de datos (*data leakage*) mediante una separación estricta *train/validation/test*.
5. **Fase de análisis y visualización** (O6): interpretación de los resultados y desarrollo de visualizaciones.
6. **Fase de redacción** de la memoria.

Tabla 2.1: Trazabilidad entre objetivos específicos y capítulos de la memoria.

Objetivo	Descripción breve	Capítulo
O1	Estado del arte	3
O2	Preparación de datos	5, 6
O3	Descriptores topológicos	4, 5
O4	Clasificadores sobre TDA	5, 7
O5	Comparación con DL	7
O6	Visualización	6, 7

Capítulo 3

Estado del arte

Este capítulo revisa los trabajos previos relevantes en dos líneas complementarias: el análisis automático de mamografías mediante aprendizaje profundo, y las aplicaciones del Análisis Topológico de Datos en imagen médica.

3.1. Análisis automático de mamografías

El análisis asistido por computador de mamografías tiene una larga trayectoria, desde los primeros sistemas CAD basados en características diseñadas manualmente (*hand-crafted features*) hasta los actuales enfoques de aprendizaje profundo. Las redes neuronales convolucionales (CNN) se han consolidado como el paradigma dominante en visión por computador y en imagen médica, gracias a su capacidad para aprender jerarquías de características directamente de los datos [1], [5].

En el ámbito específico de la mamografía, destacan trabajos orientados a la detección y clasificación de masas y microcalcificaciones, así como a la estimación del riesgo. Yala *et al.* [6] propusieron un modelo basado en *deep learning* que mejora la predicción del riesgo de cáncer de mama a partir de la mamografía, superando a los modelos de riesgo tradicionales. El uso de *transfer learning* a partir de redes preentrenadas en ImageNet (ResNet, DenseNet, EfficientNet, etc.) es una práctica habitual para mitigar la escasez de datos etiquetados en el dominio médico.

3.1.1. Conjuntos de datos públicos

Entre los conjuntos de datos públicos de mamografía más utilizados destaca CBIS-DDSM [4], una versión curada y estandarizada del clásico DDSM que incluye segmentaciones de ROI verificadas y etiquetas de patología. Otros recursos relevantes son INbreast y las bases de datos de ecografía mamaria.

3.1.2. Limitaciones

A pesar de sus buenos resultados, los modelos de *deep learning* en mamografía presentan limitaciones bien conocidas:

- **Interpretabilidad limitada:** su naturaleza de caja negra dificulta la confianza clínica y la certificación.
- **Dependencia de grandes volúmenes de datos** etiquetados.
- **Riesgo de fuga de datos** (*data leakage*) y de sesgos de adquisición, que pueden producir métricas artificialmente altas si el protocolo experimental no es riguroso.

Estas limitaciones motivan la búsqueda de representaciones más robustas e interpretables, como las que proporciona el TDA.

3.2. Análisis Topológico de Datos en imagen médica

El Análisis Topológico de Datos (TDA) engloba un conjunto de técnicas que estudian la forma de los datos mediante herramientas de topología algebraica [2], [3]. Su herramienta central, la *homología persistente*, ha sido aplicada con éxito en diversos problemas de imagen médica: caracterización de texturas de tumores, análisis de imágenes histopatológicas, neuroimagen y detección de estructuras en radiología.

En el contexto de la mamografía y del cáncer de mama, los descriptores topológicos permiten capturar patrones de conectividad y estructura (número de componentes conexas, agujeros, ramificaciones de conductos, distribución de microcalcificaciones) que resultan difíciles de modelar con características convencionales. Su robustez frente al ruido y su interpretabilidad geométrica los convierten en un complemento natural de las CNN.

3.3. Síntesis y aportación de este trabajo

La revisión anterior muestra que, si bien el *deep learning* domina el análisis de mamografías, el TDA ofrece una vía prometedora y poco explorada para obtener representaciones interpretables y robustas. La aportación de este TFG es un estudio sistemático de descriptores topológicos sobre CBIS-DDSM, su evaluación como características para la clasificación benigno/maligno, y su comparación y combinación con un modelo de *deep learning* de referencia.

Capítulo 4

Fundamentos teóricos

Este capítulo introduce los conceptos necesarios para comprender el trabajo: los fundamentos del Análisis Topológico de Datos, con énfasis en la homología persistente, y una breve descripción de los modelos de aprendizaje profundo empleados como referencia.

4.1. Análisis Topológico de Datos

El TDA parte de la idea de que los datos poseen una *forma* y que dicha forma contiene información relevante. Formalmente, se construye a partir de los datos una familia de espacios topológicos y se estudia cómo evolucionan sus invariantes.

4.1.1. Complejos simpliciales y filtraciones

Definición 4.1 (Complejo simplicial). Un *complejo simplicial* K es un conjunto de símlices (vértices, aristas, triángulos, tetraedros, ...) cerrado bajo la operación de tomar caras y tal que la intersección de dos símlices es una cara de ambos.

Para analizar datos se construye una *filtración*, es decir, una familia anidada de complejos simpliciales

$$\emptyset = K_0 \subseteq K_1 \subseteq \dots \subseteq K_n = K,$$

indexada por un parámetro de escala. En imágenes, una filtración habitual es la *filtración por sublevel sets* de la intensidad: se van incluyendo los píxeles cuyo valor es menor o igual que un umbral creciente.

4.1.2. Homología y números de Betti

La homología asocia a cada complejo una secuencia de grupos cuyos rangos, los *números de Betti* β_k , cuentan las características topológicas de dimensión k :

- β_0 : número de **componentes conexas**.
- β_1 : número de **agujeros** o ciclos unidimensionales.
- β_2 : número de **cavidades** o huecos tridimensionales.

4.1.3. Homología persistente

La *homología persistente* rastrea el nacimiento (*birth*) y la muerte (*death*) de las características topológicas a lo largo de la filtración. Una característica que persiste durante un amplio rango de escalas se considera una propiedad estructural significativa, mientras que las de vida corta suelen corresponder a ruido.

Definición 4.2 (Diagrama de persistencia). El *diagrama de persistencia* es un multiconjunto de puntos $(b_i, d_i) \in \mathbb{R}^2$ con $b_i \leq d_i$, donde cada punto representa una característica topológica que nace en la escala b_i y muere en d_i . La *persistencia* de la característica es $d_i - b_i$.

La misma información puede representarse como un *código de barras* (*barcode*), donde cada característica es un intervalo $[b_i, d_i]$.

4.1.4. Estabilidad y vectorización

Una propiedad fundamental es la **estabilidad**: pequeñas perturbaciones en los datos producen pequeñas variaciones en el diagrama de persistencia (medidas con la distancia *bottleneck* o de Wasserstein). Esto explica la robustez del TDA frente al ruido.

Para poder utilizar los diagramas como entrada de algoritmos de aprendizaje automático es necesario *vectorizarlos*. Entre las representaciones más utilizadas destacan:

- **Imágenes de persistencia** (*persistence images*): transforman el diagrama en una imagen (matriz) de tamaño fijo.
- **Persistence landscapes**: funciones a trozos que resumen el diagrama.
- **Curvas de Betti** y estadísticos de persistencia.

4.2. Aprendizaje profundo (referencia)

Como referencia comparativa se emplean redes neuronales convolucionales (CNN).

4.2.1. Redes neuronales convolucionales

Una CNN aprende, mediante capas convolucionales, jerarquías de características espaciales a partir de las imágenes. Combinada con capas de *pooling* y capas totalmente conectadas, permite abordar tareas de clasificación de imagen.

4.2.2. Transfer learning

Dado el tamaño limitado de los conjuntos de datos médicos, se recurre al *transfer learning*: se parte de una red preentrenada en un gran corpus (p.ej. ImageNet) y se ajusta (*fine-tuning*) a la tarea de mamografía. En este trabajo se utiliza como referencia una arquitectura de la familia DenseNet/ResNet.

Ejemplo 4.1 (Intuición del enfoque topológico en mamografía). Una agrupación de microcalcificaciones puede caracterizarse por el número de componentes conexas (β_0) y su patrón de aparición a lo largo de la filtración de intensidad, mientras que la estructura de una masa espiculada puede reflejarse en la aparición y desaparición de ciclos (β_1). El TDA codifica estos patrones de forma compacta y robusta.

Capítulo 5

Metodología propuesta

En este capítulo se describe la metodología propuesta para aplicar el TDA a la clasificación de mamografías, desde la preparación de los datos hasta la evaluación de los modelos.

5.1. Visión general del *pipeline*

El sistema propuesto consta de cinco etapas:

1. Preparación de datos (CBIS-DDSM).
2. Preprocesado de imágenes y extracción de ROIs.
3. Extracción de descriptores topológicos.
4. Clasificación (topológica, *deep learning* y fusión).
5. Evaluación y visualización.




Figura 5.1: Esquema general del *pipeline* propuesto: de los datos crudos a las métricas clínicas, pasando por la extracción de descriptores topológicos.

5.2. Conjunto de datos

Se utiliza CBIS-DDSM [4]. El fichero de metadatos disponible en el repositorio (CBIS-DDSM-All-... .xlsx) contiene la información de cada estudio: identificador de paciente, tipo de lesión (masa o calcificación), densidad de la mama (BI-RADS), vista (CC/MLO), y la etiqueta de patología (BENIGN, MALIGNANT, BENIGN_WITHOUT_CALLBACK).

- **Tarea principal:** clasificación binaria benigno vs. maligno.
- **Unidad de análisis:** región de interés (ROI) de la lesión y/o imagen completa reescalada.

5.2.1. Protocolo de evaluación y prevención de fuga de datos

Se adopta una partición estricta en **entrenamiento** / **validación** / **test**. Para evitar la fuga de datos (*data leakage*), la separación se realiza **a nivel de paciente**: todas las imágenes de un mismo paciente pertenecen a una única partición. Se emplea estratificación por la etiqueta de patología para mantener la proporción de clases.

Nota metodológica. En el material de partida (`Demo_Notebook.ipynb`) se observaba una exactitud de entrenamiento del 100 % desde la primera época y una exactitud de validación cercana al 100 %, lo que es un indicio claro de fuga de datos o de un problema en el *pipeline*. Este trabajo corrige dicho protocolo mediante partición por paciente, control de la normalización y validación cruzada.

5.3. Preprocesado de imágenes

El preprocesado incluye:

- Conversión y normalización de intensidades.
- Recorte de la ROI a partir de las máscaras de segmentación.
- Reescalado a un tamaño común (p. ej. 224×224).
- Opcionalmente, realce de contraste (CLAHE) y filtrado de ruido.

5.4. Extracción de descriptores topológicos

A partir de cada imagen (o ROI) se calcula la homología persistente mediante una filtración por *sublevel sets* de la intensidad (para imágenes en escala de grises) o sobre nubes de puntos derivadas de las microcalcificaciones. Se obtienen los diagramas de persistencia en dimensiones 0 y 1, y a partir de ellos se generan los vectores de características:

- Imágenes de persistencia.
- Estadísticos de persistencia (número de puntos, persistencia total, máxima, media; curvas de Betti).

5.5. Modelos de clasificación

Se comparan tres enfoques:

1. **Topológico:** clasificadores clásicos (SVM, *random forest*, regresión logística) sobre los descriptores topológicos.
2. **Deep learning:** CNN con *transfer learning* sobre las imágenes.
3. **Fusión:** combinación de las características topológicas con las *embeddings* de la CNN.

5.6. Métricas de evaluación

Dado el carácter clínico del problema, se emplean varias métricas complementarias:

- **Exactitud** (*accuracy*).
- **Sensibilidad** (*recall*) — crítica para no pasar por alto casos malignos.
- **Especificidad y precisión.**
- **F1-score y AUC-ROC.**
- **Matriz de confusión.**

La sensibilidad recibe especial atención, ya que un falso negativo (no detectar un cáncer) tiene un coste clínico mucho mayor que un falso positivo.

Capítulo 6

Implementación

Este capítulo describe las herramientas, la organización del código y los detalles de implementación del *pipeline*.

6.1. Herramientas y librerías

El proyecto se desarrolla en **Python**. Las principales librerías son:

Tabla 6.1: Principales herramientas utilizadas.

Ámbito	Herramienta
Manipulación de datos	pandas, NumPy
Imagen	OpenCV, scikit-image, Pillow
TDA / homología persistente	giotto-tda (referencia) / GUDHI + persim (portable)
Aprendizaje automático	scikit-learn
Aprendizaje profundo	TensorFlow / Keras (o PyTorch)
Visualización	Matplotlib, seaborn
Entorno	Jupyter Notebook

6.2. Organización del código

El repositorio se estructura de la siguiente forma (véase el `README.md`):

```
mammoviz-tda/  
  data/           # datos (no versionados)  
  src/            # código fuente del pipeline  
    data.py       # carga y partición por paciente  
    preprocessing.py # preprocesado de imágenes  
    topology.py   # homología persistente y vectorización  
    models.py     # clasificadores y CNN
```

```

    evaluate.py      # metricas y visualizacion
notebooks/         # experimentos reproducibles
tfg/               # memoria en LaTeX

```

6.3. Extracción de descriptores topológicos

giotto-tda solo distribuye binarios precompilados hasta Python 3.12, por lo que `src/topology.py` detecta en tiempo de ejecución qué backend está disponible (giotto-tda o, si no, gudhi + persim, con soporte hasta Python 3.14) y expone la misma interfaz (`persistence_diagram`, `extract_features`) independientemente de cuál esté activo; `topology.backend()` permite consultarlo. El siguiente fragmento ilustra el cálculo de un diagrama de persistencia a partir de una imagen en escala de grises mediante una filtración por *sublevel sets*, utilizando giotto-tda.

```

1 import numpy as np
2 from gtdata.images import HeightFiltration, RadialFiltration
3 from gtdata.homology import CubicalPersistence
4 from gtdata.diagrams import PersistenceImage
5
6 def descriptor_topologico(imagen_gris):
7     # imagen_gris: array 2D normalizado en [0, 1]
8     x = imagen_gris[None, :, :]          # (1, H, W)
9     cubical = CubicalPersistence(homology_dimensions=(0, 1))
10    diagrams = cubical.fit_transform(x)    # diagramas de
11                                           persistencia
12    pi = PersistenceImage(n_bins=20)
13    vector = pi.fit_transform(diagrams)    # imagen de persistencia
14    return vector.reshape(len(x), -1)

```

Listing 6.1: Ejemplo de extracción de un diagrama de persistencia.

6.4. Reproducibilidad

Para garantizar la reproducibilidad de los experimentos:

- Se fija una semilla aleatoria común.
- Se documentan las versiones de las librerías (`requirements.txt`).
- La partición de datos por paciente se guarda en disco para reutilizarla.
- Cada experimento se ejecuta desde un *notebook* autocontenido.

6.5. Visualización

Se desarrollan visualizaciones específicas para el análisis topológico: diagramas de persistencia y códigos de barras superpuestos sobre la imagen, mapas de calor de las imágenes de persistencia, y comparación de las regiones más informativas frente a las activaciones de la CNN (p.ej. Grad-CAM).

Capítulo 7

Experimentos y resultados

Este capítulo presenta el diseño experimental del trabajo y los resultados obtenidos hasta el momento. Como se detalla en la Sección 7.4.1, la descarga completa de CBIS-DDSM (imágenes y máscaras de ROI) todavía no se ha completado; por ello, los resultados que se presentan aquí corresponden a una **validación preliminar del *pipeline* completo con datos sintéticos** (Sección 7.3), y se deja preparada la estructura (tablas, figuras, apartados) que se rellenará con los resultados sobre el conjunto de datos real en cuanto estén disponibles (Sección 7.4).

7.1. Diseño experimental

Se definen los siguientes experimentos, alineados con los objetivos O4 y O5 (Capítulo 2):

- E1.** Clasificación con descriptores topológicos + clasificador clásico (SVM, *random forest*).
- E2.** Clasificación con CNN (*transfer learning*, DenseNet121).
- E3.** Fusión de características topológicas y *embeddings* de CNN.
- E4.** Análisis de robustez frente a ruido y a variaciones de adquisición.

7.2. Configuración

En todos los experimentos se fija una semilla aleatoria común (`seed = 42`) para garantizar la reproducibilidad. La partición de datos se realiza **por paciente** (Capítulo 5), con proporciones 70 % / 15 % / 15 % para entrenamiento, validación y test respectivamente, estratificadas por la etiqueta de patología. Los hiperparámetros de los clasificadores clásicos (`SVC(kernel='rbf')`, `RandomForestClassifier(n_estimators=300)`)

se fijan a valores por defecto razonables en esta fase preliminar; en la fase de experimentación con datos reales se ajustarán mediante validación cruzada sobre el conjunto de validación.

7.2.1. Backend de homología persistente

La implementación de referencia de este trabajo usa `giotto-tda` (Sección 6), pero esta librería solo distribuye binarios precompilados hasta Python 3.12. Para no depender de una versión concreta de Python, `src/topology.py` elige automáticamente, en este orden, el primer backend disponible en el entorno de ejecución:

1. **giotto-tda** — implementación de referencia.
2. **gudhi + persim** — backend alternativo con soporte binario hasta Python 3.14; se usa `gudhi.CubicalComplex` para el diagrama de persistencia y una imagen de persistencia calculada mediante un núcleo gaussiano ponderado por persistencia sobre la rejilla fija $[0, 1] \times [0, 1]$ (las imágenes ya están normalizadas por `preprocessing.to_grayscale_float`).
3. **Curva de Betti-0** (`scipy`) — respaldo mínimo si ningún backend anterior está instalado; cuenta cómo evoluciona el número de componentes conexas al barrer el umbral de intensidad.

Los resultados de este capítulo se obtuvieron con el backend **gudhi**, por ser el que está instalado en el entorno de desarrollo (Python 3.14, donde `giotto-tda` no tiene binarios disponibles). Ambos backends calculan la misma homología persistente cúbica sobre H_0 y H_1 ; la diferencia está en la vectorización final (imagen de persistencia), por lo que los resultados no deberían diferir sustancialmente de los que produciría `giotto-tda`.

7.3. Validación preliminar del *pipeline* con datos sintéticos

Antes de disponer del conjunto de datos real, se ha validado el *pipeline* de extremo a extremo (`notebooks/01_pipeline_demo.ipynb`) sobre un conjunto de **imágenes sintéticas** generadas para imitar de forma simplificada la textura y el contraste de una mamografía con lesión: 120 imágenes en escala de grises de 64×64 píxeles, con 60 ejemplos de cada clase (benigno/maligno simulados mediante patrones con distinta rugosidad topológica). El objetivo de este experimento **no** es obtener conclusiones clínicas — los datos son artificiales — sino comprobar que las cinco etapas del *pipeline* (datos $\rightarrow$ preprocesado $\rightarrow$ homología persistente $\rightarrow$ clasificación $\rightarrow$ evaluación) encajan correctamente y producen métricas coherentes, usando ya el descriptor topológico

completo (imágenes de persistencia H_0+H_1 , no la curva de Betti-0) gracias al backend *gudhi* (Sección 7.2.1).




Figura 7.1: Ejemplo de imagen sintética de cada clase: un *blob* redondeado y suave (benigno) frente a una masa con espículas y micro-motas (maligno), ambas con ruido gaussiano fuerte para evitar un problema trivial.

Con partición 90/30 (train/test) y un vector de 288 características por imagen (12×12 píxeles por imagen de persistencia, dos dimensiones de homología H_0 y H_1), se obtienen los siguientes resultados:

Tabla 7.1: Resultados sobre datos sintéticos (validación del *pipeline*, imagen de persistencia H_0+H_1 , backend *gudhi*).

Modelo	Exactitud	Sensib.	Especif.	F1	AUC
TDA + SVM (RBF)	0.667	0.600	0.733	0.643	0.844
TDA + Random Forest	0.733	0.800	0.667	0.750	0.833

Con estos datos sintéticos, el *random forest* obtiene la mejor sensibilidad y F1, y es el modelo seleccionado por F1 en el notebook; la SVM obtiene ligeramente mejor AUC. Ambos modelos superan claramente al azar ($AUC \approx 0,83-0,84$), y la sensibilidad del *random forest* (0,80) es notablemente mejor que la obtenida en una validación previa con el descriptor de respaldo Betti-0 (0,60, un vector de solo 24 características frente a las 288 de la imagen de persistencia), lo que es consistente con la hipótesis de que **la dimensión H_1 (agujeros/ciclos), ausente en la curva de Betti-0, aporta información discriminativa** relevante para las morfologías espiculadas simuladas en la clase maligna.




Figura 7.2: Matriz de confusión del *random forest* (mejor modelo por F1) sobre el conjunto sintético de test. Generada en `notebooks/01_pipeline_demo.ipynb`.




Figura 7.3: Diagramas de persistencia (backend `gudhi`) de un ejemplo benigno y uno maligno del conjunto sintético. H0 (componentes conexas) en azul, H1 (agujeros/ciclos) en naranja; la diagonal discontinua marca $\text{birth} = \text{death}$.

7.4. Resultados pendientes con el conjunto de datos real

La siguiente tabla mantiene la estructura de comparación planificada para los experimentos E1–E3 sobre CBIS-DDSM real, con el mismo descriptor topológico (imágenes de persistencia H0+H1) ya validado en la Sección 7.3, y el modelo de *deep learning* de referencia. Se rellenará en cuanto se complete la descarga de datos (Sección 7.4.1) y se ejecuten los experimentos correspondientes.

Tabla 7.2: Resultados comparativos en el conjunto de test de CBIS-DDSM (plantilla, pendiente de completar).

Modelo	Exactitud	Sensib.	Especif.	F1	AUC
Baseline (clase mayoritaria)	—	—	—	—	—
TDA + SVM	—	—	—	—	—
TDA + Random Forest	—	—	—	—	—
CNN (transfer learning)	—	—	—	—	—
Fusión TDA + CNN	—	—	—	—	—

7.4.1. Estado de los datos

A fecha de redacción de este capítulo, el repositorio contiene únicamente el manifiesto de TCIA (CBIS-DDSM-A11-...-nbia-digest.xlsx), que identifica las series pero no incluye la etiqueta de patología. Quedan pendientes:

- Descargar los CSV de descripción de casos (`mass_/calc_case_description_*.csv`) a `data/csv/`.
- Descargar las imágenes DICOM y las máscaras de ROI a `data/images/` mediante el NBIA Data Retriever.
- Ejecutar `src/topology.py` (backend `gudhi` o `giotto-tda`, ya operativo — Sección 7.2.1) sobre las imágenes reales.
- Entrenar y evaluar la CNN de referencia (`src/models.py:build_cnn`) y el experimento de fusión.

7.5. Discusión

Aunque los resultados sobre datos sintéticos no permiten extraer conclusiones clínicas, sí permiten adelantar algunas observaciones metodológicas relevantes para la fase de experimentación real:

- El *pipeline* es funcionalmente correcto de extremo a extremo y con el descriptor topológico completo: la partición por paciente, el preprocesado, la extracción de imágenes de persistencia H_0+H_1 y la evaluación con métricas clínicas se ejecutan sin errores y producen resultados coherentes ($AUC \approx 0,83-0,84$).
- La dimensión H_1 aporta información que la curva de Betti-0 no captura: al pasar del descriptor de respaldo (Betti-0, solo H_0 , 24 características) a la

imagen de persistencia completa (H0+H1, 288 características), la sensibilidad del *random forest* mejora de 0,60 a 0,80 sobre el mismo conjunto sintético. Es una observación preliminar (mismo generador, tamaño de muestra pequeño), pero apunta en la dirección esperada: los ciclos/agujeros (H1) deberían ser relevantes para masas espiculadas y distribuciones de microcalcificaciones.

- **La sensibilidad sigue siendo sensible al tamaño de muestra:** con solo 120 imágenes sintéticas, la sensibilidad de la SVM (0,60) queda por debajo de su especificidad (0,73), lo que anticipa la necesidad de vigilar el desbalance de clases y el tamaño muestral al pasar a datos reales (CBIS-DDSM tiene más casos benignos que malignos).
- **Comparación con *deep learning* y fusión:** quedan pendientes de ejecutar sobre datos reales; la discusión sobre si el enfoque topológico aporta información complementaria a la CNN (y no solo redundante) solo puede responderse con el experimento E3 de fusión.

Las limitaciones específicas de esta fase preliminar (tamaño de muestra, naturaleza sintética de los datos, ausencia de comparación con CNN) se retoman en el Capítulo 8 junto con las limitaciones generales del trabajo.

Capítulo 8

Conclusiones y trabajo futuro

8.1. Conclusiones

En este Trabajo de Fin de Grado se ha estudiado la aplicación del Análisis Topológico de Datos a la clasificación y visualización de mamografías digitales del conjunto CBIS-DDSM. El resultado principal es un ***pipeline completo y reproducible*** — desde la carga de metadatos hasta la evaluación clínica — que corrige el problema de fuga de datos detectado en el material de partida y que ha sido validado de extremo a extremo, si bien todavía con datos sintéticos a falta de completar la descarga de CBIS-DDSM (Sección 7.4). En relación con los objetivos específicos planteados en el Capítulo 2:

- Se ha revisado el estado del arte en análisis automático de mamografías y en aplicaciones del TDA a imagen médica (O1).
- Se ha construido un *pipeline* reproducible de preparación de datos (`src/data.py`) cuyo aporte metodológico central es la **partición por paciente**, que corrige la fuga de datos observada en el `Demo_Notebook.ipynb` original (exactitud del 100 % desde la primera época) (O2).
- Se ha implementado la extracción de descriptores topológicos mediante homología persistente cúbica (`src/topology.py`: diagramas de persistencia, imágenes de persistencia H_0+H_1 , estadísticos), con dos backends intercambiables (`giotto-tda` y `gudhi`, este último operativo en Python 3.14) para no depender de una versión concreta de Python, y se ha entrenado y evaluado clasificadores clásicos (SVM, *random forest*) sobre estos descriptores, con resultados preliminares coherentes ($AUC \approx 0,83-0,84$) sobre datos sintéticos (O3 — **cumplido a nivel de implementación**; O4 — **validado parcialmente**: falta repetir el experimento sobre imágenes reales de CBIS-DDSM).

- Se ha diseñado e implementado la CNN de referencia y el mecanismo de fusión de características (`src/models.py:build_cnn, fuse_features`), pero **no se ha podido entrenar ni comparar todavía** por falta del conjunto de imágenes real (O5 — **pendiente**).
- Se han desarrollado utilidades de visualización (matriz de confusión, diagrama de persistencia) en `src/evaluate.py`, integradas en el notebook de demostración; queda pendiente su aplicación sobre casos reales y su comparación con mapas de activación de la CNN (p. ej. Grad-CAM) (O6 — **parcialmente cumplido**).

8.2. Grado de cumplimiento de los objetivos

Tabla 8.1: Grado de cumplimiento de los objetivos específicos.

Obj.	Estado	Observaciones
O1	Cumplido	Revisión bibliográfica completa (Cap. 3).
O2	Cumplido	<i>Pipeline</i> de datos y partición por paciente implementados y verificados.
O3	Cumplido (impl.)	Extracción de imágenes de persistencia H0+H1 implementada y validada sobre datos sintéticos con dos backends (gudhi, giotto-tda); falta validar sobre imágenes reales de CBIS-DDSM.
O4	Parcialmente cumplido	Clasificadores entrenados y evaluados sobre datos sintéticos; falta la ejecución sobre CBIS-DDSM.
O5	Pendiente	CNN y fusión implementadas pero no entrenadas ni comparadas por falta de datos.
O6	Parcialmente cumplido	Visualizaciones básicas implementadas; falta aplicarlas a casos reales y compararlas con Grad-CAM.

La principal desviación respecto a la planificación inicial es de naturaleza logística, no metodológica: el volumen y los tiempos de descarga de CBIS-DDSM (imágenes DICOM completas y máscaras de ROI, del orden de decenas de gigabytes) han retrasado la fase de experimentación con datos reales (O4, O5), a pesar de que el *pipeline* que los consumirá está terminado, documentado y validado funcionalmente.

8.3. Limitaciones

Se identifican las siguientes limitaciones del trabajo en su estado actual:

- **Ausencia de resultados sobre datos reales.** Las métricas presentadas en el Capítulo 7 se obtienen sobre datos sintéticos (con el descriptor topológico completo, imágenes de persistencia H_0+H_1 vía `gudhi`); no son extrapolables a la capacidad diagnóstica real del enfoque sobre mamografías.
- **Tamaño y sesgos del conjunto de datos.** CBIS-DDSM, aunque curado, procede de un número limitado de centros y equipos de adquisición, lo que puede limitar la generalización a otras poblaciones o tecnologías de imagen.
- **Coste computacional de la homología persistente.** El cálculo de homología cúbica sobre imágenes completas de alta resolución es costoso; en la práctica suele requerir trabajar sobre ROIs recortadas y reescaladas, lo que introduce una decisión de diseño (tamaño y margen del recorte) con impacto en el resultado.
- **Alcance de la validación clínica.** Ni las métricas obtenidas ni las que se obtengan sobre CBIS-DDSM constituyen una validación clínica: falta contraste con radiólogos y con conjuntos de datos externos antes de extraer conclusiones sobre utilidad diagnóstica real.

8.4. Trabajo futuro

A corto plazo, para completar los objetivos O4–O6 sobre datos reales:

- Completar la descarga de CBIS-DDSM (CSV de casos e imágenes/máscaras vía NBIA Data Retriever) y ejecutar el *pipeline* de extracción topológica (ya operativo con `gudhi/giotto-tda`) sobre las imágenes reales.
- Entrenar la CNN de referencia y el experimento de fusión, y completar la Tabla 7.2.
- Generar las visualizaciones finales (diagramas de persistencia sobre casos reales, comparación con Grad-CAM) para la memoria.

Como líneas de trabajo futuro de más largo alcance se proponen:

- Extender el estudio a otras filtraciones y descriptores topológicos (*multiparameter persistence*).
- Integrar el TDA directamente en arquitecturas de *deep learning* (capas topológicas diferenciables).
- Validar el enfoque en otros conjuntos de datos (INbreast, datos propios).
- Realizar una evaluación con radiólogos para medir la utilidad clínica de las visualizaciones.

Bibliografía

- [1] A. Ali Eli y A. Ali, “Deep Learning Applications in Medical Image Analysis: Advancements, Challenges, and Future Directions”, *arXiv preprint arXiv:2410.14131*, 2024. arXiv: 2410.14131 [eess.IV].
- [2] G. Carlsson, “Topology and data”, *Bulletin of the American Mathematical Society*, vol. 46, n.º 2, págs. 255-308, 2009. DOI: 10.1090/S0273-0979-09-01249-X
- [3] H. Edelsbrunner y J. L. Harer, *Computational Topology: An Introduction*. American Mathematical Society, 2010, ISBN: 978-0-8218-4925-5.
- [4] R. S. Lee, F. Gimenez, A. Hoogi, K. K. Miyake, M. Gorovoy y D. L. Rubin, “A curated mammography data set for use in computer-aided detection and diagnosis research”, *Scientific Data*, vol. 4, págs. 170 177, 2017. DOI: 10.1038/sdata.2017.177
- [5] G. Litjens et al., “A survey on deep learning in medical image analysis”, *Medical Image Analysis*, vol. 42, págs. 60-88, 2017. DOI: 10.1016/j.media.2017.07.005
- [6] A. Yala, C. Lehman, T. Schuster, T. Portnoi y R. Barzilay, “A Deep Learning Mammography-based Model for Improved Breast Cancer Risk Prediction”, *Radiology*, vol. 292, n.º 1, págs. 60-66, 2019. DOI: 10.1148/radiol.2019182716

Apéndice A

Material adicional

A.1. Instalación del entorno

Instrucciones para reproducir el entorno de desarrollo:

```
python -m venv .venv
source .venv/bin/activate          # En Windows: .venv\Scripts\activate
pip install -r requirements.txt
```

A.2. Descripción de los campos de CBIS-DDSM

A.2.1. Manifiesto de TCIA (incluido en el repositorio)

El fichero `CBIS-DDSM-All-doiJNLP-zzWs5zfZ-nbia-digest.xlsx` es el manifiesto que genera TCIA al exportar una colección: identifica las series DICOM disponibles pero **no incluye la etiqueta de patología**. Sus campos más relevantes para el *pipeline* son:

Tabla A.1: Campos relevantes del manifiesto de TCIA.

Campo	Descripción
Patient ID	Identificador largo, p. ej. <code>Mass-Training_P_01009_RIGHT_CC_1</code> . <code>src.data.load_manifest</code> extrae de aquí el id real de paciente (P_01009) con una expresión regular, base de la partición por paciente.
Series	Tipo de imagen de la serie: <code>full mammogram images</code> , <code>ROI mask images</code> o <code>cropped images</code> .
Description	
Modality	Modalidad DICOM; MG (mamografía) en todos los casos.
Body Part	Región anatómica (BREAST).
Examined	
Image Count	Número de imágenes DICOM de la serie.
File Size	Tamaño en bytes de la serie (para estimar la descarga total).
Collection URI	DOI de la colección en TCIA [4].
License Name	<i>Creative Commons Attribution 3.0 Unported</i> .

A.2.2. CSV de descripción de casos (a descargar de TCIA)

Los ficheros `mass_/calc_case_description_{train,test}_set.csv` — no incluidos en el repositorio, véase la Sección 7.4.1 — sí contienen la etiqueta clínica. La función `load_case_descriptions` de `src/data.py` espera, entre otros, los campos `patient_id`, `breast_density` (densidad BI-RADS, 1–4), `left or right breast`, `image view` (CC/MLO), `abnormality type` (masa o calcificación), `assessment` (BI-RADS 0–5), `subtlety` y, sobre todo, `pathology` (BENIGN, BENIGN_WITHOUT_CALLBACK, MALIGNANT), que `src.data.to_binary_label` convierte en la etiqueta binaria 0/1 usada en todo el trabajo.

A.3. Fragmentos de código adicionales

A.3.1. Selección automática de backend de homología persistente

Como `giotto-tda` no publica binarios para Python 3.13+ (Sección 7.2.1), `src/topology.py` detecta en tiempo de importación qué backend usar, sin que el resto del *pipeline* necesite saberlo:

```

1 try:
2     from gtda.homology import CubicalPersistence
3     _HAS_GIOTTO = True

```

```

4 except ImportError:
5     _HAS_GIOTTO = False
6
7 try:
8     import gudhi
9     _HAS_GUDHI = True
10 except ImportError:
11     _HAS_GUDHI = False
12
13 def backend() -> str:
14     if _HAS_GIOTTO:
15         return "giotto-tda"
16     if _HAS_GUDHI:
17         return "gudhi"
18     return "none"

```

Listing A.1: Deteccion de backend en src/topology.py (fragmento).

A.3.2. Imagen de persistencia sin giotto-tda

Cuando el backend activo es `gudhi`, la imagen de persistencia se calcula a mano con un núcleo gaussiano ponderado por persistencia, sobre la rejilla fija $[0, 1] \times [0, 1]$ (las imágenes ya están normalizadas por `preprocessing.to_grayscale_float`, Sección 5):

```

1 grid = np.linspace(0.0, 1.0, n_bins)
2 birth_grid, pers_grid = np.meshgrid(grid, grid, indexing="ij")
3 sigma = 1.0 / n_bins
4
5 for birth, pers, weight in zip(births, persistences, weights):
6     image += weight * np.exp(
7         -((birth_grid - birth) ** 2 + (pers_grid - pers) ** 2) / (2 *
8             sigma ** 2)
9     )

```

Listing A.2: Imagen de persistencia manual (núcleo gaussiano), src/topology.py (fragmento).

Al fijar la rejilla de antemano (en vez de ajustarla, *fit*, por lote como hace `giotto-tda`), todas las imágenes del conjunto de datos producen vectores de la misma longitud y directamente comparables entre sí, sin necesitar un paso de ajuste previo sobre el conjunto de entrenamiento.