Universidad de Alicante
Escuela Politécnica Superior

Grado en Ingeniería Informática

Análisis Topológico de Datos aplicado a la clasificación y visualización de mamografías digitales

Trabajo de Fin de Grado

Autor:
Jaime Hernández Delgado

Tutor/es:
Nombre del tutor/a

11 de noviembre de 2026

Resumen

El cáncer de mama es el tumor de mayor incidencia entre las mujeres a nivel mundial, y la mamografía sigue siendo la prueba de cribado de referencia para su detección precoz. En los últimos años, las técnicas de *deep learning* han demostrado un gran potencial en el análisis automático de imagen médica, pero suelen comportarse como cajas negras y son sensibles al ruido y a la variabilidad de adquisición. El **Análisis Topológico de Datos** (TDA, por sus siglas en inglés) ofrece una perspectiva complementaria: cuantifica la *forma* de los datos mediante invariantes topológicos robustos frente al ruido, como la homología persistente.

Este Trabajo de Fin de Grado estudia la aplicación del TDA a la clasificación y visualización de mamografías digitales del conjunto de datos público CBIS-DDSM. Se extraen descriptores topológicos (diagramas de persistencia, códigos de barras e imágenes de persistencia) a partir de las imágenes y de las regiones de interés, se evalúa su capacidad discriminativa entre lesiones benignas y malignas, y se comparan y combinan con modelos de aprendizaje profundo. El objetivo último es obtener un sistema de apoyo al diagnóstico más *interpretable* sin sacrificar rendimiento.

Palabras clave: análisis topológico de datos, homología persistente, mamografía, cáncer de mama, aprendizaje profundo, imagen médica, CBIS-DDSM.

Abstract. Breast cancer is the most common malignancy among women worldwide, and mammography remains the reference screening test for its early detection. Deep learning has shown remarkable potential in medical image analysis, yet such models often behave as black boxes and are sensitive to noise and acquisition variability. **Topological Data Analysis** (TDA) provides a complementary viewpoint by quantifying the *shape* of the data through noise-robust topological invariants such as persistent homology. This bachelor's thesis investigates the application of TDA to the classification and visualisation of digital mammograms from the public CBIS-DDSM dataset. Topological descriptors (persistence diagrams, barcodes and persistence images) are extracted and evaluated for their ability to discriminate benign from malignant lesions, and compared and combined with deep learning models, aiming at a more *interpretable* decision-support system.

Keywords: topological data analysis, persistent homology, mammography, breast cancer, deep learning, medical imaging, CBIS-DDSM.

Índice general

Resumen I

1. Introducción **1**
1.1. Motivación 1
1.2. Contexto del problema 1
1.3. Objetivos y alcance (resumen) 2
1.4. Estructura de la memoria 2

2. Objetivos y metodología **3**
2.1. Objetivo general 3
2.2. Objetivos específicos 3
2.3. Metodología general 4

3. Estado del arte **7**
3.1. Análisis automático de mamografías 7
3.1.1. Conjuntos de datos públicos 7
3.1.2. Limitaciones 8
3.2. Análisis Topológico de Datos en imagen médica 8
3.2.1. Comparación de novedad con los trabajos más cercanos 8
3.3. Predicción de riesgo y análisis longitudinal de mamografía 10
3.4. Síntesis y aportación de este trabajo 10

4. Fundamentos teóricos **13**
4.1. Análisis Topológico de Datos 13
4.1.1. Complejos simpliciales y filtraciones 13
4.1.2. Homología y números de Betti 13
4.1.3. Homología persistente 14
4.1.4. Estabilidad y vectorización 14
4.2. Aprendizaje profundo (referencia) 14
4.2.1. Redes neuronales convolucionales 15
4.2.2. Transfer learning 15

5. Metodología propuesta **17**
5.1. Visión general del *pipeline* . . . 17
5.2. Conjunto de datos . . . 17
5.2.1. Protocolo de evaluación y prevención de fuga de datos . . . 18
5.3. Preprocesado de imágenes . . . 18
5.4. Extracción de descriptores topológicos . . . 18
5.5. Modelos de clasificación . . . 19
5.6. Métricas de evaluación . . . 19
5.7. Métrica de acuerdo topológico-clínico (línea secundaria) . . . 19
5.7.1. Cuatro métodos, una región binaria comparable . . . 19
5.7.2. Métrica de acuerdo . . . 20
5.7.3. Nota metodológica: IoU contra la máscara de ROI real . . . 21
5.7.4. Coste computacional . . . 21
5.7.5. Protocolo estadístico (issue #79) . . . 21
5.7.6. Protocolo de hold-out congelado (issue #89) . . . 22
5.8. Metodología longitudinal (hipótesis principal) . . . 23
5.8.1. Definición de las señales longitudinales . . . 23
5.8.2. Comprobación de ingeniería previa (datos sintéticos, sin resultados) 24
5.8.3. Acceso a datos longitudinales reales . . . 24

6. Implementación **27**
6.1. Herramientas y librerías . . . 27
6.2. Organización del código . . . 27
6.3. Extracción de descriptores topológicos . . . 28
6.4. Reproducibilidad . . . 28
6.5. Visualización . . . 29

7. Experimentos y resultados **31**
7.1. Diseño experimental . . . 31
7.2. Configuración . . . 31
7.2.1. Backend de homología persistente . . . 32
7.3. Resultados sobre el piloto real de CBIS-DDSM . . . 32
7.3.1. El AUC baja al ampliar el piloto (y por qué es una buena noticia) 33
7.3.2. Refinamiento: ajuste de hiperparámetros por vía (issue #77) . . 34
7.3.3. Sanity check visual: masa espiculada benigna vs. maligna . . . 34
7.3.4. Estado de los datos . . . 35
7.4. Interpretabilidad: TDA vs Grad-CAM vs SHAP vs LIME . . . 36
7.4.1. El hallazgo principal: los cuatro métodos apenas coinciden entre sí 36
7.4.2. IoU contra la máscara de ROI real . . . 38
7.4.3. Desglose por tipo de margen de la masa y por densidad mamaria 38

7.4.4. Coste computacional 39
7.5. Evaluación real de la hipótesis longitudinal (EMBED, O8) 39
7.6. Discusión 40

8. Conclusiones y trabajo futuro **43**
8.1. Conclusiones 43
8.2. Grado de cumplimiento de los objetivos 45
8.3. Limitaciones 46
8.4. Trabajo futuro 46

Bibliografía **49**

A. Material adicional **53**
A.1. Instalación del entorno 53
A.2. Descripción de los campos de CBIS-DDSM 53
A.2.1. Manifiesto de TCIA (incluido en el repositorio) 53
A.2.2. CSV de descripción de casos (a descargar de TCIA) 54
A.3. Fragmentos de código adicionales 54
A.3.1. Selección automática de backend de homología persistente . . . 54
A.3.2. Imagen de persistencia sin giotto-tda 55

Índice de figuras

5.1. Esquema general del *pipeline* propuesto: de los datos crudos a las métricas clínicas, pasando por la extracción de descriptores topológicos. . . . 17

7.1. Caso real benigno (`P_00692`, arriba) y maligno (`P_00734`, abajo) con margen de masa espiculado, con su diagrama de persistencia H0/H1 (backend `gudhi`). 35

7.2. Caso de mayor acuerdo TDA/Grad-CAM del piloto (`P_00592`, arriba) frente al de menor acuerdo (`P_00409`, abajo), con las 4 regiones superpuestas en rojo sobre la imagen preprocesada. 37

Índice de tablas

2.1. Trazabilidad entre objetivos específicos y capítulos de la memoria. . . . 5

3.1. Comparación con los dos trabajos de TDA en mamografía más cercanos identificados (issue #51). 9

6.1. Principales herramientas utilizadas. 27

7.1. Resultados reales sobre el piloto de CBIS-DDSM (70 pacientes, `scripts/run_pipeline.py` y `scripts/fuse_and_evaluate.py`, `n_bins=4`, Random Forest por defecto). El AUC por validación cruzada (5-fold sobre train) es la columna fiable; el test de solo 21 casos sigue siendo ruidoso (ver discusión debajo de la tabla). 33

7.2. AUC por validación cruzada (5-fold, train, piloto de 70 pacientes) con *random forest* por defecto, *random forest* ajustada y SVM ajustada por `GridSearchCV` ($n_bins = 4$, $C \in \{0{,}01, \ldots, 100\}$, kernel lineal/RBF). "Mejor encontrado" es el máximo de las tres. 34

7.3. Acuerdo por pares entre los 4 métodos de interpretabilidad (IoU media, intervalo de confianza 95 % por *bootstrap*, $n = 122$ casos reales). 36

7.4. IoU de cada método contra la máscara de ROI real (IC 95 % *bootstrap*, $n = 119$ casos con máscara disponible). 38

7.5. Coste computacional por método (segundos/caso, $n = 122$). 39

7.6. AUC por validación cruzada (5-fold) de cada señal longitudinal sobre el piloto REAL de EMBED (`scripts/embed_longitudinal_evaluation.py`, $n = 99$ pacientes). 40

8.1. Grado de cumplimiento de los objetivos específicos. 45

A.1. Campos relevantes del manifiesto de TCIA. 54

Capítulo 1

Introducción

1.1. Motivación

El cáncer de mama es la neoplasia más frecuente en mujeres y una de las principales causas de mortalidad por cáncer a nivel mundial. La detección precoz mediante programas de cribado con mamografía reduce de forma significativa la mortalidad, ya que permite identificar lesiones en estadios tempranos y más tratables. Sin embargo, la interpretación de mamografías es una tarea compleja, sujeta a variabilidad inter-observador y a una carga de trabajo elevada para los radiólogos.

En este contexto, los sistemas de diagnóstico asistido por computador (*Computer-Aided Diagnosis*, CAD) y, más recientemente, las técnicas de aprendizaje profundo (*deep learning*) se han convertido en herramientas de gran interés. Trabajos como el de Yala *et al.* [20] han demostrado que los modelos basados en mamografía pueden mejorar la predicción del riesgo de cáncer de mama. No obstante, estos modelos presentan limitaciones importantes: son difíciles de interpretar, requieren grandes cantidades de datos etiquetados y pueden ser sensibles al ruido y a las condiciones de adquisición.

El **Análisis Topológico de Datos** (TDA) surge como un enfoque complementario que caracteriza la *forma* intrínseca de los datos mediante herramientas de la topología algebraica. Su técnica principal, la *homología persistente*, es robusta frente al ruido y proporciona descriptores interpretables geométricamente, lo que la hace especialmente atractiva para el análisis de imagen médica.

1.2. Contexto del problema

Una mamografía digital es una imagen de rayos X de la mama que revela estructuras como el tejido glandular, los conductos, las calcificaciones y posibles masas. La densidad mamaria (clasificada habitualmente según el sistema BI-RADS) y la morfología de las lesiones son factores clave en el diagnóstico. El conjunto de datos público

CBIS-DDSM [13] proporciona mamografías digitalizadas con anotaciones de lesiones (masas y microcalcificaciones), regiones de interés (ROI) segmentadas y etiquetas de patología (benigno/maligno), lo que lo convierte en un banco de pruebas adecuado para este trabajo.

1.3. Objetivos y alcance (resumen)

El objetivo general de este TFG es **estudiar y evaluar la aplicación del Análisis Topológico de Datos a la clasificación y visualización de mamografías**, comparándolo y combinándolo con técnicas de aprendizaje profundo. Los objetivos específicos se detallan en el Capítulo 2.

1.4. Estructura de la memoria

El resto de la memoria se organiza como sigue:

- El **Capítulo 2** formula los objetivos y la metodología general del trabajo.
- El **Capítulo 3** revisa el estado del arte en análisis de mamografías y en TDA aplicado a imagen médica.
- El **Capítulo 4** introduce los fundamentos teóricos de la homología persistente y del aprendizaje profundo.
- El **Capítulo 5** describe la metodología propuesta: datos, preprocesado, extracción de descriptores y modelos.
- El **Capítulo 6** detalla la implementación y las herramientas utilizadas.
- El **Capítulo 7** presenta y discute los resultados experimentales.
- El **Capítulo 8** recoge las conclusiones y las líneas de trabajo futuro.

Capítulo 2

Objetivos y metodología

2.1. Objetivo general

El objetivo general de este Trabajo de Fin de Grado es **investigar si el Análisis Topológico de Datos (TDA) permite la detección anticipada del cáncer de mama mediante el análisis longitudinal de mamografías sucesivas de una misma paciente**: comparar los descriptores topológicos de la exploración previa (leída clínicamente como normal) con los de la exploración donde el cáncer se diagnostica, para determinar si ya existía una señal topológica medible antes del diagnóstico. Esta hipótesis se apoya en una base necesaria — la clasificación benigno/maligno sobre una mamografía aislada mediante homología persistente, y su comparación con un modelo de *deep learning* — que constituye la primera mitad de los objetivos específicos.

2.2. Objetivos específicos

Para alcanzar el objetivo general se plantean los siguientes objetivos específicos:

O1. Revisar el estado del arte en (i) análisis automático de mamografías, (ii) aplicaciones del TDA en imagen médica y (iii) predicción de riesgo/análisis longitudinal de mamografías.

O2. Preparar y preprocesar un conjunto de datos de mamografía (CBIS-DDSM para la base de clasificación; un conjunto longitudinal — CSAW-CC o EMBED, pendiente de acceso, ver Capítulo 5 — para la hipótesis principal): descarga, limpieza de metadatos, extracción de ROIs y normalización de las imágenes.

O3. Extraer descriptores topológicos (diagramas de persistencia, códigos de barras e imágenes de persistencia) a partir de las mamografías mediante homología persistente.

O4. Entrenar y evaluar clasificadores sobre los descriptores topológicos (p. ej. SVM, *random forest*) para la tarea benigno/maligno sobre una mamografía aislada.

O5. Comparar el enfoque topológico con un modelo de *deep learning* de referencia (CNN con *transfer learning*) y **explorar su combinación** (fusión de características).

O6. Desarrollar herramientas de visualización que hagan interpretables los resultados topológicos para su uso como apoyo al diagnóstico.

O7. Diseñar y validar la metodología de comparación longitudinal: definir cómo medir el cambio topológico entre dos exploraciones de la misma paciente (distancia *bottleneck*/ Wasserstein entre diagramas de persistencia) y validar que el *pipeline* es capaz de detectar esa señal cuando existe, inicialmente sobre datos sintéticos controlados.

O8. Evaluar la hipótesis de detección anticipada sobre datos longitudinales reales: determinar si los descriptores topológicos de la exploración previa (sin diagnóstico) distinguen a las pacientes que desarrollarán cáncer de las que no, y comparar esta señal con los modelos de predicción de riesgo basados en *deep learning* ya publicados (p. ej. LongiMam [16]).

2.3. Metodología general

El desarrollo del trabajo sigue una metodología incremental e iterativa, estructurada en las siguientes fases, alineadas con los objetivos anteriores:

1. **Fase de documentación** (O1): estudio de la bibliografía y de las herramientas disponibles.

2. **Fase de datos** (O2): construcción de un *pipeline* reproducible de preparación de datos.

3. **Fase de extracción de características** (O3): implementación de la extracción de descriptores topológicos.

4. **Fase de modelado** (O4, O5): entrenamiento, validación y comparación de modelos, evitando la fuga de datos (*data leakage*) mediante una separación estricta *train/validation/test*.

5. **Fase de análisis y visualización** (O6): interpretación de los resultados y desarrollo de visualizaciones.

6. **Fase longitudinal** (O7, O8): diseño de la comparación topológica entre exploraciones sucesivas, validación con datos sintéticos y, en cuanto se obtenga acceso a un dataset real longitudinal, evaluación de la hipótesis de detección anticipada.

7. **Fase de redacción** de la memoria.

Tabla 2.1: Trazabilidad entre objetivos específicos y capítulos de la memoria.

Objetivo	**Descripción breve**	**Capítulo**
O1	Estado del arte	3
O2	Preparación de datos	5, 6
O3	Descriptores topológicos	4, 5
O4	Clasificadores sobre TDA	5, 7
O5	Comparación con DL	7
O6	Visualización	6, 7
O7	Diseño y validación sintética de la comparación longitudinal	5, 7
O8	Evaluación de la hipótesis de detección anticipada (datos reales)	7, 8

Capítulo 3

Estado del arte

Este capítulo revisa los trabajos previos relevantes en dos líneas complementarias: el análisis automático de mamografías mediante aprendizaje profundo, y las aplicaciones del Análisis Topológico de Datos en imagen médica.

3.1. Análisis automático de mamografías

El análisis asistido por computador de mamografías tiene una larga trayectoria, desde los primeros sistemas CAD basados en características diseñadas manualmente (*hand-crafted features*) hasta los actuales enfoques de aprendizaje profundo. Las redes neuronales convolucionales (CNN) se han consolidado como el paradigma dominante en visión por computador y en imagen médica, gracias a su capacidad para aprender jerarquías de características directamente de los datos [1], [14].

En el ámbito específico de la mamografía, destacan trabajos orientados a la detección y clasificación de masas y microcalcificaciones, así como a la estimación del riesgo. Yala *et al.* [20] propusieron un modelo basado en *deep learning* que mejora la predicción del riesgo de cáncer de mama a partir de la mamografía, superando a los modelos de riesgo tradicionales. El uso de *transfer learning* a partir de redes preentrenadas en ImageNet (ResNet, DenseNet, EfficientNet, etc.) es una práctica habitual para mitigar la escasez de datos etiquetados en el dominio médico.

3.1.1. Conjuntos de datos públicos

Entre los conjuntos de datos públicos de mamografía más utilizados destaca CBIS-DDSM [13], una versión curada y estandarizada del clásico DDSM que incluye segmentaciones de ROI verificadas y etiquetas de patología. Otros recursos relevantes son INbreast y las bases de datos de ecografía mamaria.

3.1.2. Limitaciones

A pesar de sus buenos resultados, los modelos de *deep learning* en mamografía presentan limitaciones bien conocidas:

- **Interpretabilidad limitada**: su naturaleza de caja negra dificulta la confianza clínica y la certificación.
- **Dependencia de grandes volúmenes de datos** etiquetados.
- **Riesgo de fuga de datos** (*data leakage*) y de sesgos de adquisición, que pueden producir métricas artificialmente altas si el protocolo experimental no es riguroso.

Estas limitaciones motivan la búsqueda de representaciones más robustas e interpretables, como las que proporciona el TDA.

3.2. Análisis Topológico de Datos en imagen médica

El Análisis Topológico de Datos (TDA) engloba un conjunto de técnicas que estudian la forma de los datos mediante herramientas de topología algebraica [3], [6]. Su herramienta central, la *homología persistente*, ha sido aplicada con éxito en diversos problemas de imagen médica: caracterización de texturas de tumores, análisis de imágenes histopatológicas, neuroimagen y detección de estructuras en radiología.

En el contexto de la mamografía y del cáncer de mama, los descriptores topológicos permiten capturar patrones de conectividad y estructura (número de componentes conexas, agujeros, ramificaciones de conductos, distribución de microcalcificaciones) que resultan difíciles de modelar con características convencionales. Su robustez frente al ruido y su interpretabilidad geométrica los convierten en un complemento natural de las CNN.

3.2.1. Comparación de novedad con los trabajos más cercanos

Dos trabajos muy recientes aplican homología persistente a la clasificación de mamografías de forma cercana a la base de este TFG (issue #51), y conviene distinguir explícitamente en qué se diferencia este trabajo de ambos:

Tabla 3.1: Comparación con los dos trabajos de TDA en mamografía más cercanos identificados (issue #51).

	Jetomo et al. 2025 [9]	**Hitit Univ. 2026** [5]	**Este TFG**
Dataset	INbreast	No verificado (artículo de pago)	CBIS-DDSM (piloto real descargado)
Features	HOG + PCA + PHCA (algoritmo propio de clasificación por homología persistente)	Homología persistente (sublevel set) + momentos de Zernike + Haralick/GLCM	Imágenes de persistencia H0+H1 (`gudhi`/`giotto-tda`)
Comparación con *deep learning*	No reportada en el resumen disponible	No reportada en el resumen disponible	Sí: CNN (DenseNet121) y fusión TDA+CNN (Capítulo 7)
Interpretabilidad	No es el foco	No es el foco (se presenta la TDA como alternativa interpretable, pero sin comparar contra XAI)	Sí: comparación sistemática con Grad-CAM, SHAP y LIME (Sección 7.4)
Longitudinal/temporal	No	No	Sí: hipótesis principal (Capítulo 2, O7–O8)

Los dos comparten con este TFG el uso de homología persistente para clasificación benigno/maligno sobre una mamografía aislada, pero ninguno compara explícitamente su enfoque topológico contra una CNN de referencia entrenada en el mismo conjunto, ni contra métodos de explicabilidad estándar (Grad-CAM, SHAP, LIME), y ninguno aborda el análisis longitudinal. Esto confirma, desde el ángulo de los trabajos más afines (no solo desde la ausencia general de literatura ya discutida en la Sección 3.3), que el hueco de novedad que ocupa este TFG — combinación con *deep learning*, **comparación sistemática de interpretabilidad** e **hipótesis longitudinal** — sigue sin estar cubierto.

Nota de verificación: el artículo de Hitit University (EPJ Plus, 2026) está detrás de muro de pago; su descripción metodológica proviene de su resumen público, no de una lectura completa, y sus métricas de rendimiento no se han podido verificar directamente (ver nota en `tfg/bibliografia.bib`). Queda pendiente completar la verificación si se consigue acceso a texto completo.

3.3. Predicción de riesgo y análisis longitudinal de mamografía

Una línea de trabajo más reciente y directamente relevante para la hipótesis principal de este TFG (Capítulo 2) es la que usa **varias exploraciones sucesivas** de la misma paciente, en vez de una única mamografía, para predecir el riesgo de cáncer. Dadsetan *et al.* [4] fueron de los primeros en mostrar que un modelo de *deep learning* entrenado sobre pares longitudinales de mamografías mejora la predicción de riesgo frente a usar solo la exploración más reciente. Trabajos más recientes refinan esta idea: LongiMam [16] combina explícitamente la exploración actual y las previas en un único modelo; STA-Risk [21] explota asimetrías espacio-temporales entre exploraciones; Karimian *et al.* [10] proponen destilar el historial longitudinal hacia un modelo que solo necesita la exploración actual en inferencia (*privileged information*); y Thrun *et al.* [19] estudian específicamente el problema — no trivial — de **alinear espacialmente** exploraciones de distinta fecha antes de compararlas. Kooi y Karssemeijer [12] y Bai *et al.* [2] abordan variantes anteriores del mismo problema (cambio temporal y simetría entre mamas) con CNN y modelos no supervisados, respectivamente.

Todos estos trabajos son de *deep learning* end-to-end sobre píxeles; ninguno usa descriptores topológicos. En paralelo, la aplicación de TDA a mamografía (Sección 3.2 y [7]) trabaja siempre sobre una **única exploración por caso**. Una búsqueda sistemática (arXiv, Google Scholar; 2026-10-07) combinando "persistent homology/"topological data analysisçon "longitudinal/"temporalƶ "mammography/"breast cancer"no encontró ningún trabajo que combine ambas líneas. Un *survey* de aplicaciones de TDA en oncología citado en esa búsqueda llega a sugerir explícitamente el análisis de series temporales en cáncer como dirección futura no explorada, lo que corrobora el hueco. Esto deja planteada la pregunta que motiva la hipótesis principal de este trabajo: **¿aporta la homología persistente, aplicada al cambio topológico entre exploraciones sucesivas, una señal predictiva que los modelos de *deep learning* longitudinal actuales no capturan — o capturan de forma menos interpretable?**

3.4. Síntesis y aportación de este trabajo

La revisión anterior muestra dos líneas activas que, hasta donde se ha podido verificar, no se han combinado todavía: el TDA aplicado a una mamografía aislada (prometedor pero poco explorado frente al *deep learning* dominante) y la predicción de riesgo mediante *deep learning* sobre exploraciones longitudinales (activa y reciente, pero exclusivamente basada en píxeles). La aportación de este TFG parte de un estudio sistemático de descriptores topológicos sobre CBIS-DDSM para la clasificación

benigno/maligno sobre una mamografía aislada — necesario como base, y comparado y combinado con un modelo de *deep learning* de referencia — pero su objetivo central es extender esa base al caso longitudinal: usar la homología persistente para comparar la exploración previa (normal) con la exploración donde se diagnostica el cáncer, y evaluar si ya existía una señal topológica medible antes del diagnóstico (Capítulo 5, Sección 5.8).

Capítulo 4

Fundamentos teóricos

Este capítulo introduce los conceptos necesarios para comprender el trabajo: los fundamentos del Análisis Topológico de Datos, con énfasis en la homología persistente, y una breve descripción de los modelos de aprendizaje profundo empleados como referencia.

4.1. Análisis Topológico de Datos

El TDA parte de la idea de que los datos poseen una *forma* y que dicha forma contiene información relevante. Formalmente, se construye a partir de los datos una familia de espacios topológicos y se estudia cómo evolucionan sus invariantes.

4.1.1. Complejos simpliciales y filtraciones

Definición 4.1 (Complejo simplicial)**.** Un *complejo simplicial* K es un conjunto de símplices (vértices, aristas, triángulos, tetraedros, ...) cerrado bajo la operación de tomar caras y tal que la intersección de dos símplices es una cara de ambos.

Para analizar datos se construye una *filtración*, es decir, una familia anidada de complejos simpliciales

$$\emptyset = K_0 \subseteq K_1 \subseteq \cdots \subseteq K_n = K,$$

indexada por un parámetro de escala. En imágenes, una filtración habitual es la *filtración por sublevel sets* de la intensidad: se van incluyendo los píxeles cuyo valor es menor o igual que un umbral creciente.

4.1.2. Homología y números de Betti

La homología asocia a cada complejo una secuencia de grupos cuyos rangos, los *números de Betti* β_k, cuentan las características topológicas de dimensión k:

- β_0: número de **componentes conexas**.
- β_1: número de **agujeros** o ciclos unidimensionales.
- β_2: número de **cavidades** o huecos tridimensionales.

4.1.3. Homología persistente

La *homología persistente* rastrea el nacimiento (*birth*) y la muerte (*death*) de las características topológicas a lo largo de la filtración. Una característica que persiste durante un amplio rango de escalas se considera una propiedad estructural significativa, mientras que las de vida corta suelen corresponder a ruido.

Definición 4.2 (Diagrama de persistencia)**.** El *diagrama de persistencia* es un multiconjunto de puntos $(b_i, d_i) \in \mathbb{R}^2$ con $b_i \leq d_i$, donde cada punto representa una característica topológica que nace en la escala b_i y muere en d_i. La *persistencia* de la característica es $d_i - b_i$.

La misma información puede representarse como un *código de barras* (*barcode*), donde cada característica es un intervalo $[b_i, d_i]$.

4.1.4. Estabilidad y vectorización

Una propiedad fundamental es la **estabilidad**: pequeñas perturbaciones en los datos producen pequeñas variaciones en el diagrama de persistencia (medidas con la distancia *bottleneck* o de Wasserstein). Esto explica la robustez del TDA frente al ruido.

Para poder utilizar los diagramas como entrada de algoritmos de aprendizaje automático es necesario *vectorizarlos*. Entre las representaciones más utilizadas destacan:

- **Imágenes de persistencia** (*persistence images*): transforman el diagrama en una imagen (matriz) de tamaño fijo.
- **Persistence landscapes**: funciones a trozos que resumen el diagrama.
- **Curvas de Betti** y estadísticos de persistencia.

4.2. Aprendizaje profundo (referencia)

Como referencia comparativa se emplean redes neuronales convolucionales (CNN).

4.2.1. Redes neuronales convolucionales

Una CNN aprende, mediante capas convolucionales, jerarquías de características espaciales a partir de las imágenes. Combinada con capas de *pooling* y capas totalmente conectadas, permite abordar tareas de clasificación de imagen.

4.2.2. Transfer learning

Dado el tamaño limitado de los conjuntos de datos médicos, se recurre al *transfer learning*: se parte de una red preentrenada en un gran corpus (p. ej. ImageNet) y se ajusta (*fine-tuning*) a la tarea de mamografía. En este trabajo se utiliza como referencia una arquitectura de la familia DenseNet/ResNet.

Ejemplo 4.1 (Intuición del enfoque topológico en mamografía)**.** Una agrupación de microcalcificaciones puede caracterizarse por el número de componentes conexas (β_0) y su patrón de aparición a lo largo de la filtración de intensidad, mientras que la estructura de una masa espiculada puede reflejarse en la aparición y desaparición de ciclos (β_1). El TDA codifica estos patrones de forma compacta y robusta.

Capítulo 5

Metodología propuesta

En este capítulo se describe la metodología propuesta para aplicar el TDA a la clasificación de mamografías, desde la preparación de los datos hasta la evaluación de los modelos.

5.1. Visión general del *pipeline*

El sistema propuesto consta de cinco etapas:

1. Preparación de datos (CBIS-DDSM).
2. Preprocesado de imágenes y extracción de ROIs.
3. Extracción de descriptores topológicos.
4. Clasificación (topológica, *deep learning* y fusión).
5. Evaluación y visualización.

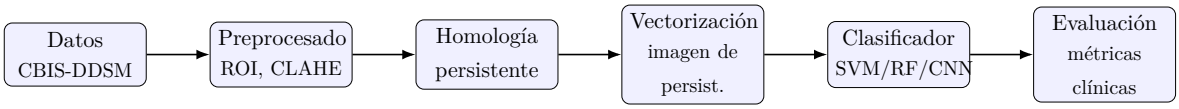


Figura 5.1: Esquema general del *pipeline* propuesto: de los datos crudos a las métricas clínicas, pasando por la extracción de descriptores topológicos.

5.2. Conjunto de datos

Se utiliza CBIS-DDSM [13]. El fichero de metadatos disponible en el repositorio (`CBIS-DDSM-All-... .xlsx`) contiene la información de cada estudio: identificador de paciente, tipo de lesión (masa o calcificación), densidad de la mama (BI-RADS), vista (CC/MLO), y la etiqueta de patología (`BENIGN`, `MALIGNANT`, `BENIGN_WITHOUT_CALLBACK`).

- **Tarea principal**: clasificación binaria benigno vs. maligno.
- **Unidad de análisis**: región de interés (ROI) de la lesión y/o imagen completa reescalada.

5.2.1. Protocolo de evaluación y prevención de fuga de datos

Se adopta una partición estricta en **entrenamiento / validación / test**. Para evitar la fuga de datos (*data leakage*), la separación se realiza **a nivel de paciente**: todas las imágenes de un mismo paciente pertenecen a una única partición. Se emplea estratificación por la etiqueta de patología para mantener la proporción de clases.

> *Nota metodológica.* En el material de partida (`Demo_Notebook.ipynb`) se observaba una exactitud de entrenamiento del 100 % desde la primera época y una exactitud de validación cercana al 100 %, lo que es un indicio claro de fuga de datos o de un problema en el *pipeline*. Este trabajo corrige dicho protocolo mediante partición por paciente, control de la normalización y validación cruzada.

5.3. Preprocesado de imágenes

El preprocesado incluye:

- Conversión y normalización de intensidades.
- Recorte de la ROI a partir de las máscaras de segmentación.
- Reescalado a un tamaño común (p. ej. 224×224).
- Opcionalmente, realce de contraste (CLAHE) y filtrado de ruido.

5.4. Extracción de descriptores topológicos

A partir de cada imagen (o ROI) se calcula la homología persistente mediante una filtración por *sublevel sets* de la intensidad (para imágenes en escala de grises) o sobre nubes de puntos derivadas de las microcalcificaciones. Se obtienen los diagramas de persistencia en dimensiones 0 y 1, y a partir de ellos se generan los vectores de características:

- Imágenes de persistencia.
- Estadísticos de persistencia (número de puntos, persistencia total, máxima, media; curvas de Betti).

5.5. Modelos de clasificación

Se comparan tres enfoques:

1. **Topológico**: clasificadores clásicos (SVM, *random forest*, regresión logística) sobre los descriptores topológicos.
2. **Deep learning**: CNN con *transfer learning* sobre las imágenes.
3. **Fusión**: combinación de las características topológicas con las *embeddings* de la CNN.

5.6. Métricas de evaluación

Dado el carácter clínico del problema, se emplean varias métricas complementarias:

- **Exactitud** (*accuracy*).
- **Sensibilidad** (*recall*) — crítica para no pasar por alto casos malignos.
- **Especificidad** y **precisión**.
- **F1-score** y **AUC-ROC**.
- **Matriz de confusión**.

La sensibilidad recibe especial atención, ya que un falso negativo (no detectar un cáncer) tiene un coste clínico mucho mayor que un falso positivo.

5.7. Métrica de acuerdo topológico-clínico (línea secundaria)

Antes del pivote hacia la hipótesis longitudinal (Sección 5.8), el eje central del TFG comparaba la **interpretabilidad** del enfoque topológico frente a los métodos de explicabilidad habituales en *deep learning*: Grad-CAM [18], SHAP [15] y LIME [17]. Tras el pivote deja de ser la contribución central, pero se mantiene como línea secundaria (issue #91) y se ha implementado sobre el piloto real de CBIS-DDSM (`src/explainability.py`, `scripts/explainability_benchmark.py`).

5.7.1. Cuatro métodos, una región binaria comparable

Para que los cuatro métodos puedan compararse entre sí con la misma métrica, cada uno produce, sobre la **misma imagen preprocesada**, una región binaria de la imagen:

Grad-CAM Mapa de saliencia estándar (Selvaraju et al. 2017) sobre la salida de la última capa convolucional de la CNN de referencia (`model.features` de DenseNet121): se pondera cada canal de activación por el promedio espacial de su gradiente respecto a la clase predicha, se aplica ReLU y se reescala a la resolución de la imagen. Se binariza quedándose con el 20 % de píxeles más salientes (percentil 80).

Región topológica dominante El par de persistencia (H0 o H1) con mayor persistencia se localiza en píxeles concretos mediante `gudhi.cofaces_of_persistence_pairs()`, que asocia cada par de persistencia a dos celdas top-dimensionales (dos píxeles). Se umbraliza la imagen en el punto medio de los valores de nacimiento y muerte de ese par, y se toma la componente conexa del conjunto de sublevel resultante que contiene el píxel de nacimiento. Para H1 esto es una aproximación razonable — la región real"de un ciclo no es, en general, un conjunto de sublevel simple — no una reconstrucción exacta del ciclo representativo (gudhi no calcula ciclos representativos para complejos cúbicos).

SHAP `GradientExplainer` [15] sobre la misma CNN, con una imagen en negro como referencia (*background*). Se suman los valores de Shapley en valor absoluto sobre los 3 canales y se binariza igual que Grad-CAM (percentil 80).

LIME `lime_image` [17], con segmentación en superpíxeles (`quickshift` de scikit-image) y la misma CNN como función de predicción. Se toman los superpíxeles con contribución positiva a la clase predicha como región binaria.

5.7.2. Métrica de acuerdo

Dadas dos regiones binarias A y B (de cualquiera de los cuatro métodos, o de la máscara de ROI real), el acuerdo se mide con la intersección sobre unión (*Jaccard*) y, de forma complementaria, con el coeficiente de Dice:

$$\mathrm{IoU}(A,B) = \frac{|A \cap B|}{|A \cup B|}, \qquad \mathrm{Dice}(A,B) = \frac{2\,|A \cap B|}{|A| + |B|}.$$

Se calcula el acuerdo **por pares entre los cuatro métodos** (6 combinaciones) sobre todos los casos usables del piloto real — entrenamiento y test juntos, ya que este es un estudio descriptivo de interpretabilidad, no una evaluación predictiva, así que no hace falta reservar partición de test (issue #62) — y se desglosa por `mass_margins` (el campo de CBIS-DDSM que distingue, p. ej., márgenes circunscritos de espiculados) para ver si el acuerdo entre métodos varía según el tipo de lesión.

5.7.3. Nota metodológica: IoU contra la máscara de ROI real

Además del acuerdo entre métodos, se calcula también el IoU de cada método contra la máscara de ROI real (referencia clínica, disponible para cada caso de CBIS-DDSM). Es importante señalar una limitación honesta de esta comparación concreta: como la imagen ya está recortada muy cerca de la ROI (margen de 16 px, `src/preprocessing.py:crop_roi`, igual que el resto del *pipeline*), ese recorte sesga al alza el IoU de **cualquier** región central razonable contra la máscara por pura construcción geométrica, y por tanto es menos informativo que el acuerdo entre métodos de arriba. Se reporta por completitud (issue #61 lo pide explícitamente como referencia clínica), pero la conclusión principal de este estudio debe apoyarse en el acuerdo *inter*-método, no en este número.

5.7.4. Coste computacional

Se mide el tiempo de cómputo de cada método por caso (issue #66): Grad-CAM y la región topológica dominante son prácticamente instantáneos (menos de 0,2 s/caso); LIME tarda del orden de medio segundo a unos pocos segundos por caso según el número de muestras de perturbación; SHAP (`GradientExplainer`) es, con diferencia, el método más costoso (del orden de 20 s/caso en el entorno de desarrollo), lo que es relevante para valorar la viabilidad práctica del TDA como çapa de interpretabilidad nativa– su coste es orden de magnitud menor que el de SHAP, y comparable o menor que el de Grad-CAM/LIME, sin necesitar entrenar ni ejecutar inferencia de una CNN.

5.7.5. Protocolo estadístico (issue #79)

Con un piloto de pocas decenas de casos, reportar solo la media de una métrica invita a sobreinterpretar diferencias que podrían deberse al azar. Se adopta el siguiente protocolo, implementado en `src/evaluate.py:bootstrap_ci/paired_test` y aplicado tanto a los resultados de clasificación (Sección 7.3) como a los de interpretabilidad (Sección 7.4):

- **Intervalo de confianza por *bootstrap*** (percentil, 2000 remuestreos) para la media de cualquier métrica agregada (IoU medio, AUC por CV), en vez de un intervalo paramétrico que asuma normalidad — poco justificable con n pequeño.
- **Test pareado de Wilcoxon** (*signed-rank*) cuando se comparan dos métricas sobre **los mismos casos** (p. ej. el IoU de TDA/Grad-CAM frente al de SHAP/LIME, caso a caso): es la alternativa no paramétrica al t-test pareado, apropiada cuando no se puede asumir que las diferencias se distribuyen normalmente.

- **Desglose por subgrupo clínico** (`mass_margins`, `breast_density`): reportar la métrica también por categoría, no solo agregada, para detectar si el resultado global esconde heterogeneidad (p. ej. un método que funciona bien solo en mamas de densidad baja).

Un hallazgo metodológico colateral de implementar este desglose: el CSV de masas de CBIS-DDSM usa la columna `breast_density` (con guion bajo) y el de calcificaciones `breast density` (con espacio); si la normalización de nombres de columna se aplica **después** de concatenar ambos CSV, `pandas` no las fusiona y el resultado son **dos** columnas llamadas `breast_density` en vez de una — un error silencioso que no lanza ninguna excepción, solo produce columnas mal pobladas. Se corrigió normalizando los nombres de columna por CSV individual, antes de concatenar (`src/data.py:load_case_descriptions`), con un test de regresión que fija este comportamiento.

5.7.6. Protocolo de hold-out congelado (issue #89)

Un riesgo metodológico clásico — y el mismo tipo de error que este trabajo ya identificó y corrigió una vez (la fuga de datos del `Demo_Notebook.ipynb` original, Sección 5) — es tomar decisiones de diseño (umbral de binarización, resolución del descriptor, hiperparámetros del clasificador) mirando el mismo conjunto de datos sobre el que después se reportan los resultados finales. Para evitarlo, se declaran aquí por escrito las decisiones tomadas y en qué fase del proyecto:

- **Resolución del *Persistence Image*** ($n_bins = 4$): elegida mediante el barrido empírico de la Sección 7.3.2 sobre el piloto **inicial de 30 pacientes** (issue #77).

- **Umbral de binarización de Grad-CAM/SHAP** (percentil 80, el 20 % de píxeles más salientes): fijado en el diseño de `src/explainability.py` (issue #59/#64), sin ajustarlo por búsqueda sobre ningún tamaño de piloto concreto.

- **Clasificador y sus hiperparámetros** (Random Forest por defecto; SVM con `GridSearchCV` como alternativa, Sección 7.3.2): la búsqueda de `GridSearchCV` se repite en cada ejecución sobre el *split* de entrenamiento vigente en ese momento (no se fija un valor concreto a fuego), precisamente para no congelar una configuración óptima para un tamaño de piloto que luego deja de serlo al ampliar el piloto (ver la caída del CV-AUC de TDA de 0,850 a 0,658 al pasar de 30 a 70 pacientes, Sección 7.3.1, como ejemplo de por qué fijar hiperparámetros de una vez por todas sería mala idea aquí).

Estas tres decisiones se tomaron **antes** de ampliar el piloto de CBIS-DDSM de 30 a 70 pacientes (issue #82) y de EMBED de 20+20 a 50+50 pacientes (issue #95), y no se han vuelto a ajustar mirando los datos ampliados: todos los resultados de los Capítulos 5 y 7 sobre los pilotos ampliados usan exactamente la misma resolución, el mismo umbral y el mismo procedimiento de ajuste de hiperparámetros que sobre el piloto inicial.

`scripts/download_cbis_ddsm.py:select_new_cases` excluye explícitamente, por construcción, a los pacientes ya descargados (`already_downloaded_patients()`) antes de elegir el siguiente lote; se ha verificado que los 70 pacientes en disco son efectivamente 70 identificadores de paciente distintos, no casos adicionales de los mismos 30 pacientes del piloto inicial, cumpliendo el criterio de aceptación de la issue #89 sobre no mezclar pacientes de ajuste con pacientes nuevos.

5.8. Metodología longitudinal (hipótesis principal)

Las secciones anteriores describen la clasificación benigno/maligno sobre una mamografía **aislada**, que constituye la base necesaria del trabajo (objetivos O3–O6). La hipótesis **principal** del TFG, sin embargo, es de naturaleza distinta: no preguntar si una imagen ya diagnosticada es maligna, sino si la exploración **anterior** de la misma paciente — leída clínicamente como normal — ya contenía una señal topológica de la lesión que se diagnosticaría después.

5.8.1. Definición de las señales longitudinales

Para una paciente con dos exploraciones sucesivas, $t-1$ (previa, sin diagnóstico) y t (donde se diagnostica la lesión), se calculan los diagramas de persistencia D_{t-1} y D_t mediante el mismo procedimiento de la Sección 5.4 y se derivan dos señales candidatas:

- **Anticipación**: el vector de características topológicas (imagen de persistencia, estadísticos) calculado **únicamente** sobre D_{t-1}. Mide si la exploración previa, por sí sola, ya es distinguible de la de una paciente control.
- **Deriva** (*drift*): la distancia *bottleneck* (o Wasserstein) entre D_{t-1} y D_t, $d(D_{t-1}, D_t)$, calculada por dimensión de homología (H_0, H_1) con la librería `persim`. Mide cuánto cambia la topología entre ambas exploraciones.
- **Combinada**: concatenación de ambas señales anteriores.

Cada señal se evalúa como entrada de un clasificador binario (paciente "incidente", que desarrolla la lesión en t, frente a paciente "control", sin lesión en ninguna de las dos exploraciones), reportando el AUC por validación cruzada de 5 particiones en vez

de un único *split* de test, dado el tamaño reducido de las cohortes disponibles (mismo criterio de robustez estadística aplicado en la clasificación aislada, ver Capítulo 7).

5.8.2. Comprobación de ingeniería previa (datos sintéticos, sin resultados)

Antes de disponer de datos longitudinales reales, la mecánica del *pipeline* de comparación (generación de pares $(t-1, t)$, cálculo de ambas señales, clasificación incidente/control) se comprobó sobre datos sintéticos controlados (`scripts/synthetic_longitudinal_valida` que se conserva en el repositorio con un barrido de sensibilidad ejecutable con `-sweep`). De esa fase de diseño se retiene una única observación cualitativa, relevante para interpretar los resultados reales: **la deriva y la anticipación no miden lo mismo**. La deriva responde sobre todo al crecimiento de la lesión entre $t-1$ y t (grande casi por definición en los casos incidentes), mientras que la anticipación depende de que exista un precursor detectable en $t-1$; un *pipeline* puede tener deriva alta con anticipación nula. Los resultados cuantitativos de este trabajo son exclusivamente los obtenidos sobre datos reales (Capítulo 7).

5.8.3. Acceso a datos longitudinales reales

Durante la mayor parte del desarrollo de este TFG no hubo acceso a ningún dataset longitudinal público de mamografía con descarga directa. Se identificaron dos candidatos:

> *CSAW-CC* [11], cohorte real del Karolinska Institutet con 8723 pacientes y 24694 exploraciones (75.5 % con dos o más exploraciones), cuyas imágenes DICOM/PNG (∼2.5 TB) requieren solicitud formal de acceso; y *EMBED* [8], de Emory, con acceso controlado (*Controlled Access*) a través de un portal dedicado.

Durante la redacción de esta memoria se concedió acceso a EMBED. Sus tablas de metadatos clínicos (`empi_anon` como identificador de paciente, `acc_anon` como identificador de exploración, `study_date_anon` y la valoración BI-RADS `asses` de cada exploración) confirman que EMBED tiene, de hecho, una estructura longitudinal real y de tamaño considerable: sobre 23253 pacientes únicos y 72770 exploraciones, 14789 pacientes (63.6 %) tienen dos o más exploraciones. Filtrando por la definición de O7/O8 (exploración más antigua con `asses` Normal o Benigno, exploración posterior con `asses` Sospechoso/Altamente sugestivo/Malignidad confirmada), se identificaron **644 pacientes "incidentes"** candidatos y **7256 pacientes "control"** (todas sus exploraciones Normal o Benigno) — una cohorte de tamaño comparable o mayor que

la de CSAW-CC, ya accesible. El resultado sobre un primer piloto de esta cohorte se reporta en la Sección 7.5 del Capítulo 7, la primera evaluación de la hipótesis principal del TFG sobre datos reales en vez de sintéticos.

El trabajo reconocidamente comparable más cercano en la literatura sigue siendo LongiMam [16], que también explota pares longitudinales de mamografía pero con un modelo de *deep learning* end-to-end, no con descriptores topológicos.

Nota de ingeniería: coste de la distancia bottleneck sobre diagramas reales

Un hallazgo práctico no trivial al pasar de datos sintéticos a reales: los diagramas de persistencia de una mamografía real preprocesada (224×224) tienen del orden de 1000-2000 puntos en H_0 y H_1 (frente a decenas en las imágenes sintéticas de la Sección 5.8.2), y `persim.bottleneck` escala muy mal con el número de puntos: se midió $\sim$121 s para un solo par de diagramas reales sin recortar, lo que habría hecho inviable (horas) evaluar incluso un piloto pequeño. La solución — estándar en TDA — es quedarse con los `max_points` puntos de mayor persistencia de cada diagrama antes de calcular la distancia bottleneck (`synthetic_longitudinal_validation.py:_diagram_by_dim`), descartando el "ruido topológico" de baja persistencia: con `max_points` $= 100$ el cálculo baja a $\sim$0.18 s por par (más de 600$\times$ más rápido). Es una aproximación, no una igualdad garantizada — la distancia bottleneck no es en general invariante a quitar puntos, aunque el cambio es pequeño cuando hay una señal dominante de alta persistencia, verificado con un test de regresión (`tests/test_synthetic_longitudinal_validation.py`) —, pero imprescindible para que la evaluación sobre datos reales sea tratable.

Capítulo 6

Implementación

Este capítulo describe las herramientas, la organización del código y los detalles de implementación del *pipeline*.

6.1. Herramientas y librerías

El proyecto se desarrolla en **Python**. Las principales librerías son:

Tabla 6.1: Principales herramientas utilizadas.

Ámbito	**Herramienta**
Manipulación de datos	pandas, NumPy
Imagen	OpenCV, scikit-image, Pillow
TDA / homología persistente	giotto-tda (referencia) / GUDHI + persim (portable)
Aprendizaje automático	scikit-learn
Aprendizaje profundo	PyTorch / torchvision (DenseNet121)
Visualización	Matplotlib, seaborn
Entorno	Jupyter Notebook

6.2. Organización del código

El repositorio se estructura de la siguiente forma (véase el `README.md`):

```
mammoviz-tda/
  data/             # datos (no versionados)
  src/              # codigo fuente del pipeline
    data.py         # carga y particion por paciente
    preprocessing.py  # preprocesado de imagenes
    topology.py     # homologia persistente y vectorizacion
    models.py       # clasificadores y CNN
```

```
    evaluate.py     # metricas y visualizacion
  notebooks/        # experimentos reproducibles
  tfg/              # memoria en LaTeX
```

6.3. Extracción de descriptores topológicos

`giotto-tda` solo distribuye binarios precompilados hasta Python 3.12, por lo que `src/topology.py` detecta en tiempo de ejecución qué backend está disponible (`giotto-tda` o, si no, `gudhi + persim`, con soporte hasta Python 3.14) y expone la misma interfaz (`persistence_diagram`, `extract_features`) independientemente de cuál esté activo; `topology.backend()` permite consultarlo. El siguiente fragmento ilustra el cálculo de un diagrama de persistencia a partir de una imagen en escala de grises mediante una filtración por *sublevel sets*, utilizando `giotto-tda`.

```python
import numpy as np
from gtda.images import HeightFiltration, RadialFiltration
from gtda.homology import CubicalPersistence
from gtda.diagrams import PersistenceImage

def descriptor_topologico(imagen_gris):
    # imagen_gris: array 2D normalizado en [0, 1]
    x = imagen_gris[None, :, :]              # (1, H, W)
    cubical = CubicalPersistence(homology_dimensions=(0, 1))
    diagramas = cubical.fit_transform(x)     # diagramas de
       persistencia
    pi = PersistenceImage(n_bins=20)
    vector = pi.fit_transform(diagramas)     # imagen de persistencia
    return vector.reshape(len(x), -1)
```

Listing 6.1: Ejemplo de extracción de un diagrama de persistencia.

6.4. Reproducibilidad

Para garantizar la reproducibilidad de los experimentos:

- Se fija una semilla aleatoria común.
- Se documentan las versiones de las librerías (`requirements.txt`).
- La partición de datos por paciente se guarda en disco para reutilizarla.
- Cada experimento se ejecuta desde un *notebook* autocontenido.

6.5. Visualización

Se desarrollan visualizaciones específicas para el análisis topológico: diagramas de persistencia y códigos de barras superpuestos sobre la imagen, mapas de calor de las imágenes de persistencia, y comparación de las regiones más informativas frente a las activaciones de la CNN (p. ej. Grad-CAM).

Capítulo 7

Experimentos y resultados

Este capítulo presenta el diseño experimental del trabajo y los resultados obtenidos, **todos sobre datos reales**: la clasificación benigno/maligno sobre el piloto de CBIS-DDSM (70 pacientes descargados con `scripts/download_cbis_ddsm.py`, Sección 7.3), el estudio de interpretabilidad (Sección 7.4) y la evaluación de la hipótesis longitudinal principal (O7–O8) sobre el piloto real de EMBED (Sección 7.5). Durante el desarrollo se usaron datos sintéticos únicamente como comprobación de ingeniería de que las etapas del *pipeline* encajaban entre sí (`notebooks/01_pipeline_demo.ipynb`, `scripts/synthetic_longitudinal_validation.py`, que se conservan en el repositorio); ningún resultado de este capítulo procede de datos sintéticos.

7.1. Diseño experimental

Se definen los siguientes experimentos, alineados con los objetivos O4 y O5 (Capítulo 2):

E1. Clasificación con descriptores topológicos + clasificador clásico (SVM, *random forest*).

E2. Clasificación con CNN (*transfer learning*, DenseNet121).

E3. Fusión de características topológicas y *embeddings* de CNN.

E4. Análisis de robustez frente a ruido y a variaciones de adquisición.

7.2. Configuración

En todos los experimentos se fija una semilla aleatoria común (`seed = 42`) para garantizar la reproducibilidad. La partición de datos se realiza **por paciente** (Capítulo 5),

con proporciones 70 % / 15 % / 15 % para entrenamiento, validación y test respectivamente, estratificadas por la etiqueta de patología. Los hiperparámetros de los clasificadores clásicos (`SVC(kernel='rbf')`, `RandomForestClassifier(n_estimators=300)`) se fijan a valores por defecto razonables en esta fase preliminar; en la fase de experimentación con datos reales se ajustarán mediante validación cruzada sobre el conjunto de validación.

7.2.1. Backend de homología persistente

La implementación de referencia de este trabajo usa `giotto-tda` (Sección 6), pero esta librería solo distribuye binarios precompilados hasta Python 3.12. Para no depender de una versión concreta de Python, `src/topology.py` elige automáticamente, en este orden, el primer backend disponible en el entorno de ejecución:

1. **giotto-tda** — implementación de referencia.
2. **gudhi + persim** — backend alternativo con soporte binario hasta Python 3.14; se usa `gudhi.CubicalComplex` para el diagrama de persistencia y una imagen de persistencia calculada mediante un núcleo gaussiano ponderado por persistencia sobre la rejilla fija $[0, 1] \times [0, 1]$ (las imágenes ya están normalizadas por `preprocessing.to_grayscale_float`).
3. **Curva de Betti-0** (`scipy`) — respaldo mínimo si ningún backend anterior está instalado; cuenta cómo evoluciona el número de componentes conexas al barrer el umbral de intensidad.

Los resultados de este capítulo se obtuvieron con el backend **gudhi**, por ser el que está instalado en el entorno de desarrollo (Python 3.14, donde `giotto-tda` no tiene binarios disponibles). Ambos backends calculan la misma homología persistente cúbica sobre H0 y H1; la diferencia está en la vectorización final (imagen de persistencia), por lo que los resultados no deberían diferir sustancialmente de los que produciría `giotto-tda`.

7.3. Resultados sobre el piloto real de CBIS-DDSM

El repositorio dispone ya de un **piloto real descargado**: 70 pacientes de CBIS-DDSM (casos de tipo masa), con sus mamografías completas y máscaras de ROI en `data/images/`, descargados de forma incremental y balanceada benigno/maligno con `scripts/download_cbis_ddsm.py` directamente contra la API REST de TCIA (ampliado desde los 30 pacientes iniciales, issue #82). La partición por paciente (Sección 5) deja, sobre este piloto, 101 casos usables de entrenamiento y 21 de test (el resto de filas de los CSV originales corresponden a pacientes todavía no descargados y se omiten automáticamente).

Tabla 7.1: Resultados reales sobre el piloto de CBIS-DDSM (70 pacientes, `scripts/run_pipeline.py` y `scripts/fuse_and_evaluate.py`, `n_bins=4`, Random Forest por defecto). El AUC por validación cruzada (5-fold sobre train) es la columna fiable; el test de solo 21 casos sigue siendo ruidoso (ver discusión debajo de la tabla).

Modelo	**AUC (test, $n = 21$)**	**AUC (CV, train)**	**Sensib. (test)**
TDA (Persistence Image)	0.490	$0{,}658 \pm 0{,}134$	0.429
CNN (DenseNet121, embeddings)	0.668	$0{,}798 \pm 0{,}122$	0.643
Fusión TDA + CNN	0.714	$0{,}796 \pm 0{,}117$	0.714

7.3.1. El AUC baja al ampliar el piloto (y por qué es una buena noticia)

Con el piloto de 30 pacientes (Sección 7.3 en una versión anterior de este capítulo), el CV-AUC de TDA llegaba a $0{,}850 \pm 0{,}143$; con 70 pacientes baja a $0{,}658 \pm 0{,}134$. A primera vista parece un empeoramiento, pero es justo lo contrario: con solo 40 casos de entrenamiento, una sola partición de validación cruzada podía caer, por puro azar, en el extremo favorable de la distribución de aciertos — el mismo fenómeno, en la dirección opuesta, que llevó a un AUC de test de 0,000 en aquel piloto cuando el *random forest* invirtió literalmente las 8 predicciones de un test diminuto. El número de 0,658 sobre 101 casos de entrenamiento es **menos vistoso pero más creíble**: la desviación típica también baja (de $\pm 0{,}143$ a $\pm 0{,}134$), señal de que la estimación se está estabilizando al crecer la muestra, tal como anticipaba la Sección 7.3.2 de la versión anterior de este capítulo. Es exactamente el fenómeno ya anticipado al corregir el sobreajuste del clasificador (issue #77): el AUC de un único *split* pequeño — y, por extensión, el de una validación cruzada sobre muy pocos casos — es **demasiado ruidoso para tomarse al pie de la letra**, y solo ampliar el piloto permite distinguir una estimación real de un golpe de suerte.

Con el piloto ampliado, los tres modelos superan el azar (AUC $\geq 0{,}66$), con la CNN y la fusión claramente por delante de TDA en solitario (a diferencia del piloto de 30 pacientes, donde los tres estaban más igualados) y con un orden más estable: la fusión iguala o mejora ligeramente a la CNN sola en la mayoría de las configuraciones probadas (Sección 7.3.2). Seguir ampliando el piloto (issue #82, O7 del Capítulo 2) sigue siendo el camino natural para reducir más la incertidumbre.

7.3.2. Refinamiento: ajuste de hiperparámetros por vía (issue #77)

La Tabla 7.1 usa los valores por defecto de `src/models.py` (*random forest* sin ajustar) para las tres vías por igual. `scripts/run_pipeline.py -tune` y `scripts/fuse_and_evaluate.py -tune` permiten, en cambio, ajustar por `GridSearchCV` el clasificador (SVM o *random forest*, y sus hiperparámetros) **por separado para cada vía**, ya que no hay razón para esperar que la misma configuración sea óptima para un vector topológico de 32 características, un *embedding* de CNN de 1024, o su fusión de 1056.

Tabla 7.2: AUC por validación cruzada (5-fold, train, piloto de 70 pacientes) con *random forest* por defecto, *random forest* ajustada y SVM ajustada por `GridSearchCV` ($n_bins = 4$, $C \in \{0{,}01, \ldots, 100\}$, kernel lineal/RBF). "Mejor encontrado" es el máximo de las tres.

Vía	RF por defecto	RF ajustada	SVM ajustada	Mejor encontrado
TDA sola	$0{,}658 \pm 0{,}134$	$0{,}658 \pm 0{,}134$	$0{,}653 \pm 0{,}201$	$\mathbf{0{,}658 \pm 0{,}134}$ (RF)
CNN sola	$0{,}798 \pm 0{,}122$	$0{,}798 \pm 0{,}127$	$\mathbf{0{,}827 \pm 0{,}110}$	$\mathbf{0{,}827 \pm 0{,}110}$ (SVM)
Fusión TDA + CNN	$0{,}796 \pm 0{,}117$	$0{,}813 \pm 0{,}104$	$\mathbf{0{,}819 \pm 0{,}113}$	$\mathbf{0{,}819 \pm 0{,}113}$ (SVM)

A diferencia del piloto de 30 pacientes (donde el ajuste de hiperparámetros producía un resultado llamativo de 0,967 para la fusión, muy por encima de cualquier otra configuración), con 70 pacientes el panorama es más estable y menos espectacular: **ajustar hiperparámetros aporta una mejora modesta y consistente** (entre 0 y 0,03 puntos de AUC según la vía), no el salto grande que sugería el piloto pequeño — una confirmación directa de la cautela que ya se pedía en la versión anterior de esta sección sobre el *look-elsewhere effect* (issue #77). La SVM ajustada es ahora la mejor opción tanto para la CNN sola como para la fusión, mientras que para TDA el *random forest* por defecto ya es difícil de mejorar. La fusión y la CNN sola quedan prácticamente empatadas (0,819 vs. 0,827, diferencia muy por debajo de sus desviaciones típicas): con el tamaño de piloto actual **no se puede afirmar que la fusión aporte una mejora clara** sobre la CNN sola, a diferencia de lo que sugería — de forma demasiado optimista — el piloto de 30 pacientes. Confirmar si la fusión aporta algo real requiere seguir ampliando el piloto (issue #82).

7.3.3. Sanity check visual: masa espiculada benigna vs. maligna

Como comprobación cualitativa independiente de las métricas anteriores (issue #56), la Figura 7.1 compara dos casos reales de CBIS-DDSM con el mismo tipo de

margen de masa (`SPICULATED` en el campo `mass_margins` del CSV de descripción): uno benigno (`P_00692`) y uno maligno (`P_00734`). Ambos tienen una morfología visualmente similar — precisamente el tipo de caso donde interesa que el descriptor topológico aporte algo más allá de lo evidente a simple vista — y sus diagramas de persistencia difieren tanto en el número de puntos de H_1 (ciclos) como en su persistencia (distancia a la diagonal), consistente con la intuición de que una masa espiculada maligna real genera una textura de borde más irregular que una espiculación benigna. Esta observación es cualitativa y sobre un único par de casos; no sustituye a la validación cuantitativa de la Tabla 7.1, pero sirve de comprobación de sentido común de que el descriptor no es ciego a la diferencia clínica relevante.

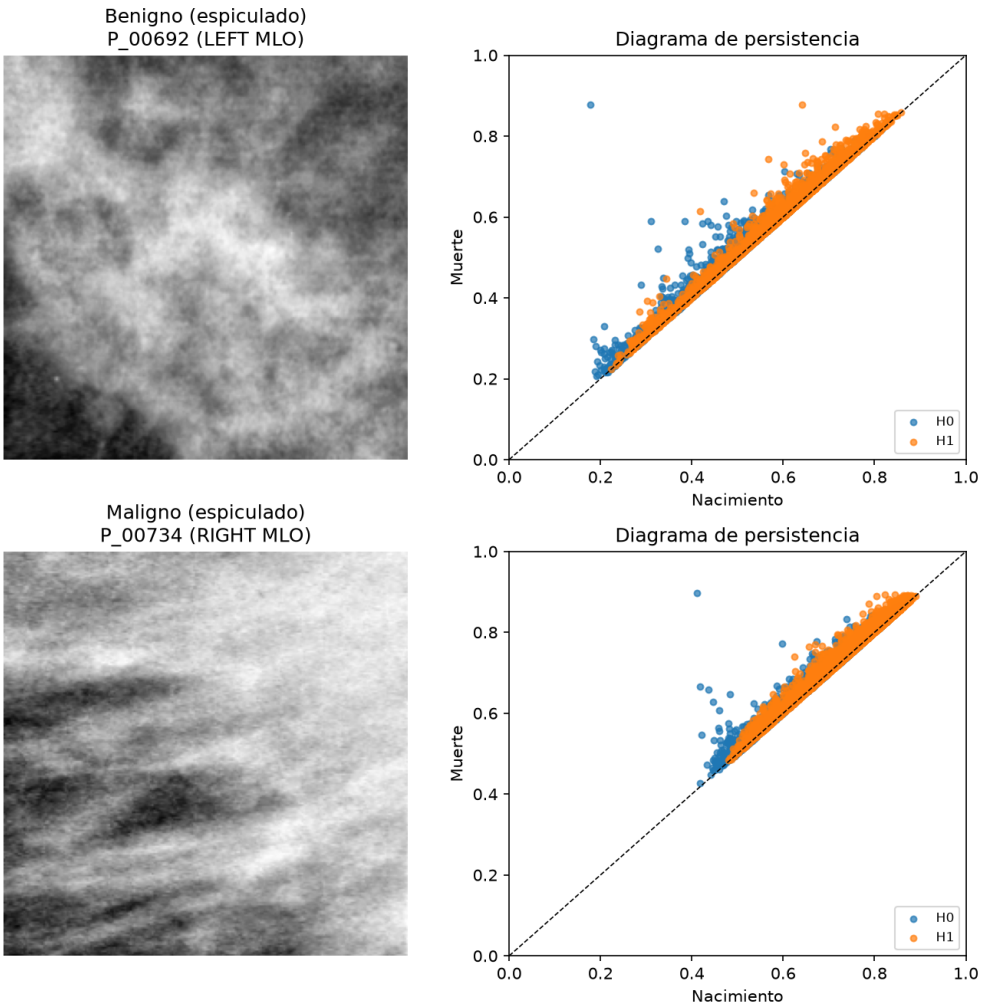


Figura 7.1: Caso real benigno (`P_00692`, arriba) y maligno (`P_00734`, abajo) con margen de masa espiculado, con su diagrama de persistencia H0/H1 (backend `gudhi`).

7.3.4. Estado de los datos

El piloto real de CBIS-DDSM cubre 70 pacientes de tipo masa, y el piloto longitudinal real de EMBED cubre 99 pacientes (Sección 7.5). Ambas descargas están resueltas

y automatizadas; lo que queda es **ampliarlas**:

- Relanzar `scripts/download_cbis_ddsm.py -add N N` para crecer el piloto de clasificación y reducir la varianza de la Tabla 7.1 (issue #82), e incorporar los casos de tipo calcificación (`Calc-*`), de momento excluidos.
- Relanzar `scripts/download_embed_longitudinal.py` con más pacientes para el piloto longitudinal (issue #95): la cohorte completa de EMBED tiene 644 incidentes y 7256 control candidatos, de los que solo se han usado 99.

7.4. Interpretabilidad: TDA vs Grad-CAM vs SHAP vs LIME

Como línea secundaria del trabajo (Sección 5.7), se ha ejecutado `scripts/explainability_benchma` sobre los **122 casos usables** del piloto real ampliado (entrenamiento y test juntos, estudio descriptivo, no predictivo), calculando las 4 regiones binarias (Grad-CAM, región topológica dominante, SHAP, LIME) y su acuerdo por pares, con el protocolo estadístico de la Sección 5.7.5.

Tabla 7.3: Acuerdo por pares entre los 4 métodos de interpretabilidad (IoU media, intervalo de confianza 95 % por *bootstrap*, $n = 122$ casos reales).

Par de métodos	**IoU**	**IC 95 %**
Grad-CAM vs. TDA	0,114	[0,096, 0,133]
Grad-CAM vs. SHAP	0,125	[0,114, 0,135]
Grad-CAM vs. LIME	0,137	[0,121, 0,153]
TDA vs. SHAP	0,070	[0,058, 0,083]
TDA vs. LIME	0,091	[0,077, 0,107]
SHAP vs. LIME	0,117	[0,110, 0,124]

7.4.1. El hallazgo principal: los cuatro métodos apenas coinciden entre sí

El acuerdo por pares es **bajo en las seis combinaciones** (IoU entre 0,07 y 0,14), y con un piloto de 122 casos los intervalos de confianza son ya lo bastante estrechos para afirmar con razonable confianza que ningún par destaca claramente sobre los demás — ni siquiera entre Grad-CAM, SHAP y LIME, que comparten la misma CNN de referencia como base. El par TDA/SHAP es el de menor acuerdo (0,070); el de mayor, Grad-CAM/LIME (0,137), pero sus intervalos de confianza no se solapan del todo con los demás por muy poco margen, no por una diferencia sustantiva.

Para confirmarlo formalmente (issue #79), se aplicó un **test pareado de Wilcoxon** comparando, caso a caso, el acuerdo TDA/Grad-CAM contra el acuerdo SHAP/LIME (dos métodos que comparten la CNN, usado como referencia de .ªcuerdo típico entre métodos basados en píxeles"): estadístico = 3510, $p = 0{,}537$, diferencia mediana $= -0{,}025$ — **no significativo**. Es decir, no hay evidencia de que el hecho de que uno de los métodos sea topológico en vez de basado en píxeles cambie el nivel de acuerdo típico: la región topológica dominante se integra en la misma distribución de (des)acuerdo que los tres métodos de *deep learning* entre sí.

Este resultado es consistente con una observación ya reportada en la literatura de *interpretable ML* fuera del dominio médico: distintos métodos de explicabilidad, aplicados al mismo modelo y la misma entrada, con frecuencia señalan regiones distintas, porque cada uno optimiza una noción distinta de ïmportancia"(gradiente local para Grad-CAM, valores de Shapley para SHAP, un modelo local interpretable sobre superpíxeles para LIME).

La Figura 7.2 ilustra esto con el caso de mayor acuerdo TDA/Grad-CAM del piloto (`P_00592`, arriba: ambos métodos señalan el mismo borde de la lesión) frente al de menor acuerdo (`P_00409`, abajo: Grad-CAM señala dos esquinas de la imagen y la región topológica dominante no marca ninguna región). SHAP produce en ambos casos un patrón disperso tipo "sal y pimienta"sobre buena parte de la imagen, poco localizado; LIME selecciona unos pocos superpíxeles, frecuentemente cerca de los bordes del recorte.

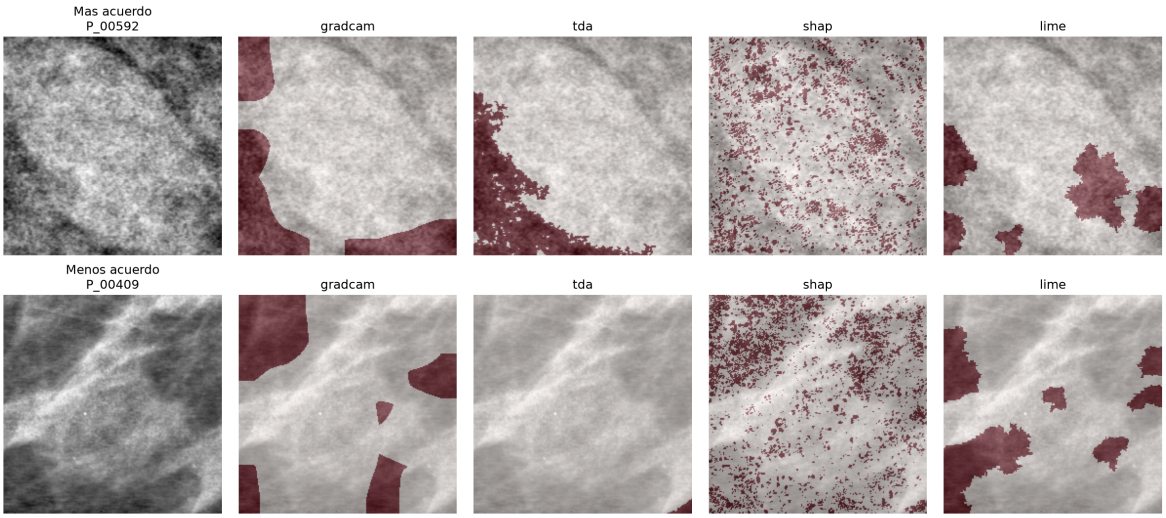


Figura 7.2: Caso de mayor acuerdo TDA/Grad-CAM del piloto (`P_00592`, arriba) frente al de menor acuerdo (`P_00409`, abajo), con las 4 regiones superpuestas en rojo sobre la imagen preprocesada.

7.4.2. IoU contra la máscara de ROI real

Como se advirtió metodológicamente en la Sección 5.7.3, este número está sesgado al alza por el recorte del *pipeline* y es menos informativo que la Tabla 7.3; se incluye por completitud (issue #61):

Tabla 7.4: IoU de cada método contra la máscara de ROI real (IC 95 % *bootstrap*, $n = 119$ casos con máscara disponible).

Método	**IoU vs. ROI**	**IC 95 %**
Grad-CAM	0,167	[0,148, 0,187]
TDA	0,130	[0,103, 0,158]
SHAP	0,222	[0,211, 0,232]
LIME	0,163	[0,148, 0,178]

SHAP sigue obteniendo el IoU más alto contra la ROI (con el intervalo más estrecho de los cuatro: [0,211, 0,232]), pero su patrón disperso (Figura 7.2) sugiere que esto puede deberse simplemente a que marca muchos píxeles repartidos por una fracción grande de la imagen (y la ROI, tras el recorte, también cubre una fracción grande de la imagen), no a una localización precisa de la lesión. TDA sigue siendo el método con el intervalo más ancho ([0,103, 0,158]), reflejando que a veces la región dominante cae dentro de la ROI y a veces fuera, consistente con el bajo acuerdo inter-método ya comentado.

7.4.3. Desglose por tipo de margen de la masa y por densidad mamaria

El acuerdo TDA/Grad-CAM desglosado por `mass_margins` (con más categorías representadas que en el piloto de 30 pacientes) oscila entre 0,028 (`OBSCURED-ILL_DEFINED`, $n = 3$) y 0,193 (`CIRCUMSCRIBED-OBSCURED`, $n = 3$), pero las categorías con tamaño de muestra razonable — `CIRCUMSCRIBED` ($n = 38$, $0{,}109 \pm 0{,}093$), `ILL_DEFINED` ($n = 26$, $0{,}098 \pm 0{,}096$) y `SPICULATED` ($n = 21$, $0{,}085 \pm 0{,}091$) — están todas dentro del mismo rango bajo, sin una categoría que destaque claramente.

El desglose por `breast_density` (issue #90; BI-RADS A–D, codificado 1–4) tampoco muestra una tendencia clara: $0{,}121 \pm 0{,}103$ (densidad 1, $n = 40$), $0{,}111 \pm 0{,}097$ (densidad 2, $n = 50$), $0{,}123 \pm 0{,}122$ (densidad 3, $n = 22$) y $0{,}084 \pm 0{,}096$ (densidad 4, $n = 10$). La densidad más alta (tejido más denso, donde la lectura radiológica es clínicamente más difícil) tiene el acuerdo más bajo, pero con solo 10 casos en esa categoría no se puede afirmar que sea una tendencia real y no ruido de muestra.

7.4.4. Coste computacional

Tabla 7.5: Coste computacional por método (segundos/caso, $n = 122$).

Método	**Tiempo (s/caso)**
Grad-CAM	$0{,}078 \pm 0{,}022$
TDA (región dominante)	$0{,}065 \pm 0{,}016$
LIME	$1{,}866 \pm 0{,}162$
SHAP	$20{,}005 \pm 1{,}400$

Este es el resultado más favorable para el TDA de todo el estudio, ahora confirmado con un piloto más grande: la región topológica dominante es tan rápida de calcular como Grad-CAM (0,065 s/caso vs. 0,078 s/caso) **sin necesitar entrenar ni ejecutar ninguna CNN**, y más de dos órdenes de magnitud más rápida que SHAP (20,0 s/caso, $> 300\times$). Es, con diferencia, el argumento más sólido a favor de la homología persistente como çapa de interpretabilidad nativa– no porque coincida más con los otros métodos (no lo hace, Tabla 7.3, confirmado estadísticamente con el test pareado), sino porque ofrece una localización topológicamente fundamentada prácticamente gratis en comparación con SHAP, y sin la dependencia de una CNN ya entrenada que tienen los otros tres métodos.

7.5. Evaluación real de la hipótesis longitudinal (EMBED, O8)

Como se explica en la Sección 5.8.3, durante la redacción de esta memoria se concedió acceso a EMBED. Se construyó un primer piloto longitudinal real con `scripts/download_embed_l` para cada paciente seleccionado se descargan las dos exploraciones (t-1, t) de la misma vista (lateralidad + proyección, para que la comparación sea sobre la misma región anatómica), filtrando a imágenes de tipo `2D` (mamografía digital real, no el *C-view* sintetizado de tomosíntesis). El piloto tiene **99 pacientes**: 49 incidentes (primera exploración Normal/Benigna, exploración posterior Sospechosa/Maligna; un candidato más se descartó automáticamente por no tener ninguna vista común entre sus dos exploraciones) y 50 control (todas sus exploraciones Normal/Benigna), seleccionados aleatoriamente (semilla fija) de los 644 y 7256 candidatos respectivamente identificados en la cohorte completa. Una primera iteración con 40 pacientes dio el mismo patrón cualitativo con el doble de varianza; se reportan los números del piloto de 99.

Tabla 7.6: AUC por validación cruzada (5-fold) de cada señal longitudinal sobre el piloto REAL de EMBED (`scripts/embed_longitudinal_evaluation.py`, $n = 99$ pacientes).

Señal	**AUC (CV, media ± desv.)**
Anticipación (solo D_{t-1})	$0{,}550 \pm 0{,}105$
Deriva ($d(D_{t-1}, D_t)$)	$0{,}805 \pm 0{,}060$
Combinada	$0{,}762 \pm 0{,}094$

Aviso metodológico, antes de interpretar estos números. Con 99 pacientes este sigue siendo un **piloto**, no un estudio definitivo — el mismo aviso repetido en todo este capítulo sobre pilotos pequeños aplica también aquí, aunque con menos fuerza que en la primera iteración de 40.

El patrón de resultados es claro: la señal de **deriva** ($0{,}805 \pm 0{,}060$) supera al azar de forma robusta — el cambio topológico entre la exploración previa y la del diagnóstico es real y medible con homología persistente —, mientras que la señal de **anticipación pura** ($0{,}550 \pm 0{,}105$) sigue estadísticamente cerca del azar incluso tras multiplicar por 2.5 el tamaño del piloto. Tiene sentido mecánico: la deriva mide sobre todo çuánto cambió la topología entre t-1 y t"(que casi por definición es grande en los casos incidentes, donde en t ya hay una lesión diagnosticada), mientras que la anticipación mide si ya había señal **antes** del diagnóstico — la pregunta clínicamente valiosa, y la más difícil. Dos lecturas posibles, no excluyentes entre sí:

- Los precursores topológicos reales son, en efecto, demasiado sutiles para el descriptor actual (imagen de persistencia de la vista completa a 224×224): haría falta un descriptor más sensible, mayor resolución o localización de la región sospechosa.
- El AUC de anticipación de $0{,}550 \pm 0{,}105$ aún deja margen a que exista una señal débil ($\sim$0.55) real: distinguir "señal débil"de "sin señalrequiere todavía más pacientes.

Eso sí, la tendencia entre las dos iteraciones del piloto (de $0{,}525 \pm 0{,}219$ con 40 pacientes a $0{,}550 \pm 0{,}105$ con 99) es la de un AUC que se estabiliza en un valor bajo con varianza decreciente, no la de una señal fuerte emergiendo al crecer la muestra. Ampliar el piloto (hay candidatos de sobra: 644 incidentes y 7256 control en la cohorte completa de EMBED) sigue siendo el siguiente paso natural (Capítulo 8).

7.6. Discusión

Las observaciones principales de este capítulo, todas sobre datos reales:

- **El *pipeline* completo funciona de extremo a extremo sobre datos reales**: partición por paciente, preprocesado, extracción de imágenes de persistencia H0+H1 y evaluación con métricas clínicas, tanto sobre CBIS-DDSM (clasificación) como sobre EMBED (longitudinal).

- **El tamaño de muestra manda**: la lección metodológica más repetida del capítulo. El CV-AUC de TDA pasó de $0{,}850 \pm 0{,}143$ (30 pacientes) a $0{,}658 \pm 0{,}134$ (70); un test de $n = 8$ llegó a dar AUC 0,000 por puro azar; y el "mejor resultado"de la fusión con el piloto pequeño (0,967) se desinfló a 0,819 al ampliar. Ningún número de un piloto pequeño debe tomarse al pie de la letra sin su intervalo de confianza.

- **Clasificación aislada (E1–E3)**: la CNN sola y la fusión quedan prácticamente empatadas (AUC por CV 0,827 y 0,819 tras ajustar hiperparámetros por vía), ambas claramente por delante de TDA en solitario (0,658). Con el piloto actual no se puede afirmar que la fusión aporte una mejora real sobre la CNN sola (issue #82). El resultado de TDA es además robusto a la elección de la función de filtración (intensidad vs. transformada de distancia: mismo CV-AUC medio, 0,658, issue #77).

- **Interpretabilidad**: los cuatro métodos (Grad-CAM, región topológica dominante, SHAP, LIME) apenas coinciden entre sí (IoU 0,07–0,14, $n = 122$), y un test pareado confirma que TDA no se comporta distinto de los métodos basados en píxeles en ese aspecto; la ventaja real de TDA es el coste (300× más rápida que SHAP, sin necesitar CNN).

- **Hipótesis longitudinal (O8), el resultado central**: sobre 99 pacientes reales de EMBED, la deriva topológica entre exploraciones es una señal robusta ($0{,}805 \pm 0{,}060$), pero la anticipación pura — la pregunta clínicamente valiosa — se mantiene cerca del azar ($0{,}550 \pm 0{,}105$), con una tendencia entre iteraciones del piloto que apunta a señal débil o ausente con el descriptor actual, más que a una señal fuerte oculta por el ruido de muestra.

Las limitaciones de estos resultados (tamaño de los pilotos frente a las cohortes completas disponibles, una sola vista por paciente en el piloto longitudinal, ausencia de validación clínica) se retoman en el Capítulo 8 junto con las limitaciones generales del trabajo.

Capítulo 8

Conclusiones y trabajo futuro

8.1. Conclusiones

Este Trabajo de Fin de Grado parte de la clasificación benigno/maligno sobre una mamografía aislada mediante Análisis Topológico de Datos (TDA), pero su objetivo principal es más ambicioso: estudiar si esos mismos descriptores topológicos permiten **detección anticipada**, comparando la exploración previa (normal) y la exploración donde se diagnostica el cáncer en la misma paciente (Capítulo 2, objetivos O7–O8). Este pivote — documentado en detalle en el registro de decisión del repositorio — sustituye al planteamiento inicial centrado en comparar la interpretabilidad del TDA frente a Grad-CAM/SHAP/LIME sobre una imagen aislada, que se mantiene como línea secundaria si el tiempo lo permite, pero ya no como contribución central.

El resultado principal es un ***pipeline* completo, reproducible y ejecutado íntegramente sobre datos reales** — CBIS-DDSM para la clasificación aislada y EMBED para la hipótesis longitudinal — desde la carga de metadatos hasta la evaluación clínica, que corrige el problema de fuga de datos detectado en el material de partida (partición estricta por paciente). En relación con los objetivos específicos:

- Se ha revisado el estado del arte en análisis automático de mamografías, aplicaciones del TDA a imagen médica y predicción de riesgo/análisis longitudinal (O1).
- Se ha construido un *pipeline* reproducible de preparación de datos (`src/data.py`) cuyo aporte metodológico central es la **partición por paciente**, que corrige la fuga de datos observada en el `Demo_Notebook.ipynb` original (exactitud del 100 % desde la primera época); se ha descargado y usado un piloto real de 70 pacientes de CBIS-DDSM (O2).
- Se ha implementado y ejecutado sobre datos reales la extracción de descriptores topológicos mediante homología persistente cúbica (`src/topology.py`: diagra-

mas de persistencia, imágenes de persistencia H0+H1), con dos backends intercambiables (`giotto-tda` y `gudhi`, este último operativo en Python 3.14) (O3), y se han entrenado y evaluado clasificadores clásicos (SVM, *random forest*) sobre estos descriptores sobre el piloto real, con AUC por validación cruzada $\approx 0{,}66$ (Sección 7.3) (O4).

- Se ha migrado la CNN de referencia a PyTorch (DenseNet121 con *transfer learning*), se ha entrenado de forma determinista sobre el piloto real, y se ha implementado y evaluado la fusión de características topológicas y *embeddings* de la CNN, con AUC por CV $\approx 0{,}83$ (CNN) y $\approx 0{,}82$ (fusión) tras ajustar hiperparámetros por vía sobre el piloto actual, sin que se pueda todavía afirmar que la fusión mejore a la CNN sola (O5).

- Se han desarrollado utilidades de visualización (matriz de confusión, diagrama de persistencia, comparación visual benigno vs. maligno espiculado con datos reales) en `src/evaluate.py` y en el notebook interactivo (O6).

- Se ha diseñado la metodología de comparación longitudinal (señales de *anticipación* y *deriva* topológica entre exploraciones sucesivas, Sección 5.8 del Capítulo 5), con la distinción metodológica clave de que ambas señales no miden lo mismo: la deriva detecta "algo cambió", la anticipación detecta "ya había señal antes" (O7).

- Se concedió acceso a EMBED y se ha evaluado la hipótesis de detección anticipada sobre un **piloto real de 99 pacientes** (49 incidentes, 50 control): AUC por CV de $0{,}805 \pm 0{,}060$ (deriva, señal robusta) y $0{,}550 \pm 0{,}105$ (anticipación pura, cerca del azar), ver Sección 7.5. Queda pendiente ampliar el piloto, para lo que ya hay acceso y candidatos de sobra (644 incidentes, 7256 control) (O8).

8.2. Grado de cumplimiento de los objetivos

Tabla 8.1: Grado de cumplimiento de los objetivos específicos.

Obj.	**Estado**	**Observaciones**
O1	Cumplido	Revisión bibliográfica completa, incluida la línea longitudinal/predicción de riesgo (Cap. 3).
O2	Cumplido	*Pipeline* de datos y partición por paciente implementados y verificados sobre un piloto real de 70 pacientes; dataset longitudinal (CSAW-CC/EMBED) bajo solicitud de acceso (O8).
O3	Cumplido	Extracción de imágenes de persistencia H0+H1 implementada y ejecutada sobre el piloto real con dos backends (gudhi, giotto-tda).
O4	Cumplido	Clasificadores entrenados y evaluados sobre el piloto real (AUC por CV $\approx$ 0,66, estimación más fiable al ampliar el piloto); tamaño de muestra todavía pequeño (issue #82).
O5	Cumplido	CNN (PyTorch/DenseNet121) y fusión entrenadas y comparadas sobre el piloto real, con ajuste de hiperparámetros por vía (issue #77).
O6	Cumplido	Visualizaciones implementadas y aplicadas a casos reales; comparación sistemática con Grad-CAM, SHAP y LIME completada como línea secundaria (Sección 7.4): acuerdo bajo entre los 4 métodos, TDA tan rápida como Grad-CAM y $>$ 300$\times$ más rápida que SHAP.
O7	Cumplido	Metodología de comparación longitudinal diseñada y aplicada sobre datos reales (Sección 5.8, Sección 7.5).
O8	Cumplido (preliminar)	Acceso a EMBED concedido; evaluación sobre un piloto real de 99 pacientes completada (AUC deriva 0,805$\pm$0,060, anticipación 0,550$\pm$0,105, Sección 7.5). Es el objetivo más importante del TFG y el resultado es ya real, pero preliminar: falta ampliar el piloto para que sea concluyente.

La principal desviación respecto a la planificación inicial ya no es logística ni de acceso (la descarga de CBIS-DDSM está resuelta y automatizada, y el acceso a EMBED se concedió durante la redacción de esta memoria), sino de **tamaño de piloto**: el

primer resultado real sobre la hipótesis central del trabajo (O8) ya existe, pero sobre solo 99 pacientes de los más de 7900 candidatos disponibles en EMBED, así que no es todavía una validación concluyente.

8.3. Limitaciones

Se identifican las siguientes limitaciones del trabajo en su estado actual:

- **El piloto real sobre la hipótesis principal es todavía pequeño.** 99 pacientes (Sección 7.5) dan ya una señal de deriva robusta ($0{,}805 \pm 0{,}060$), pero no bastan para cerrar la pregunta central: el AUC de anticipación ($0{,}550 \pm 0{,}105$) aún no permite distinguir con confianza entre "señal débil real" y "sin señal". Además, el piloto usa una sola vista (lateralidad + proyección) por paciente, sin registro espacial entre exploraciones de distinta fecha.

- **Tamaño del piloto real.** 70 pacientes (101 casos de entrenamiento, 21 de test tras la partición por paciente) ya permite estimaciones más estables que el piloto inicial de 30 pacientes — el CV-AUC de TDA bajó de $0{,}850 \pm 0{,}143$ a $0{,}658 \pm 0{,}134$ al ampliar el piloto, una corrección a la baja que es en sí misma evidencia de que el número anterior era optimista por el tamaño de muestra (Sección 7.3.1) — pero sigue siendo pequeño para un estudio concluyente: con 30 pacientes, el AUC de un único *split* de test con $n = 8$ llegó a ser, en una ejecución, peor que el azar por pura casualidad, lo que ilustra por qué se reporta el AUC por validación cruzada como métrica principal y no el de un solo *split*.

- **Sesgos del conjunto de datos.** CBIS-DDSM, aunque curado, procede de un número limitado de centros y equipos de adquisición, lo que puede limitar la generalización a otras poblaciones o tecnologías de imagen; además, el piloto actual solo incluye casos de tipo masa, no de calcificación.

- **Alcance de la validación clínica.** Ninguna de las métricas obtenidas constituye una validación clínica: falta contraste con radiólogos y con conjuntos de datos externos antes de extraer conclusiones sobre utilidad diagnóstica real.

8.4. Trabajo futuro

A corto plazo, para consolidar el objetivo O8 (ya con un primer resultado real, pero preliminar):

- Ampliar el piloto real de EMBED más allá de 40 pacientes (hay 644 incidentes y 7256 control disponibles en la cohorte completa, issue #92) para reducir la

varianza del AUC de la Tabla 7.6 y poder distinguir si la señal de anticipación mejora con más datos o se mantiene cerca del azar.

- Solicitar también acceso a CSAW-CC como fuente adicional/cruzada, ya que no hay coste en tenerlo como respaldo (ver `docs/acceso_datasets_longitudinales.pdf`).
- Seguir ampliando el piloto real de CBIS-DDSM más allá de 70 pacientes (issue #82) para reducir aún más la varianza de las métricas de la Tabla 7.1 e incorporar los casos de calcificación.

Como líneas de trabajo futuro de más largo alcance se proponen:

- Comparar la señal de anticipación topológica con modelos de predicción de riesgo basados en *deep learning* ya publicados sobre datos longitudinales reales (p. ej. LongiMam [16], STA-Risk [21]).
- Completar las dos tareas que quedaron abiertas de la línea secundaria de interpretabilidad (Sección 7.4): una cota de estabilidad teórica de la métrica de acuerdo frente a perturbaciones del ROI (issue #78) y una validación cualitativa con un segundo anotador humano sobre los casos más discordantes (issue #80), ya que no hay acceso garantizado a un radiólogo.
- Extender el estudio a otras filtraciones y descriptores topológicos (*multiparameter persistence*) para la señal de deriva entre exploraciones.
- Explorar la **consistencia topológica entre proyecciones CC/MLO** de la misma exploración (distancia de Wasserstein entre sus diagramas de persistencia) como señal de calidad/ambigüedad complementaria a la señal longitudinal: dos vistas de la misma lesión deberían ser topológicamente similares, y una discrepancia grande podría señalar casos donde el descriptor topológico es menos fiable.
- Validar el enfoque longitudinal en otros conjuntos de datos (además de CSAW-CC/EMBED) y, si procede, con radiólogos, para medir la utilidad clínica real de una ventana de detección anticipada.

Bibliografía

[1] A. Ali Eli y A. Ali, "Deep Learning Applications in Medical Image Analysis: Advancements, Challenges, and Future Directions", *arXiv preprint arXiv:2410.14131*, 2024. arXiv: 2410.14131 [eess.IV].

[2] J. Bai, A. Jin, M. Adams, C. Yang y S. Nabavi, "Unsupervised feature correlation model to predict breast abnormal variation maps in longitudinal mammograms", *arXiv preprint arXiv:2312.16772*, 2023. arXiv: 2312.16772 [eess.IV].

[3] G. Carlsson, "Topology and data", *Bulletin of the American Mathematical Society*, vol. 46, n.º 2, págs. 255-308, 2009. DOI: 10.1090/S0273-0979-09-01249-X

[4] S. Dadsetan, D. Arefan, W. A. Berg, M. L. Zuley, J. H. Sumkin y S. Wu, "Deep learning of longitudinal mammogram examinations for breast cancer risk prediction", *Pattern Recognition*, vol. 132, pág. 108 919, 2022. DOI: 10.1016/j.patcog.2022.108919

[5] Departamento de Matematicas, Universidad de Hitit, "A hybrid deep learning architecture for breast cancer classification", *The European Physical Journal Plus*, 2026, Articulo de pago (403 al intentar leerlo completo); resumen verificado via busqueda, metricas exactas no verificadas directamente. DOI: 10.1140/epjp/s13360-026-07852-w

[6] H. Edelsbrunner y J. L. Harer, *Computational Topology: An Introduction*. American Mathematical Society, 2010, ISBN: 978-0-8218-4925-5.

[7] C. Fanning y M. E. Aktas, "Topological Conditioning for Mammography Models via a Stable Wavelet-Persistence Vectorization", *arXiv preprint arXiv:2512.10151 (sometido a IEEE Transactions on Medical Imaging)*, 2025. arXiv: 2512.10151 [eess.IV].

[8] J. J. Jeong, B. L. Vey, A. Bhimireddy et al., "The EMory BrEast imaging Dataset (EMBED): A Racially Diverse, Granular Dataset of 3.5 Million Screening and Diagnostic Mammograms", *Radiology: Artificial Intelligence*, 2023, Acceso controlado ("Controlled Access"): requiere solicitud formal a traves del portal data.hitilab.com; verificado empiricamente (boto3 sin firmar y HTTP directo)

que el bucket de AWS Open Data no permite listado anonimo (AccessDenied). No existe un subconjunto publico sin autenticacion. DOI: 10.1148/ryai.220047

[9] C. B. Jetomo, M. L. D. De Lara y S. I. Hussain, "Topological insights and hybrid feature extraction for breast cancer detection", *PeerJ Computer Science*, vol. 11, e3374, 2025. DOI: 10.7717/peerj-cs.3374

[10] B. Karimian, S. Belharbi y A. Guichemerre, "Single-Exam Mammography Risk Prediction with Privileged History Distillation", *arXiv preprint arXiv:2603.15814*, 2026. arXiv: 2603.15814 [eess.IV].

[11] Karolinska Institutet, *CSAW-CC (mammography) – a dataset for AI research to improve screening, diagnostics and prognostics of breast cancer*, Cohorte longitudinal real (8723 pacientes, 24694 examenes, 75.5 % con >=2 examenes); acceso a imagenes DICOM/PNG (2.5 TB) bajo solicitud formal, no descarga directa, 2021. DOI: 10.5878/45vm-t798

[12] T. Kooi y N. Karssemeijer, "Classifying Symmetrical Differences and Temporal Change for the Detection of Malignant Masses in Mammography Using Deep Neural Networks", *Journal of Medical Imaging*, vol. 4, n.º 4, pág. 044 501, 2017. DOI: 10.1117/1.JMI.4.4.044501

[13] R. S. Lee, F. Gimenez, A. Hoogi, K. K. Miyake, M. Gorovoy y D. L. Rubin, "A curated mammography data set for use in computer-aided detection and diagnosis research", *Scientific Data*, vol. 4, pág. 170 177, 2017. DOI: 10.1038/sdata.2017.177

[14] G. Litjens et al., "A survey on deep learning in medical image analysis", *Medical Image Analysis*, vol. 42, págs. 60-88, 2017. DOI: 10.1016/j.media.2017.07.005

[15] S. M. Lundberg y S.-I. Lee, "A Unified Approach to Interpreting Model Predictions", en *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, págs. 4765-4774.

[16] M. Rakez et al., "The LongiMam model for improved breast cancer risk prediction using longitudinal mammograms", *arXiv preprint arXiv:2509.21383*, 2025. arXiv: 2509.21383 [eess.IV].

[17] M. T. Ribeiro, S. Singh y C. Guestrin, ""Why Should I Trust You?": Explaining the Predictions of Any Classifier", en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, págs. 1135-1144. DOI: 10.1145/2939672.2939778

[18] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh y D. Batra, "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization", en *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, págs. 618-626. DOI: 10.1109/ICCV.2017.74

[19] S. Thrun et al., "The Impact of Longitudinal Mammogram Alignment on Breast Cancer Risk Assessment", *arXiv preprint arXiv:2511.08328*, 2025. arXiv: 2511.08328 [eess.IV].

[20] A. Yala, C. Lehman, T. Schuster, T. Portnoi y R. Barzilay, "A Deep Learning Mammography-based Model for Improved Breast Cancer Risk Prediction", *Radiology*, vol. 292, n.º 1, págs. 60-66, 2019. DOI: 10.1148/radiol.2019182716

[21] Z. Zhou, D. Arefan, M. Zuley, J. Sumkin y S. Wu, "STA-Risk: A Deep Dive of Spatio-Temporal Asymmetries for Breast Cancer Risk Prediction", *arXiv preprint arXiv:2505.21699*, 2025. arXiv: 2505.21699 [eess.IV].

Apéndice A

Material adicional

A.1. Instalación del entorno

Instrucciones para reproducir el entorno de desarrollo:

```
python -m venv .venv
source .venv/bin/activate          # En Windows: .venv\Scripts\activate
pip install -r requirements.txt
```

A.2. Descripción de los campos de CBIS-DDSM

A.2.1. Manifiesto de TCIA (incluido en el repositorio)

El fichero `CBIS-DDSM-All-doiJNLP-zzWs5zfZ-nbia-digest.xlsx` es el manifiesto que genera TCIA al exportar una colección: identifica las series DICOM disponibles pero **no incluye la etiqueta de patología**. Sus campos más relevantes para el *pipeline* son:

Tabla A.1: Campos relevantes del manifiesto de TCIA.

Campo	Descripción
`Patient ID`	Identificador largo, p. ej. `Mass-Training_P_01009_RIGHT_CC_1`. `src.data.load_manifest` extrae de aquí el id real de paciente (`P_01009`) con una expresión regular, base de la partición por paciente.
`Series Description`	Tipo de imagen de la serie: `full mammogram images`, `ROI mask images` o `cropped images`.
`Modality`	Modalidad DICOM; `MG` (mamografía) en todos los casos.
`Body Part Examined`	Región anatómica (`BREAST`).
`Image Count`	Número de imágenes DICOM de la serie.
`File Size`	Tamaño en bytes de la serie (para estimar la descarga total).
`Collection URI`	DOI de la colección en TCIA [13].
`License Name`	*Creative Commons Attribution 3.0 Unported.*

A.2.2. CSV de descripción de casos (a descargar de TCIA)

Los ficheros `mass_/calc_case_description_{train,test}_set.csv` — no incluidos en el repositorio, véase la Sección 7.3.4 — sí contienen la etiqueta clínica. La función `load_case_descriptions` de `src/data.py` espera, entre otros, los campos `patient_id`, `breast_density` (densidad BI-RADS, 1–4), `left or right breast`, `image view` (CC/MLO), `abnormality type` (masa o calcificación), `assessment` (BI-RADS 0–5), `subtlety` y, sobre todo, `pathology` (`BENIGN`, `BENIGN_WITHOUT_CALLBACK`, `MALIGNANT`), que `src.data.to_binary_label` convierte en la etiqueta binaria 0/1 usada en todo el trabajo.

A.3. Fragmentos de código adicionales

A.3.1. Selección automática de backend de homología persistente

Como `giotto-tda` no publica binarios para Python 3.13+ (Sección 7.2.1), `src/topology.py` detecta en tiempo de importación qué backend usar, sin que el resto del *pipeline* necesite saberlo:

```
try:
    from gtda.homology import CubicalPersistence
    _HAS_GIOTTO = True
```

```
except ImportError:
    _HAS_GIOTTO = False

try:
    import gudhi
    _HAS_GUDHI = True
except ImportError:
    _HAS_GUDHI = False

def backend() -> str:
    if _HAS_GIOTTO:
        return "giotto-tda"
    if _HAS_GUDHI:
        return "gudhi"
    return "none"
```

Listing A.1: Deteccion de backend en src/topology.py (fragmento).

A.3.2. Imagen de persistencia sin giotto-tda

Cuando el backend activo es `gudhi`, la imagen de persistencia se calcula a mano con un núcleo gaussiano ponderado por persistencia, sobre la rejilla fija $[0,1] \times [0,1]$ (las imágenes ya están normalizadas por `preprocessing.to_grayscale_float`, Sección 5):

```
grid = np.linspace(0.0, 1.0, n_bins)
birth_grid, pers_grid = np.meshgrid(grid, grid, indexing="ij")
sigma = 1.0 / n_bins

for birth, pers, weight in zip(births, persistences, weights):
    image += weight * np.exp(
        -((birth_grid - birth) ** 2 + (pers_grid - pers) ** 2) / (2 *
           sigma ** 2)
    )
```

Listing A.2: Imagen de persistencia manual (nucleo gaussiano), src/topology.py (fragmento).

Al fijar la rejilla de antemano (en vez de ajustarla, *fit*, por lote como hace `giotto-tda`), todas las imágenes del conjunto de datos producen vectores de la misma longitud y directamente comparables entre sí, sin necesitar un paso de ajuste previo sobre el conjunto de entrenamiento.