Universidad de Alicante
Escuela Politécnica Superior

Grado en Ingeniería Informática

Análisis Topológico de Datos aplicado a la clasificación y visualización de mamografías digitales

Trabajo de Fin de Grado

Autor:
Nombre Apellido Apellido

Tutor/es:
Nombre del tutor/a

9 de noviembre de 2026

Resumen

El cáncer de mama es el tumor de mayor incidencia entre las mujeres a nivel mundial, y la mamografía sigue siendo la prueba de cribado de referencia para su detección precoz. En los últimos años, las técnicas de *deep learning* han demostrado un gran potencial en el análisis automático de imagen médica, pero suelen comportarse como cajas negras y son sensibles al ruido y a la variabilidad de adquisición. El **Análisis Topológico de Datos** (TDA, por sus siglas en inglés) ofrece una perspectiva complementaria: cuantifica la *forma* de los datos mediante invariantes topológicos robustos frente al ruido, como la homología persistente.

Este Trabajo de Fin de Grado estudia la aplicación del TDA a la clasificación y visualización de mamografías digitales del conjunto de datos público CBIS-DDSM. Se extraen descriptores topológicos (diagramas de persistencia, códigos de barras e imágenes de persistencia) a partir de las imágenes y de las regiones de interés, se evalúa su capacidad discriminativa entre lesiones benignas y malignas, y se comparan y combinan con modelos de aprendizaje profundo. El objetivo último es obtener un sistema de apoyo al diagnóstico más *interpretable* sin sacrificar rendimiento.

Palabras clave: análisis topológico de datos, homología persistente, mamografía, cáncer de mama, aprendizaje profundo, imagen médica, CBIS-DDSM.

Abstract. Breast cancer is the most common malignancy among women worldwide, and mammography remains the reference screening test for its early detection. Deep learning has shown remarkable potential in medical image analysis, yet such models often behave as black boxes and are sensitive to noise and acquisition variability. **Topological Data Analysis** (TDA) provides a complementary viewpoint by quantifying the *shape* of the data through noise-robust topological invariants such as persistent homology. This bachelor's thesis investigates the application of TDA to the classification and visualisation of digital mammograms from the public CBIS-DDSM dataset.

Topological descriptors (persistence diagrams, barcodes and persistence images) are extracted and evaluated for their ability to discriminate benign from malignant lesions, and compared and combined with deep learning models, aiming at a more *interpretable* decision-support system.

Keywords: topological data analysis, persistent homology, mammography, breast cancer, deep learning, medical imaging, CBIS-DDSM.

Índice general

Resumen I

1. Introducción **1**

1.1. Motivación 1

1.2. Contexto del problema 1

1.3. Objetivos y alcance (resumen) 2

1.4. Estructura de la memoria 2

2. Objetivos y metodología **3**

2.1. Objetivo general 3

2.2. Objetivos específicos 3

2.3. Metodología general 4

3. Estado del arte **7**

3.1. Análisis automático de mamografías 7

3.1.1. Conjuntos de datos públicos 7

3.1.2. Limitaciones 8

3.2. Análisis Topológico de Datos en imagen médica 8

3.3. Predicción de riesgo y análisis longitudinal de mamografía 8

3.4. Síntesis y aportación de este trabajo 9

4. Fundamentos teóricos **11**

4.1. Análisis Topológico de Datos 11

4.1.1. Complejos simpliciales y filtraciones 11

4.1.2. Homología y números de Betti 11

4.1.3. Homología persistente 12

4.1.4. Estabilidad y vectorización 12

4.2. Aprendizaje profundo (referencia) 12

4.2.1. Redes neuronales convolucionales 13

4.2.2. Transfer learning 13

5. Metodología propuesta **15**
5.1. Visión general del *pipeline* . . . 15
5.2. Conjunto de datos . . . 15
5.2.1. Protocolo de evaluación y prevención de fuga de datos . . . 16
5.3. Preprocesado de imágenes . . . 16
5.4. Extracción de descriptores topológicos . . . 16
5.5. Modelos de clasificación . . . 17
5.6. Métricas de evaluación . . . 17
5.7. Métrica de acuerdo topológico-clínico (línea secundaria) . . . 17
5.7.1. Cuatro métodos, una región binaria comparable . . . 17
5.7.2. Métrica de acuerdo . . . 18
5.7.3. Nota metodológica: IoU contra la máscara de ROI real . . . 19
5.7.4. Coste computacional . . . 19
5.8. Metodología longitudinal (hipótesis principal) . . . 19
5.8.1. Definición de las señales longitudinales . . . 19
5.8.2. Validación de la metodología con datos sintéticos . . . 20
5.8.3. Análisis de sensibilidad: anticipación frente a deriva . . . 21
5.8.4. Limitación de acceso a datos longitudinales reales . . . 21

6. Implementación **23**
6.1. Herramientas y librerías . . . 23
6.2. Organización del código . . . 23
6.3. Extracción de descriptores topológicos . . . 24
6.4. Reproducibilidad . . . 24
6.5. Visualización . . . 25

7. Experimentos y resultados **27**
7.1. Diseño experimental . . . 27
7.2. Configuración . . . 27
7.2.1. Backend de homología persistente . . . 28
7.3. Validación preliminar del *pipeline* con datos sintéticos . . . 28
7.4. Resultados sobre el piloto real de CBIS-DDSM . . . 30
7.4.1. Por qué el AUC de test es tan malo (y por qué no es alarmante) 31
7.4.2. Refinamiento: ajuste de hiperparámetros por vía (issue #77) . . 31
7.4.3. Sanity check visual: masa espiculada benigna vs. maligna . . . 32
7.4.4. Estado de los datos . . . 33
7.5. Interpretabilidad: TDA vs Grad-CAM vs SHAP vs LIME . . . 34
7.5.1. El hallazgo principal: los cuatro métodos apenas coinciden entre sí 34
7.5.2. IoU contra la máscara de ROI real . . . 35
7.5.3. Desglose por tipo de margen de la masa . . . 36

7.5.4. Coste computacional 36
7.6. Discusión 36

8. Conclusiones y trabajo futuro **39**
8.1. Conclusiones 39
8.2. Grado de cumplimiento de los objetivos 41
8.3. Limitaciones 41
8.4. Trabajo futuro 42

Bibliografía **45**

A. Material adicional **49**
A.1. Instalación del entorno 49
A.2. Descripción de los campos de CBIS-DDSM 49
A.2.1. Manifiesto de TCIA (incluido en el repositorio) 49
A.2.2. CSV de descripción de casos (a descargar de TCIA) 50
A.3. Fragmentos de código adicionales 50
A.3.1. Selección automática de backend de homología persistente . . . 50
A.3.2. Imagen de persistencia sin giotto-tda 51

Índice de figuras

5.1. Esquema general del *pipeline* propuesto: de los datos crudos a las métricas clínicas, pasando por la extracción de descriptores topológicos. . . . 15

7.1. Ejemplo de imagen sintética de cada clase: un *blob* redondeado y suave (benigno) frente a una masa con espículas y micro-motas (maligno), ambas con ruido gaussiano fuerte para evitar un problema trivial. . . . 29
7.2. Matriz de confusión del *random forest* (mejor modelo por F1) sobre el conjunto sintético de test. Generada en `notebooks/01_pipeline_demo.ipynb`. 30
7.3. Diagramas de persistencia (backend `gudhi`) de un ejemplo benigno y uno maligno del conjunto sintético. H0 (componentes conexas) en azul, H1 (agujeros/ciclos) en naranja; la diagonal discontinua marca birth = death. 30
7.4. Caso real benigno (`P_00692`, arriba) y maligno (`P_00734`, abajo) con margen de masa espiculado, con su diagrama de persistencia H0/H1 (backend `gudhi`). 33
7.5. Caso de mayor acuerdo TDA/Grad-CAM del piloto (`P_01090`, arriba) frente al de menor acuerdo (`P_00433`, abajo), con las 4 regiones superpuestas en rojo sobre la imagen preprocesada. 35

Índice de tablas

2.1. Trazabilidad entre objetivos específicos y capítulos de la memoria. . . . 5

5.1. AUC por validación cruzada (5-fold) de cada señal longitudinal sobre datos sintéticos. 20

6.1. Principales herramientas utilizadas. 23

7.1. Resultados sobre datos sintéticos (validación del *pipeline*, imagen de persistencia H0+H1, backend gudhi). 29

7.2. Resultados reales sobre el piloto de CBIS-DDSM (30 pacientes, `scripts/run_pipeline.py` y `scripts/fuse_and_evaluate.py`, `n_bins=4`, Random Forest). El AUC por validación cruzada (5-fold sobre train) es la columna fiable; el test de solo 8 casos es muy ruidoso (ver discusión debajo de la tabla). . . . 31

7.3. AUC por validación cruzada (5-fold, train) antes y después de ajustar hiperparámetros por vía. "Mejor encontrado" es el máximo entre *random forest* por defecto (Tabla 7.2) y SVM ajustada por `GridSearchCV` ($n_bins = 4$, $C \in \{0{,}01, \ldots, 100\}$, kernel lineal/RBF). 32

7.4. Acuerdo por pares entre los 4 métodos de interpretabilidad (IoU media $\pm$ desviación típica, $n = 48$ casos reales). 34

7.5. IoU de cada método contra la máscara de ROI real ($n = 48$). 35

7.6. Coste computacional por método (segundos/caso, $n = 48$). 36

8.1. Grado de cumplimiento de los objetivos específicos. 41

A.1. Campos relevantes del manifiesto de TCIA. 50

Capítulo 1

Introducción

1.1. Motivación

El cáncer de mama es la neoplasia más frecuente en mujeres y una de las principales causas de mortalidad por cáncer a nivel mundial. La detección precoz mediante programas de cribado con mamografía reduce de forma significativa la mortalidad, ya que permite identificar lesiones en estadios tempranos y más tratables. Sin embargo, la interpretación de mamografías es una tarea compleja, sujeta a variabilidad inter-observador y a una carga de trabajo elevada para los radiólogos.

En este contexto, los sistemas de diagnóstico asistido por computador (*Computer-Aided Diagnosis*, CAD) y, más recientemente, las técnicas de aprendizaje profundo (*deep learning*) se han convertido en herramientas de gran interés. Trabajos como el de Yala *et al.* [18] han demostrado que los modelos basados en mamografía pueden mejorar la predicción del riesgo de cáncer de mama. No obstante, estos modelos presentan limitaciones importantes: son difíciles de interpretar, requieren grandes cantidades de datos etiquetados y pueden ser sensibles al ruido y a las condiciones de adquisición.

El **Análisis Topológico de Datos** (TDA) surge como un enfoque complementario que caracteriza la *forma* intrínseca de los datos mediante herramientas de la topología algebraica. Su técnica principal, la *homología persistente*, es robusta frente al ruido y proporciona descriptores interpretables geométricamente, lo que la hace especialmente atractiva para el análisis de imagen médica.

1.2. Contexto del problema

Una mamografía digital es una imagen de rayos X de la mama que revela estructuras como el tejido glandular, los conductos, las calcificaciones y posibles masas. La densidad mamaria (clasificada habitualmente según el sistema BI-RADS) y la morfología de las lesiones son factores clave en el diagnóstico. El conjunto de datos público

CBIS-DDSM [11] proporciona mamografías digitalizadas con anotaciones de lesiones (masas y microcalcificaciones), regiones de interés (ROI) segmentadas y etiquetas de patología (benigno/maligno), lo que lo convierte en un banco de pruebas adecuado para este trabajo.

1.3. Objetivos y alcance (resumen)

El objetivo general de este TFG es **estudiar y evaluar la aplicación del Análisis Topológico de Datos a la clasificación y visualización de mamografías**, comparándolo y combinándolo con técnicas de aprendizaje profundo. Los objetivos específicos se detallan en el Capítulo 2.

1.4. Estructura de la memoria

El resto de la memoria se organiza como sigue:

- El **Capítulo 2** formula los objetivos y la metodología general del trabajo.
- El **Capítulo 3** revisa el estado del arte en análisis de mamografías y en TDA aplicado a imagen médica.
- El **Capítulo 4** introduce los fundamentos teóricos de la homología persistente y del aprendizaje profundo.
- El **Capítulo 5** describe la metodología propuesta: datos, preprocesado, extracción de descriptores y modelos.
- El **Capítulo 6** detalla la implementación y las herramientas utilizadas.
- El **Capítulo 7** presenta y discute los resultados experimentales.
- El **Capítulo 8** recoge las conclusiones y las líneas de trabajo futuro.

Capítulo 2

Objetivos y metodología

2.1. Objetivo general

El objetivo general de este Trabajo de Fin de Grado es **investigar si el Análisis Topológico de Datos (TDA) permite la detección anticipada del cáncer de mama mediante el análisis longitudinal de mamografías sucesivas de una misma paciente**: comparar los descriptores topológicos de la exploración previa (leída clínicamente como normal) con los de la exploración donde el cáncer se diagnostica, para determinar si ya existía una señal topológica medible antes del diagnóstico. Esta hipótesis se apoya en una base necesaria — la clasificación benigno/maligno sobre una mamografía aislada mediante homología persistente, y su comparación con un modelo de *deep learning* — que constituye la primera mitad de los objetivos específicos.

2.2. Objetivos específicos

Para alcanzar el objetivo general se plantean los siguientes objetivos específicos:

O1. Revisar el estado del arte en (i) análisis automático de mamografías, (ii) aplicaciones del TDA en imagen médica y (iii) predicción de riesgo/análisis longitudinal de mamografías.

O2. Preparar y preprocesar un conjunto de datos de mamografía (CBIS-DDSM para la base de clasificación; un conjunto longitudinal — CSAW-CC o EMBED, pendiente de acceso, ver Capítulo 5 — para la hipótesis principal): descarga, limpieza de metadatos, extracción de ROIs y normalización de las imágenes.

O3. Extraer descriptores topológicos (diagramas de persistencia, códigos de barras e imágenes de persistencia) a partir de las mamografías mediante homología persistente.

O4. Entrenar y evaluar clasificadores sobre los descriptores topológicos (p. ej. SVM, *random forest*) para la tarea benigno/maligno sobre una mamografía aislada.

O5. Comparar el enfoque topológico con un modelo de *deep learning* de referencia (CNN con *transfer learning*) y **explorar su combinación** (fusión de características).

O6. Desarrollar herramientas de visualización que hagan interpretables los resultados topológicos para su uso como apoyo al diagnóstico.

O7. Diseñar y validar la metodología de comparación longitudinal: definir cómo medir el cambio topológico entre dos exploraciones de la misma paciente (distancia *bottleneck*/ Wasserstein entre diagramas de persistencia) y validar que el *pipeline* es capaz de detectar esa señal cuando existe, inicialmente sobre datos sintéticos controlados.

O8. Evaluar la hipótesis de detección anticipada sobre datos longitudinales reales: determinar si los descriptores topológicos de la exploración previa (sin diagnóstico) distinguen a las pacientes que desarrollarán cáncer de las que no, y comparar esta señal con los modelos de predicción de riesgo basados en *deep learning* ya publicados (p. ej. LongiMam [14]).

2.3. Metodología general

El desarrollo del trabajo sigue una metodología incremental e iterativa, estructurada en las siguientes fases, alineadas con los objetivos anteriores:

1. **Fase de documentación** (O1): estudio de la bibliografía y de las herramientas disponibles.

2. **Fase de datos** (O2): construcción de un *pipeline* reproducible de preparación de datos.

3. **Fase de extracción de características** (O3): implementación de la extracción de descriptores topológicos.

4. **Fase de modelado** (O4, O5): entrenamiento, validación y comparación de modelos, evitando la fuga de datos (*data leakage*) mediante una separación estricta *train/validation/test*.

5. **Fase de análisis y visualización** (O6): interpretación de los resultados y desarrollo de visualizaciones.

6. **Fase longitudinal** (O7, O8): diseño de la comparación topológica entre exploraciones sucesivas, validación con datos sintéticos y, en cuanto se obtenga acceso a un dataset real longitudinal, evaluación de la hipótesis de detección anticipada.

7. **Fase de redacción** de la memoria.

Tabla 2.1: Trazabilidad entre objetivos específicos y capítulos de la memoria.

Objetivo	**Descripción breve**	**Capítulo**
O1	Estado del arte	3
O2	Preparación de datos	5, 6
O3	Descriptores topológicos	4, 5
O4	Clasificadores sobre TDA	5, 7
O5	Comparación con DL	7
O6	Visualización	6, 7
O7	Diseño y validación sintética de la comparación longitudinal	5, 7
O8	Evaluación de la hipótesis de detección anticipada (datos reales)	7, 8

Capítulo 3

Estado del arte

Este capítulo revisa los trabajos previos relevantes en dos líneas complementarias: el análisis automático de mamografías mediante aprendizaje profundo, y las aplicaciones del Análisis Topológico de Datos en imagen médica.

3.1. Análisis automático de mamografías

El análisis asistido por computador de mamografías tiene una larga trayectoria, desde los primeros sistemas CAD basados en características diseñadas manualmente (*hand-crafted features*) hasta los actuales enfoques de aprendizaje profundo. Las redes neuronales convolucionales (CNN) se han consolidado como el paradigma dominante en visión por computador y en imagen médica, gracias a su capacidad para aprender jerarquías de características directamente de los datos [1], [12].

En el ámbito específico de la mamografía, destacan trabajos orientados a la detección y clasificación de masas y microcalcificaciones, así como a la estimación del riesgo. Yala *et al.* [18] propusieron un modelo basado en *deep learning* que mejora la predicción del riesgo de cáncer de mama a partir de la mamografía, superando a los modelos de riesgo tradicionales. El uso de *transfer learning* a partir de redes preentrenadas en ImageNet (ResNet, DenseNet, EfficientNet, etc.) es una práctica habitual para mitigar la escasez de datos etiquetados en el dominio médico.

3.1.1. Conjuntos de datos públicos

Entre los conjuntos de datos públicos de mamografía más utilizados destaca CBIS-DDSM [11], una versión curada y estandarizada del clásico DDSM que incluye segmentaciones de ROI verificadas y etiquetas de patología. Otros recursos relevantes son INbreast y las bases de datos de ecografía mamaria.

3.1.2. Limitaciones

A pesar de sus buenos resultados, los modelos de *deep learning* en mamografía presentan limitaciones bien conocidas:

- **Interpretabilidad limitada**: su naturaleza de caja negra dificulta la confianza clínica y la certificación.
- **Dependencia de grandes volúmenes de datos** etiquetados.
- **Riesgo de fuga de datos** (*data leakage*) y de sesgos de adquisición, que pueden producir métricas artificialmente altas si el protocolo experimental no es riguroso.

Estas limitaciones motivan la búsqueda de representaciones más robustas e interpretables, como las que proporciona el TDA.

3.2. Análisis Topológico de Datos en imagen médica

El Análisis Topológico de Datos (TDA) engloba un conjunto de técnicas que estudian la forma de los datos mediante herramientas de topología algebraica [3], [5]. Su herramienta central, la *homología persistente*, ha sido aplicada con éxito en diversos problemas de imagen médica: caracterización de texturas de tumores, análisis de imágenes histopatológicas, neuroimagen y detección de estructuras en radiología.

En el contexto de la mamografía y del cáncer de mama, los descriptores topológicos permiten capturar patrones de conectividad y estructura (número de componentes conexas, agujeros, ramificaciones de conductos, distribución de microcalcificaciones) que resultan difíciles de modelar con características convencionales. Su robustez frente al ruido y su interpretabilidad geométrica los convierten en un complemento natural de las CNN.

3.3. Predicción de riesgo y análisis longitudinal de mamografía

Una línea de trabajo más reciente y directamente relevante para la hipótesis principal de este TFG (Capítulo 2) es la que usa **varias exploraciones sucesivas** de la misma paciente, en vez de una única mamografía, para predecir el riesgo de cáncer. Dadsetan *et al.* [4] fueron de los primeros en mostrar que un modelo de *deep learning* entrenado sobre pares longitudinales de mamografías mejora la predicción de riesgo frente a usar solo la exploración más reciente. Trabajos más recientes refinan esta idea:

LongiMam [14] combina explícitamente la exploración actual y las previas en un único modelo; STA-Risk [19] explota asimetrías espacio-temporales entre exploraciones; Karimian *et al.* [8] proponen destilar el historial longitudinal hacia un modelo que solo necesita la exploración actual en inferencia (*privileged information*); y Thrun *et al.* [17] estudian específicamente el problema — no trivial — de **alinear espacialmente** exploraciones de distinta fecha antes de compararlas. Kooi y Karssemeijer [10] y Bai *et al.* [2] abordan variantes anteriores del mismo problema (cambio temporal y simetría entre mamas) con CNN y modelos no supervisados, respectivamente.

Todos estos trabajos son de *deep learning* end-to-end sobre píxeles; ninguno usa descriptores topológicos. En paralelo, la aplicación de TDA a mamografía (Sección 3.2 y [6]) trabaja siempre sobre una **única exploración por caso**. Una búsqueda sistemática (arXiv, Google Scholar; 2026-10-07) combinando "persistent homology/"topological data analysisçon "longitudinal/"temporalƶ "mammography/"breast cancer"no encontró ningún trabajo que combine ambas líneas. Un *survey* de aplicaciones de TDA en oncología citado en esa búsqueda llega a sugerir explícitamente el análisis de series temporales en cáncer como dirección futura no explorada, lo que corrobora el hueco. Esto deja planteada la pregunta que motiva la hipótesis principal de este trabajo: **¿aporta la homología persistente, aplicada al cambio topológico entre exploraciones sucesivas, una señal predictiva que los modelos de *deep learning* longitudinal actuales no capturan — o capturan de forma menos interpretable?**

3.4. Síntesis y aportación de este trabajo

La revisión anterior muestra dos líneas activas que, hasta donde se ha podido verificar, no se han combinado todavía: el TDA aplicado a una mamografía aislada (prometedor pero poco explorado frente al *deep learning* dominante) y la predicción de riesgo mediante *deep learning* sobre exploraciones longitudinales (activa y reciente, pero exclusivamente basada en píxeles). La aportación de este TFG parte de un estudio sistemático de descriptores topológicos sobre CBIS-DDSM para la clasificación benigno/maligno sobre una mamografía aislada — necesario como base, y comparado y combinado con un modelo de *deep learning* de referencia — pero su objetivo central es extender esa base al caso longitudinal: usar la homología persistente para comparar la exploración previa (normal) con la exploración donde se diagnostica el cáncer, y evaluar si ya existía una señal topológica medible antes del diagnóstico (Capítulo 5, Sección 5.8).

Capítulo 4

Fundamentos teóricos

Este capítulo introduce los conceptos necesarios para comprender el trabajo: los fundamentos del Análisis Topológico de Datos, con énfasis en la homología persistente, y una breve descripción de los modelos de aprendizaje profundo empleados como referencia.

4.1. Análisis Topológico de Datos

El TDA parte de la idea de que los datos poseen una *forma* y que dicha forma contiene información relevante. Formalmente, se construye a partir de los datos una familia de espacios topológicos y se estudia cómo evolucionan sus invariantes.

4.1.1. Complejos simpliciales y filtraciones

Definición 4.1 (Complejo simplicial)**.** Un *complejo simplicial* K es un conjunto de símplices (vértices, aristas, triángulos, tetraedros, ...) cerrado bajo la operación de tomar caras y tal que la intersección de dos símplices es una cara de ambos.

Para analizar datos se construye una *filtración*, es decir, una familia anidada de complejos simpliciales

$$\emptyset = K_0 \subseteq K_1 \subseteq \cdots \subseteq K_n = K,$$

indexada por un parámetro de escala. En imágenes, una filtración habitual es la *filtración por sublevel sets* de la intensidad: se van incluyendo los píxeles cuyo valor es menor o igual que un umbral creciente.

4.1.2. Homología y números de Betti

La homología asocia a cada complejo una secuencia de grupos cuyos rangos, los *números de Betti* β_k, cuentan las características topológicas de dimensión k:

- β_0: número de **componentes conexas**.
- β_1: número de **agujeros** o ciclos unidimensionales.
- β_2: número de **cavidades** o huecos tridimensionales.

4.1.3. Homología persistente

La *homología persistente* rastrea el nacimiento (*birth*) y la muerte (*death*) de las características topológicas a lo largo de la filtración. Una característica que persiste durante un amplio rango de escalas se considera una propiedad estructural significativa, mientras que las de vida corta suelen corresponder a ruido.

Definición 4.2 (Diagrama de persistencia)**.** El *diagrama de persistencia* es un multiconjunto de puntos $(b_i, d_i) \in \mathbb{R}^2$ con $b_i \leq d_i$, donde cada punto representa una característica topológica que nace en la escala b_i y muere en d_i. La *persistencia* de la característica es $d_i - b_i$.

La misma información puede representarse como un *código de barras* (*barcode*), donde cada característica es un intervalo $[b_i, d_i]$.

4.1.4. Estabilidad y vectorización

Una propiedad fundamental es la **estabilidad**: pequeñas perturbaciones en los datos producen pequeñas variaciones en el diagrama de persistencia (medidas con la distancia *bottleneck* o de Wasserstein). Esto explica la robustez del TDA frente al ruido.

Para poder utilizar los diagramas como entrada de algoritmos de aprendizaje automático es necesario *vectorizarlos*. Entre las representaciones más utilizadas destacan:

- **Imágenes de persistencia** (*persistence images*): transforman el diagrama en una imagen (matriz) de tamaño fijo.
- **Persistence landscapes**: funciones a trozos que resumen el diagrama.
- **Curvas de Betti** y estadísticos de persistencia.

4.2. Aprendizaje profundo (referencia)

Como referencia comparativa se emplean redes neuronales convolucionales (CNN).

4.2.1. Redes neuronales convolucionales

Una CNN aprende, mediante capas convolucionales, jerarquías de características espaciales a partir de las imágenes. Combinada con capas de *pooling* y capas totalmente conectadas, permite abordar tareas de clasificación de imagen.

4.2.2. Transfer learning

Dado el tamaño limitado de los conjuntos de datos médicos, se recurre al *transfer learning*: se parte de una red preentrenada en un gran corpus (p. ej. ImageNet) y se ajusta (*fine-tuning*) a la tarea de mamografía. En este trabajo se utiliza como referencia una arquitectura de la familia DenseNet/ResNet.

Ejemplo 4.1 (Intuición del enfoque topológico en mamografía)**.** Una agrupación de microcalcificaciones puede caracterizarse por el número de componentes conexas (β_0) y su patrón de aparición a lo largo de la filtración de intensidad, mientras que la estructura de una masa espiculada puede reflejarse en la aparición y desaparición de ciclos (β_1). El TDA codifica estos patrones de forma compacta y robusta.

Capítulo 5

Metodología propuesta

En este capítulo se describe la metodología propuesta para aplicar el TDA a la clasificación de mamografías, desde la preparación de los datos hasta la evaluación de los modelos.

5.1. Visión general del *pipeline*

El sistema propuesto consta de cinco etapas:

1. Preparación de datos (CBIS-DDSM).
2. Preprocesado de imágenes y extracción de ROIs.
3. Extracción de descriptores topológicos.
4. Clasificación (topológica, *deep learning* y fusión).
5. Evaluación y visualización.

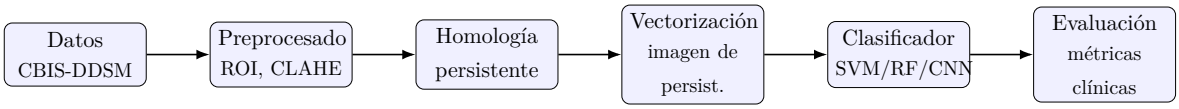


Figura 5.1: Esquema general del *pipeline* propuesto: de los datos crudos a las métricas clínicas, pasando por la extracción de descriptores topológicos.

5.2. Conjunto de datos

Se utiliza CBIS-DDSM [11]. El fichero de metadatos disponible en el repositorio (`CBIS-DDSM-All-... .xlsx`) contiene la información de cada estudio: identificador de paciente, tipo de lesión (masa o calcificación), densidad de la mama (BI-RADS), vista (CC/MLO), y la etiqueta de patología (`BENIGN`, `MALIGNANT`, `BENIGN_WITHOUT_CALLBACK`).

- **Tarea principal**: clasificación binaria benigno vs. maligno.
- **Unidad de análisis**: región de interés (ROI) de la lesión y/o imagen completa reescalada.

5.2.1. Protocolo de evaluación y prevención de fuga de datos

Se adopta una partición estricta en **entrenamiento / validación / test**. Para evitar la fuga de datos (*data leakage*), la separación se realiza **a nivel de paciente**: todas las imágenes de un mismo paciente pertenecen a una única partición. Se emplea estratificación por la etiqueta de patología para mantener la proporción de clases.

> *Nota metodológica.* En el material de partida (`Demo_Notebook.ipynb`) se observaba una exactitud de entrenamiento del 100 % desde la primera época y una exactitud de validación cercana al 100 %, lo que es un indicio claro de fuga de datos o de un problema en el *pipeline*. Este trabajo corrige dicho protocolo mediante partición por paciente, control de la normalización y validación cruzada.

5.3. Preprocesado de imágenes

El preprocesado incluye:

- Conversión y normalización de intensidades.
- Recorte de la ROI a partir de las máscaras de segmentación.
- Reescalado a un tamaño común (p. ej. 224×224).
- Opcionalmente, realce de contraste (CLAHE) y filtrado de ruido.

5.4. Extracción de descriptores topológicos

A partir de cada imagen (o ROI) se calcula la homología persistente mediante una filtración por *sublevel sets* de la intensidad (para imágenes en escala de grises) o sobre nubes de puntos derivadas de las microcalcificaciones. Se obtienen los diagramas de persistencia en dimensiones 0 y 1, y a partir de ellos se generan los vectores de características:

- Imágenes de persistencia.
- Estadísticos de persistencia (número de puntos, persistencia total, máxima, media; curvas de Betti).

5.5. Modelos de clasificación

Se comparan tres enfoques:

1. **Topológico**: clasificadores clásicos (SVM, *random forest*, regresión logística) sobre los descriptores topológicos.
2. **Deep learning**: CNN con *transfer learning* sobre las imágenes.
3. **Fusión**: combinación de las características topológicas con las *embeddings* de la CNN.

5.6. Métricas de evaluación

Dado el carácter clínico del problema, se emplean varias métricas complementarias:

- **Exactitud** (*accuracy*).
- **Sensibilidad** (*recall*) — crítica para no pasar por alto casos malignos.
- **Especificidad** y **precisión**.
- **F1-score** y **AUC-ROC**.
- **Matriz de confusión**.

La sensibilidad recibe especial atención, ya que un falso negativo (no detectar un cáncer) tiene un coste clínico mucho mayor que un falso positivo.

5.7. Métrica de acuerdo topológico-clínico (línea secundaria)

Antes del pivote hacia la hipótesis longitudinal (Sección 5.8), el eje central del TFG comparaba la **interpretabilidad** del enfoque topológico frente a los métodos de explicabilidad habituales en *deep learning*: Grad-CAM [16], SHAP [13] y LIME [15]. Tras el pivote deja de ser la contribución central, pero se mantiene como línea secundaria (issue #91) y se ha implementado sobre el piloto real de CBIS-DDSM (`src/explainability.py`, `scripts/explainability_benchmark.py`).

5.7.1. Cuatro métodos, una región binaria comparable

Para que los cuatro métodos puedan compararse entre sí con la misma métrica, cada uno produce, sobre la **misma imagen preprocesada**, una región binaria de la imagen:

Grad-CAM Mapa de saliencia estándar (Selvaraju et al. 2017) sobre la salida de la última capa convolucional de la CNN de referencia (`model.features` de DenseNet121): se pondera cada canal de activación por el promedio espacial de su gradiente respecto a la clase predicha, se aplica ReLU y se reescala a la resolución de la imagen. Se binariza quedándose con el 20 % de píxeles más salientes (percentil 80).

Región topológica dominante El par de persistencia (H0 o H1) con mayor persistencia se localiza en píxeles concretos mediante `gudhi.cofaces_of_persistence_pairs()`, que asocia cada par de persistencia a dos celdas top-dimensionales (dos píxeles). Se umbraliza la imagen en el punto medio de los valores de nacimiento y muerte de ese par, y se toma la componente conexa del conjunto de sublevel resultante que contiene el píxel de nacimiento. Para H1 esto es una aproximación razonable — la región real"de un ciclo no es, en general, un conjunto de sublevel simple — no una reconstrucción exacta del ciclo representativo (gudhi no calcula ciclos representativos para complejos cúbicos).

SHAP `GradientExplainer` [13] sobre la misma CNN, con una imagen en negro como referencia (*background*). Se suman los valores de Shapley en valor absoluto sobre los 3 canales y se binariza igual que Grad-CAM (percentil 80).

LIME `lime_image` [15], con segmentación en superpíxeles (`quickshift` de scikit-image) y la misma CNN como función de predicción. Se toman los superpíxeles con contribución positiva a la clase predicha como región binaria.

5.7.2. Métrica de acuerdo

Dadas dos regiones binarias A y B (de cualquiera de los cuatro métodos, o de la máscara de ROI real), el acuerdo se mide con la intersección sobre unión (*Jaccard*) y, de forma complementaria, con el coeficiente de Dice:

$$\mathrm{IoU}(A,B) = \frac{|A \cap B|}{|A \cup B|}, \qquad \mathrm{Dice}(A,B) = \frac{2\,|A \cap B|}{|A| + |B|}.$$

Se calcula el acuerdo **por pares entre los cuatro métodos** (6 combinaciones) sobre todos los casos usables del piloto real — entrenamiento y test juntos, ya que este es un estudio descriptivo de interpretabilidad, no una evaluación predictiva, así que no hace falta reservar partición de test (issue #62) — y se desglosa por `mass_margins` (el campo de CBIS-DDSM que distingue, p. ej., márgenes circunscritos de espiculados) para ver si el acuerdo entre métodos varía según el tipo de lesión.

5.7.3. Nota metodológica: IoU contra la máscara de ROI real

Además del acuerdo entre métodos, se calcula también el IoU de cada método contra la máscara de ROI real (referencia clínica, disponible para cada caso de CBIS-DDSM). Es importante señalar una limitación honesta de esta comparación concreta: como la imagen ya está recortada muy cerca de la ROI (margen de 16 px, `src/preprocessing.py:crop_roi`, igual que el resto del *pipeline*), ese recorte sesga al alza el IoU de **cualquier** región central razonable contra la máscara por pura construcción geométrica, y por tanto es menos informativo que el acuerdo entre métodos de arriba. Se reporta por completitud (issue #61 lo pide explícitamente como referencia clínica), pero la conclusión principal de este estudio debe apoyarse en el acuerdo *inter*-método, no en este número.

5.7.4. Coste computacional

Se mide el tiempo de cómputo de cada método por caso (issue #66): Grad-CAM y la región topológica dominante son prácticamente instantáneos (menos de 0,2 s/caso); LIME tarda del orden de medio segundo a unos pocos segundos por caso según el número de muestras de perturbación; SHAP (`GradientExplainer`) es, con diferencia, el método más costoso (del orden de 20 s/caso en el entorno de desarrollo), lo que es relevante para valorar la viabilidad práctica del TDA como çapa de interpretabilidad nativa– su coste es orden de magnitud menor que el de SHAP, y comparable o menor que el de Grad-CAM/LIME, sin necesitar entrenar ni ejecutar inferencia de una CNN.

5.8. Metodología longitudinal (hipótesis principal)

Las secciones anteriores describen la clasificación benigno/maligno sobre una mamografía **aislada**, que constituye la base necesaria del trabajo (objetivos O3–O6). La hipótesis **principal** del TFG, sin embargo, es de naturaleza distinta: no preguntar si una imagen ya diagnosticada es maligna, sino si la exploración **anterior** de la misma paciente — leída clínicamente como normal — ya contenía una señal topológica de la lesión que se diagnosticaría después.

5.8.1. Definición de las señales longitudinales

Para una paciente con dos exploraciones sucesivas, $t-1$ (previa, sin diagnóstico) y t (donde se diagnostica la lesión), se calculan los diagramas de persistencia D_{t-1} y D_t mediante el mismo procedimiento de la Sección 5.4 y se derivan dos señales candidatas:

- **Anticipación**: el vector de características topológicas (imagen de persistencia, estadísticos) calculado **únicamente** sobre D_{t-1}. Mide si la exploración previa, por sí sola, ya es distinguible de la de una paciente control.

- **Deriva** (*drift*): la distancia *bottleneck* (o Wasserstein) entre D_{t-1} y D_t, $d(D_{t-1}, D_t)$, calculada por dimensión de homología (H_0, H_1) con la librería `persim`. Mide cuánto cambia la topología entre ambas exploraciones.
- **Combinada**: concatenación de ambas señales anteriores.

Cada señal se evalúa como entrada de un clasificador binario (paciente "incidente", que desarrolla la lesión en t, frente a paciente "control", sin lesión en ninguna de las dos exploraciones), reportando el AUC por validación cruzada de 5 particiones en vez de un único *split* de test, dado el tamaño reducido de las cohortes disponibles (mismo criterio de robustez estadística aplicado en la clasificación aislada, ver Capítulo 7).

5.8.2. Validación de la metodología con datos sintéticos

Antes de poder evaluar la hipótesis sobre un dataset longitudinal real (ver limitación de acceso más abajo), es necesario comprobar que el *pipeline* de comparación es capaz de detectar la señal cuando esta existe. Para ello se implementó un generador sintético (`scripts/synthetic_longitudinal_validation.py`) que produce, para cada paciente:

- **Casos control**: dos imágenes de fondo con textura y ruido similares a una mamografía, sin ninguna lesión, en $t-1$ y en t.
- **Casos incidentes**: en $t-1$, la misma textura de fondo con un **precursor sutil** (una lesión de bordes espiculados, radio y amplitud de contraste pequeños); en t, la misma lesión pero crecida y más prominente (mayor radio y amplitud), simulando la progresión hasta el momento del diagnóstico.

Con 60 pacientes por clase (parámetros por defecto del script, semilla fija para reproducibilidad) se obtuvo:

Tabla 5.1: AUC por validación cruzada (5-fold) de cada señal longitudinal sobre datos sintéticos.

Señal	**AUC (CV, media ± desv.)**
Anticipación (solo D_{t-1})	$0{,}871 \pm 0{,}089$
Deriva ($d(D_{t-1}, D_t)$)	$0{,}937 \pm 0{,}063$
Combinada	$0{,}924 \pm 0{,}055$

Estos resultados confirman que, cuando existe un precursor topológico real en $t-1$, el *pipeline* es capaz de recuperar esa señal muy por encima del azar, validando la metodología antes de aplicarla a datos reales.

5.8.3. Análisis de sensibilidad: anticipación frente a deriva

Un hallazgo metodológico relevante surge de un barrido de sensibilidad (`-sweep`) que reduce progresivamente la amplitud del precursor en $t-1$ (de 0,25 a 0,03, manteniendo fija la lesión madura en t), es decir, simulando precursores cada vez más sutiles y clínicamente más difíciles de anticipar:

- El AUC de **anticipación** degrada de forma clara y monótona, de 0,871 (precursor claro) a 0,510 (precursor casi indistinguible del fondo) — el comportamiento esperado de una señal que de verdad depende de la sutileza del precursor.
- El AUC de **deriva**, en cambio, se mantiene prácticamente constante ($\approx$ 0,95–0,96) en todo el barrido, **independientemente** de cuán sutil sea el precursor en $t-1$.

La razón es que la deriva mide sobre todo el **crecimiento** de la lesión entre $t-1$ y t (que en el generador sintético es siempre grande, por construcción), no la **presencia de un precursor anticipable**. Es decir, la deriva es un buen detector de "algo cambió", pero no sirve para responder a la pregunta central del TFG ("¿ya se podía anticipar antes del diagnóstico?"); para eso, la señal relevante es la de **anticipación** sobre D_{t-1} en solitario. Este resultado condiciona qué señal se prioriza al evaluar la hipótesis sobre datos reales (Capítulo 7).

5.8.4. Limitación de acceso a datos longitudinales reales

La validación anterior usa datos sintéticos porque, a fecha de redacción de esta memoria, no existe un dataset longitudinal público de mamografía con descarga directa. Se han identificado dos candidatos:

> *CSAW-CC* [9], cohorte real del Karolinska Institutet con 8723 pacientes y 24694 exploraciones (75.5 % con dos o más exploraciones), cuyas imágenes DICOM/PNG ($\sim$2.5 TB) requieren solicitud formal de acceso, no descarga directa; y *EMBED* [7], de Emory, con acceso controlado (*Controlled Access*) a través de un portal dedicado, verificado empíricamente que no ofrece ningún subconjunto público sin autenticación.

Mientras se tramita el acceso a alguno de estos dos conjuntos (ver también Capítulo 8), la Sección 5.8.2 constituye la validación disponible de la metodología, y el trabajo reconocidamente comparable más cercano en la literatura es LongiMam [14], que también explota pares longitudinales de mamografía pero con un modelo de *deep learning* end-to-end, no con descriptores topológicos.

Capítulo 6

Implementación

Este capítulo describe las herramientas, la organización del código y los detalles de implementación del *pipeline*.

6.1. Herramientas y librerías

El proyecto se desarrolla en **Python**. Las principales librerías son:

Tabla 6.1: Principales herramientas utilizadas.

Ámbito	**Herramienta**
Manipulación de datos	pandas, NumPy
Imagen	OpenCV, scikit-image, Pillow
TDA / homología persistente	giotto-tda (referencia) / GUDHI + persim (portable)
Aprendizaje automático	scikit-learn
Aprendizaje profundo	PyTorch / torchvision (DenseNet121)
Visualización	Matplotlib, seaborn
Entorno	Jupyter Notebook

6.2. Organización del código

El repositorio se estructura de la siguiente forma (véase el `README.md`):

```
mammoviz-tda/
  data/              # datos (no versionados)
  src/               # codigo fuente del pipeline
    data.py          # carga y particion por paciente
    preprocessing.py  # preprocesado de imagenes
    topology.py      # homologia persistente y vectorizacion
    models.py        # clasificadores y CNN
```

```
    evaluate.py     # metricas y visualizacion
  notebooks/        # experimentos reproducibles
  tfg/              # memoria en LaTeX
```

6.3. Extracción de descriptores topológicos

`giotto-tda` solo distribuye binarios precompilados hasta Python 3.12, por lo que `src/topology.py` detecta en tiempo de ejecución qué backend está disponible (`giotto-tda` o, si no, `gudhi + persim`, con soporte hasta Python 3.14) y expone la misma interfaz (`persistence_diagram`, `extract_features`) independientemente de cuál esté activo; `topology.backend()` permite consultarlo. El siguiente fragmento ilustra el cálculo de un diagrama de persistencia a partir de una imagen en escala de grises mediante una filtración por *sublevel sets*, utilizando `giotto-tda`.

```python
import numpy as np
from gtda.images import HeightFiltration, RadialFiltration
from gtda.homology import CubicalPersistence
from gtda.diagrams import PersistenceImage

def descriptor_topologico(imagen_gris):
    # imagen_gris: array 2D normalizado en [0, 1]
    x = imagen_gris[None, :, :]              # (1, H, W)
    cubical = CubicalPersistence(homology_dimensions=(0, 1))
    diagramas = cubical.fit_transform(x)     # diagramas de
       persistencia
    pi = PersistenceImage(n_bins=20)
    vector = pi.fit_transform(diagramas)     # imagen de persistencia
    return vector.reshape(len(x), -1)
```

Listing 6.1: Ejemplo de extracción de un diagrama de persistencia.

6.4. Reproducibilidad

Para garantizar la reproducibilidad de los experimentos:

- Se fija una semilla aleatoria común.
- Se documentan las versiones de las librerías (`requirements.txt`).
- La partición de datos por paciente se guarda en disco para reutilizarla.
- Cada experimento se ejecuta desde un *notebook* autocontenido.

6.5. Visualización

Se desarrollan visualizaciones específicas para el análisis topológico: diagramas de persistencia y códigos de barras superpuestos sobre la imagen, mapas de calor de las imágenes de persistencia, y comparación de las regiones más informativas frente a las activaciones de la CNN (p. ej. Grad-CAM).

Capítulo 7

Experimentos y resultados

Este capítulo presenta el diseño experimental del trabajo y los resultados obtenidos hasta el momento. Primero se describe una **validación preliminar del *pipeline* completo con datos sintéticos** (Sección 7.3), que sirvió para comprobar que las cinco etapas encajaban correctamente antes de tener datos reales; a continuación se presentan los **resultados ya obtenidos sobre el piloto real** de CBIS-DDSM, 30 pacientes descargados con `scripts/download_cbis_ddsm.py` (Sección 7.4 y Sección 7.4.4). La hipótesis longitudinal principal del trabajo (O7–O8) se valida por separado, de momento solo con datos sintéticos, en la Sección 5.8 del Capítulo 5.

7.1. Diseño experimental

Se definen los siguientes experimentos, alineados con los objetivos O4 y O5 (Capítulo 2):

E1. Clasificación con descriptores topológicos + clasificador clásico (SVM, *random forest*).

E2. Clasificación con CNN (*transfer learning*, DenseNet121).

E3. Fusión de características topológicas y *embeddings* de CNN.

E4. Análisis de robustez frente a ruido y a variaciones de adquisición.

7.2. Configuración

En todos los experimentos se fija una semilla aleatoria común (`seed = 42`) para garantizar la reproducibilidad. La partición de datos se realiza **por paciente** (Capítulo 5), con proporciones 70 % / 15 % / 15 % para entrenamiento, validación y test respectivamente, estratificadas por la etiqueta de patología. Los hiperparámetros de los clasificadores clásicos (`SVC(kernel='rbf')`, `RandomForestClassifier(n_estimators=300)`)

se fijan a valores por defecto razonables en esta fase preliminar; en la fase de experimentación con datos reales se ajustarán mediante validación cruzada sobre el conjunto de validación.

7.2.1. Backend de homología persistente

La implementación de referencia de este trabajo usa `giotto-tda` (Sección 6), pero esta librería solo distribuye binarios precompilados hasta Python 3.12. Para no depender de una versión concreta de Python, `src/topology.py` elige automáticamente, en este orden, el primer backend disponible en el entorno de ejecución:

1. **giotto-tda** — implementación de referencia.
2. **gudhi + persim** — backend alternativo con soporte binario hasta Python 3.14; se usa `gudhi.CubicalComplex` para el diagrama de persistencia y una imagen de persistencia calculada mediante un núcleo gaussiano ponderado por persistencia sobre la rejilla fija $[0, 1] \times [0, 1]$ (las imágenes ya están normalizadas por `preprocessing.to_grayscale_float`).
3. **Curva de Betti-0** (`scipy`) — respaldo mínimo si ningún backend anterior está instalado; cuenta cómo evoluciona el número de componentes conexas al barrer el umbral de intensidad.

Los resultados de este capítulo se obtuvieron con el backend **gudhi**, por ser el que está instalado en el entorno de desarrollo (Python 3.14, donde `giotto-tda` no tiene binarios disponibles). Ambos backends calculan la misma homología persistente cúbica sobre H0 y H1; la diferencia está en la vectorización final (imagen de persistencia), por lo que los resultados no deberían diferir sustancialmente de los que produciría `giotto-tda`.

7.3. Validación preliminar del *pipeline* con datos sintéticos

Antes de disponer del conjunto de datos real, se ha validado el *pipeline* de extremo a extremo (`notebooks/01_pipeline_demo.ipynb`) sobre un conjunto de **imágenes sintéticas** generadas para imitar de forma simplificada la textura y el contraste de una mamografía con lesión: 120 imágenes en escala de grises de 64×64 píxeles, con 60 ejemplos de cada clase (benigno/maligno simulados mediante patrones con distinta rugosidad topológica). El objetivo de este experimento **no** es obtener conclusiones clínicas — los datos son artificiales — sino comprobar que las cinco etapas del *pipeline* (datos → preprocesado → homología persistente → clasificación → evaluación) encajan correctamente y producen métricas coherentes, usando ya el descriptor topológico

completo (imágenes de persistencia H0+H1, no la curva de Betti-0) gracias al backend `gudhi` (Sección 7.2.1).

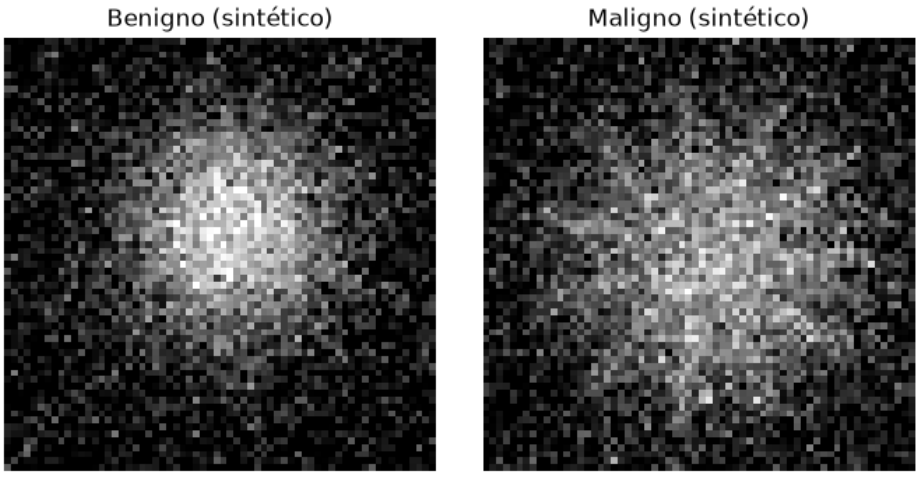


Figura 7.1: Ejemplo de imagen sintética de cada clase: un *blob* redondeado y suave (benigno) frente a una masa con espículas y micro-motas (maligno), ambas con ruido gaussiano fuerte para evitar un problema trivial.

Con partición 90/30 (train/test) y un vector de 288 características por imagen (12×12 píxeles por imagen de persistencia, dos dimensiones de homología H0 y H1), se obtienen los siguientes resultados:

Tabla 7.1: Resultados sobre datos sintéticos (validación del *pipeline*, imagen de persistencia H0+H1, backend gudhi).

Modelo	**Exactitud**	**Sensib.**	**Especif.**	**F1**	**AUC**
TDA + SVM (RBF)	0.667	0.600	0.733	0.643	0.844
TDA + Random Forest	0.733	0.800	0.667	0.750	0.833

Con estos datos sintéticos, el *random forest* obtiene la mejor sensibilidad y F1, y es el modelo seleccionado por F1 en el notebook; la SVM obtiene ligeramente mejor AUC. Ambos modelos superan claramente al azar (AUC $\approx$ 0,83–0,84), y la sensibilidad del *random forest* (0,80) es notablemente mejor que la obtenida en una validación previa con el descriptor de respaldo Betti-0 (0,60, un vector de solo 24 características frente a las 288 de la imagen de persistencia), lo que es consistente con la hipótesis de que **la dimensión H1 (agujeros/ciclos), ausente en la curva de Betti-0, aporta información discriminativa** relevante para las morfologías espiculadas simuladas en la clase maligna.

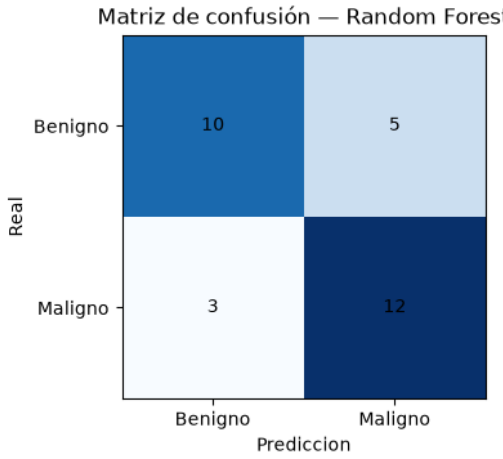


Figura 7.2: Matriz de confusión del *random forest* (mejor modelo por F1) sobre el conjunto sintético de test. Generada en `notebooks/01_pipeline_demo.ipynb`.

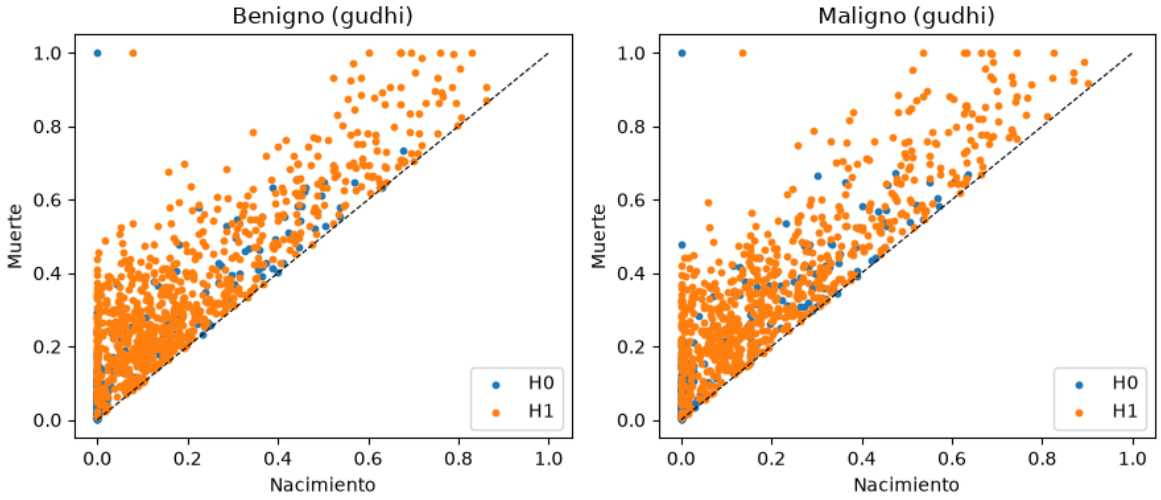


Figura 7.3: Diagramas de persistencia (backend `gudhi`) de un ejemplo benigno y uno maligno del conjunto sintético. H0 (componentes conexas) en azul, H1 (agujeros/ciclos) en naranja; la diagonal discontinua marca birth = death.

7.4. Resultados sobre el piloto real de CBIS-DDSM

El repositorio dispone ya de un **piloto real descargado**: 30 pacientes de CBIS-DDSM (casos de tipo masa), con sus mamografías completas y máscaras de ROI en `data/images/`, descargados de forma incremental y balanceada benigno/maligno con `scripts/download_cbis_ddsm.py` directamente contra la API REST de TCIA. La partición por paciente (Sección 5) deja, sobre este piloto, 40 casos usables de entrenamiento y 8 de test (el resto de filas de los CSV originales corresponden a pacientes todavía no descargados y se omiten automáticamente).

Tabla 7.2: Resultados reales sobre el piloto de CBIS-DDSM (30 pacientes, `scripts/run_pipeline.py` y `scripts/fuse_and_evaluate.py`, `n_bins=4`, Random Forest). El AUC por validación cruzada (5-fold sobre train) es la columna fiable; el test de solo 8 casos es muy ruidoso (ver discusión debajo de la tabla).

Modelo	**AUC (test, $n = 8$)**	**AUC (CV, train)**	**Sensib. (test)**
TDA (Persistence Image)	0.000	$0{,}850 \pm 0{,}143$	0.000
CNN (DenseNet121, embeddings)	0.208	$0{,}933 \pm 0{,}097$	0.167
Fusión TDA + CNN	0.333	$0{,}883 \pm 0{,}194$	0.167

7.4.1. Por qué el AUC de test es tan malo (y por qué no es alarmante)

El AUC de test de la fila TDA es 0,000: con solo 8 casos de test, el *random forest* invirtió literalmente las 8 predicciones respecto a la etiqueta real (`y_test=[1,1,0,0,1,1,1,1]` frente a `y_pred=[0,0,1,1,0,0,0,0]`). Esto no revela un error del *pipeline*: con un test tan pequeño, una sola partición concreta puede caer, por puro azar, en el extremo contrario de la distribución de aciertos. Es exactamente el fenómeno ya anticipado al corregir el sobreajuste del clasificador (issue #77): el AUC de un único *split* pequeño es **demasiado ruidoso para ser la métrica de referencia**. Por eso la columna fiable de la Tabla 7.2 es el AUC por validación cruzada de 5 particiones sobre el conjunto de entrenamiento ($n = 40$), que promedia sobre varias particiones en vez de depender de una sola.

Con esa métrica, los tres modelos superan claramente el azar (AUC $\geq 0{,}85$), con la CNN ligeramente por delante de la fusión y de TDA en solitario en este piloto concreto; la desviación típica de la fusión ($\pm 0{,}194$) es, sin embargo, la más alta de las tres, lo que indica que el orden entre modelos todavía no está establecido con el tamaño de muestra actual. Ampliar el piloto (issue #82, O7 del Capítulo 2) es el paso natural para reducir esa incertidumbre antes de poder afirmar cuál de los tres enfoques es preferible.

7.4.2. Refinamiento: ajuste de hiperparámetros por vía (issue #77)

La Tabla 7.2 usa los valores por defecto de `src/models.py` (*random forest* sin ajustar) para las tres vías por igual. `scripts/run_pipeline.py -tune` y `scripts/fuse_and_evaluate.p` `-tune` permiten, en cambio, ajustar por `GridSearchCV` el clasificador (SVM o *random forest*, y sus hiperparámetros) **por separado para cada vía**, ya que no hay razón para esperar que la misma configuración sea óptima para un vector topológico de 32 características, un *embedding* de CNN de 1024, o su fusión de 1056.

Tabla 7.3: AUC por validación cruzada (5-fold, train) antes y después de ajustar hiperparámetros por vía. "Mejor encontrado" es el máximo entre *random forest* por defecto (Tabla 7.2) y SVM ajustada por `GridSearchCV` ($n_bins = 4$, $C \in \{0{,}01, \ldots, 100\}$, kernel lineal/RBF).

Vía	**RF por defecto**	**SVM ajustada (`-tune`)**	**Mejor encontrado**
TDA sola	$0{,}850 \pm 0{,}143$	$0{,}850 \pm 0{,}143$	$0{,}850 \pm 0{,}143$
CNN sola	$0{,}933 \pm 0{,}097$	$0{,}850 \pm 0{,}186$	$\mathbf{0{,}933 \pm 0{,}097}$ (RF)
Fusión TDA + CNN	$0{,}883 \pm 0{,}194$	$\mathbf{0{,}967 \pm 0{,}067}$	$\mathbf{0{,}967 \pm 0{,}067}$ (SVM)

El hallazgo más relevante no es que .ªjustar siempre mejora– de hecho, para la CNN sola el ajuste **empeora** el resultado frente al *random forest* por defecto (de 0,933 a 0,850) — sino que **la mejor configuración depende de qué características se usan**: el *random forest* por defecto generaliza mejor sobre el *embedding* de 1024 dimensiones de la CNN, mientras que una SVM con regularización fuerte ($C = 0{,}01$) generaliza mejor sobre el vector fusionado de 1056 dimensiones, donde sube de 0,883 a $\mathbf{0{,}967 \pm 0{,}067}$ — el mejor resultado de todo el piloto, y también el de **menor varianza** de las seis configuraciones probadas. Es un resultado alentador para la hipótesis de fusión (O5): cuando se ajustan bien los hiperparámetros, combinar TDA y CNN sí aporta sobre cualquiera de los dos enfoques por separado, aunque con el tamaño de piloto actual conviene leer esta mejora con cautela (issue #77: *look-elsewhere effect* al probar varias configuraciones y quedarse con la mejor) y confirmarla cuando el piloto crezca (issue #82).

7.4.3. Sanity check visual: masa espiculada benigna vs. maligna

Como comprobación cualitativa independiente de las métricas anteriores (issue #56), la Figura 7.4 compara dos casos reales de CBIS-DDSM con el mismo tipo de margen de masa (`SPICULATED` en el campo `mass_margins` del CSV de descripción): uno benigno (`P_00692`) y uno maligno (`P_00734`). Ambos tienen una morfología visualmente similar — precisamente el tipo de caso donde interesa que el descriptor topológico aporte algo más allá de lo evidente a simple vista — y sus diagramas de persistencia difieren tanto en el número de puntos de H_1 (ciclos) como en su persistencia (distancia a la diagonal), consistente con la intuición de que una masa espiculada maligna real genera una textura de borde más irregular que una espiculación benigna. Esta observación es cualitativa y sobre un único par de casos; no sustituye a la validación cuantitativa de la Tabla 7.2, pero sirve de comprobación de sentido común de que el descriptor no es ciego a la diferencia clínica relevante.

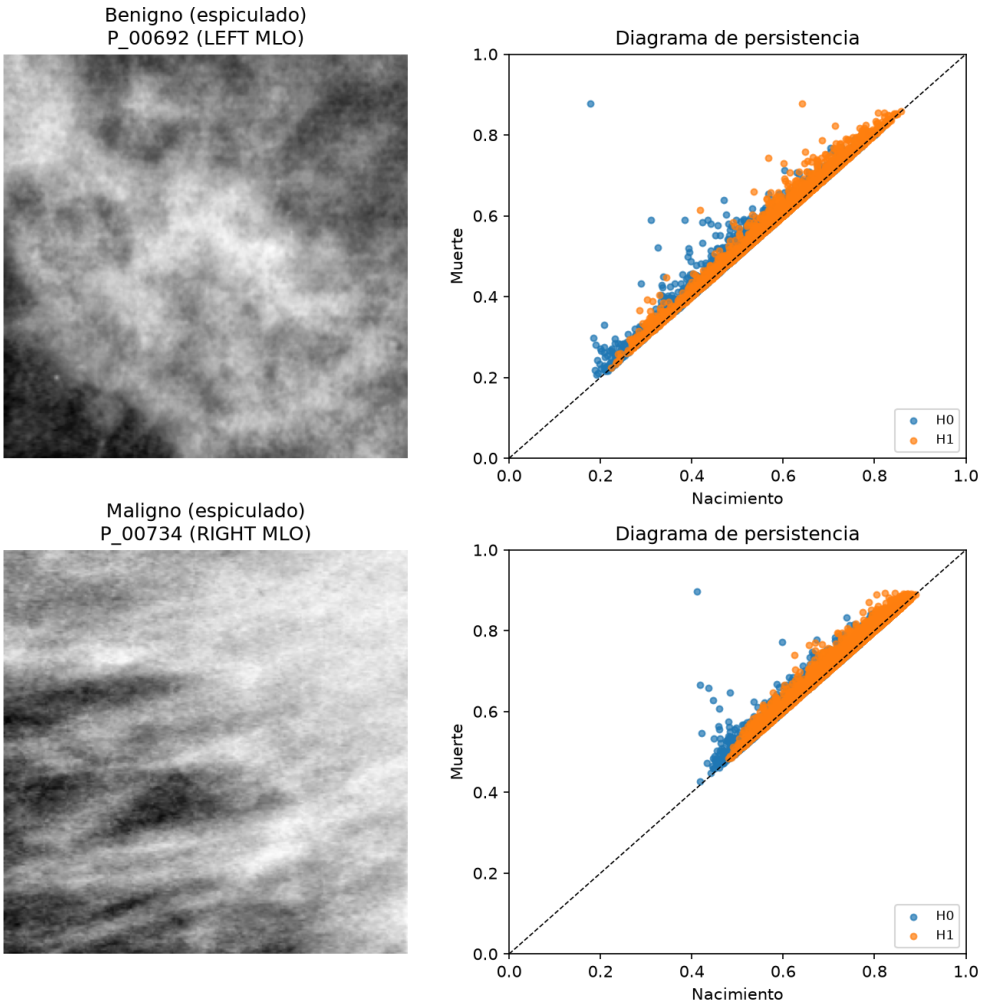


Figura 7.4: Caso real benigno (`P_00692`, arriba) y maligno (`P_00734`, abajo) con margen de masa espiculado, con su diagrama de persistencia H0/H1 (backend `gudhi`).

7.4.4. Estado de los datos

El piloto real cubre, de momento, 30 pacientes de tipo masa. Queda pendiente, no ya la descarga en sí (ya resuelta y automatizada), sino **ampliarla**:

- Relanzar `scripts/download_cbis_ddsm.py -add N N` para crecer el piloto y reducir la varianza de la Tabla 7.2 (issue #82).
- Incorporar los casos de tipo calcificación (`Calc-*`), de momento excluidos del piloto (Sección 5).
- Una vez conseguido acceso a un dataset longitudinal real (issue #92), repetir la validación de la Sección 5.8 del Capítulo 5 — ahora mismo solo validada con datos sintéticos — sobre pacientes reales con exploraciones sucesivas, que es la hipótesis principal del trabajo (O8).

7.5. Interpretabilidad: TDA vs Grad-CAM vs SHAP vs LIME

Como línea secundaria del trabajo (Sección 5.7), se ha ejecutado `scripts/explainability_benchma` sobre los **48 casos usables** del piloto real (entrenamiento y test juntos, estudio descriptivo, no predictivo), calculando las 4 regiones binarias (Grad-CAM, región topológica dominante, SHAP, LIME) y su acuerdo por pares.

Tabla 7.4: Acuerdo por pares entre los 4 métodos de interpretabilidad (IoU media ± desviación típica, $n = 48$ casos reales).

Par de métodos	**IoU**
Grad-CAM vs. TDA	$0{,}110 \pm 0{,}092$
Grad-CAM vs. SHAP	$0{,}126 \pm 0{,}040$
Grad-CAM vs. LIME	$0{,}110 \pm 0{,}074$
TDA vs. SHAP	$0{,}063 \pm 0{,}059$
TDA vs. LIME	$0{,}109 \pm 0{,}107$
SHAP vs. LIME	$0{,}110 \pm 0{,}036$

7.5.1. El hallazgo principal: los cuatro métodos apenas coinciden entre sí

El acuerdo por pares es **bajo y muy similar entre todas las combinaciones** (IoU entre 0,06 y 0,13): no hay ningún par de métodos que destaque por coincidir claramente más que los demás, ni siquiera Grad-CAM/SHAP/LIME entre sí (que comparten la misma CNN de referencia como base). Este resultado es consistente con una observación ya reportada en la literatura de *interpretable ML* fuera del dominio médico: distintos métodos de explicabilidad, aplicados al mismo modelo y la misma entrada, con frecuencia señalan regiones distintas, porque cada uno optimiza una noción distinta de ïmportancia"(gradiente local para Grad-CAM, valores de Shapley para SHAP, un modelo local interpretable sobre superpíxeles para LIME). La región topológica dominante no es una excepción a este patrón: acuerda con Grad-CAM tan poco (0,110) como Grad-CAM acuerda con SHAP (0,126) o LIME (0,110).

La Figura 7.5 ilustra esto con el caso de mayor acuerdo TDA/Grad-CAM del piloto (`P_01090`, arriba: ambos métodos señalan el mismo borde de la lesión) frente al de menor acuerdo (`P_00433`, abajo: Grad-CAM señala una esquina de la imagen y la región topológica dominante un punto completamente distinto). SHAP produce en ambos casos un patrón disperso tipo "sal y pimienta"sobre buena parte de la imagen, poco localizado; LIME selecciona unos pocos superpíxeles, frecuentemente cerca de los

bordes del recorte.

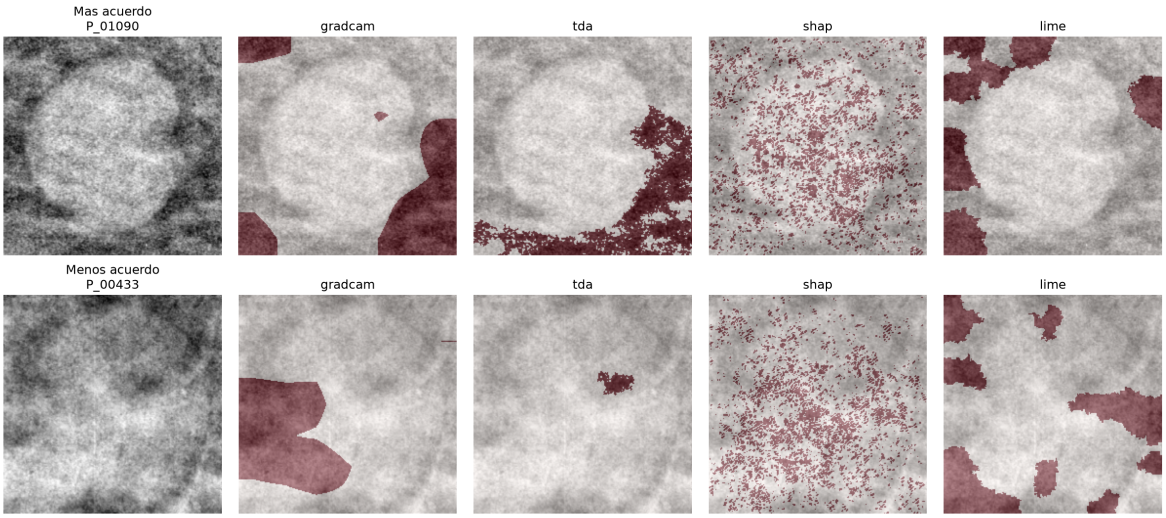


Figura 7.5: Caso de mayor acuerdo TDA/Grad-CAM del piloto (`P_01090`, arriba) frente al de menor acuerdo (`P_00433`, abajo), con las 4 regiones superpuestas en rojo sobre la imagen preprocesada.

7.5.2. IoU contra la máscara de ROI real

Como se advirtió metodológicamente en la Sección 5.7.3, este número está sesgado al alza por el recorte del *pipeline* y es menos informativo que la Tabla 7.4; se incluye por completitud (issue #61):

Tabla 7.5: IoU de cada método contra la máscara de ROI real ($n = 48$).

Método	**IoU vs. ROI**
Grad-CAM	$0{,}179 \pm 0{,}079$
TDA	$0{,}127 \pm 0{,}140$
SHAP	$0{,}226 \pm 0{,}054$
LIME	$0{,}150 \pm 0{,}070$

SHAP obtiene el IoU más alto contra la ROI, pero su patrón disperso (Figura 7.5) sugiere que esto puede deberse simplemente a que marca muchos píxeles repartidos por una fracción grande de la imagen (y la ROI, tras el recorte, también cubre una fracción grande de la imagen), no a una localización precisa de la lesión. La desviación típica de TDA ($\pm 0{,}140$) es la más alta de las cuatro, reflejando que a veces la región dominante cae dentro de la ROI y a veces fuera, consistente con el bajo acuerdo inter-método ya comentado.

7.5.3. Desglose por tipo de margen de la masa

El acuerdo TDA/Grad-CAM desglosado por `mass_margins` no muestra una categoría claramente distinta de las demás (todas entre 0,10 y 0,13, salvo `MICROLOBULATED` con solo $n = 2$, insuficiente para concluir nada): ni los márgenes espiculados (`SPICULATED`, $n = 9$, $0{,}113 \pm 0{,}069$) ni los circunscritos (`CIRCUMSCRIBED`, $n = 19$, $0{,}117 \pm 0{,}111$) muestran mayor o menor acuerdo entre TDA y Grad-CAM. Con el tamaño de piloto actual no se puede afirmar que el tipo de margen module el acuerdo entre métodos.

7.5.4. Coste computacional

Tabla 7.6: Coste computacional por método (segundos/caso, $n = 48$).

Método	**Tiempo (s/caso)**
Grad-CAM	$0{,}072 \pm 0{,}026$
TDA (región dominante)	$0{,}067 \pm 0{,}017$
LIME	$1{,}841 \pm 0{,}171$
SHAP	$22{,}788 \pm 2{,}799$

Este es el resultado más favorable para el TDA de todo el estudio: la región topológica dominante es tan rápida de calcular como Grad-CAM (0,067 s/caso vs. 0,072 s/caso) **sin necesitar entrenar ni ejecutar ninguna CNN**, y más de dos órdenes de magnitud más rápida que SHAP (22,8 s/caso). Es, con diferencia, el argumento más sólido a favor de la homología persistente como çapa de interpretabilidad nativa– no porque coincida más con los otros métodos (no lo hace, Tabla 7.4), sino porque ofrece una localización topológicamente fundamentada prácticamente gratis en comparación con SHAP, y sin la dependencia de una CNN ya entrenada que tienen los otros tres métodos.

7.6. Discusión

Aunque los resultados sobre datos sintéticos no permiten extraer conclusiones clínicas, sí permiten adelantar algunas observaciones metodológicas relevantes para la fase de experimentación real:

- **El *pipeline* es funcionalmente correcto de extremo a extremo y con el descriptor topológico completo**: la partición por paciente, el preprocesado, la extracción de imágenes de persistencia H0+H1 y la evaluación con métricas clínicas se ejecutan sin errores y producen resultados coherentes (AUC $\approx$ 0,83–0,84).

- **La dimensión H1 aporta información que la curva de Betti-0 no captura**: al pasar del descriptor de respaldo (Betti-0, solo H0, 24 características) a la imagen de persistencia completa (H0+H1, 288 características), la sensibilidad del *random forest* mejora de 0,60 a 0,80 sobre el mismo conjunto sintético. Es una observación preliminar (mismo generador, tamaño de muestra pequeño), pero apunta en la dirección esperada: los ciclos/agujeros (H1) deberían ser relevantes para masas espiculadas y distribuciones de microcalcificaciones.

- **La sensibilidad sigue siendo sensible al tamaño de muestra**: con solo 120 imágenes sintéticas, la sensibilidad de la SVM (0,60) queda por debajo de su especificidad (0,73), lo que anticipa la necesidad de vigilar el desbalance de clases y el tamaño muestral al pasar a datos reales (CBIS-DDSM tiene más casos benignos que malignos).

- **Comparación con *deep learning* y fusión**: ya ejecutada sobre el piloto real (Sección 7.4): en esta iteración concreta, la CNN sola (AUC por CV 0,933) supera tanto a TDA solo (0,850) como a la fusión (0,883), al contrario de lo anticipado aquí con datos sintéticos; con una desviación típica de la fusión del orden de 0,19, no puede todavía descartarse que el orden cambie al ampliar el piloto (issue #82).

Las observaciones anteriores, obtenidas con datos sintéticos antes de tener el conjunto real, se contrastan con los resultados reales en la Sección 7.4; las limitaciones específicas de ambas fases (tamaño de muestra del piloto real, naturaleza sintética de la validación longitudinal) se retoman en el Capítulo 8 junto con las limitaciones generales del trabajo.

Capítulo 8

Conclusiones y trabajo futuro

8.1. Conclusiones

Este Trabajo de Fin de Grado parte de la clasificación benigno/maligno sobre una mamografía aislada mediante Análisis Topológico de Datos (TDA), pero su objetivo principal es más ambicioso: estudiar si esos mismos descriptores topológicos permiten **detección anticipada**, comparando la exploración previa (normal) y la exploración donde se diagnostica el cáncer en la misma paciente (Capítulo 2, objetivos O7–O8). Este pivote — documentado en detalle en el registro de decisión del repositorio — sustituye al planteamiento inicial centrado en comparar la interpretabilidad del TDA frente a Grad-CAM/SHAP/LIME sobre una imagen aislada, que se mantiene como línea secundaria si el tiempo lo permite, pero ya no como contribución central.

El resultado principal hasta la fecha es un ***pipeline* completo, reproducible y ya ejecutado sobre datos reales** de CBIS-DDSM — no solo sintéticos — desde la carga de metadatos hasta la evaluación clínica, que corrige el problema de fuga de datos detectado en el material de partida (partición estricta por paciente), junto con una **validación metodológica de la hipótesis longitudinal sobre datos sintéticos** (Sección 5.8 del Capítulo 5) mientras se tramita el acceso a un dataset longitudinal real. En relación con los objetivos específicos:

- Se ha revisado el estado del arte en análisis automático de mamografías, aplicaciones del TDA a imagen médica y predicción de riesgo/análisis longitudinal (O1).

- Se ha construido un *pipeline* reproducible de preparación de datos (`src/data.py`) cuyo aporte metodológico central es la **partición por paciente**, que corrige la fuga de datos observada en el `Demo_Notebook.ipynb` original (exactitud del 100 % desde la primera época); se ha descargado y usado un piloto real de 30 pacientes de CBIS-DDSM (O2).

- Se ha implementado y ejecutado sobre datos reales la extracción de descriptores topológicos mediante homología persistente cúbica (`src/topology.py`: diagramas de persistencia, imágenes de persistencia H0+H1), con dos backends intercambiables (`giotto-tda` y `gudhi`, este último operativo en Python 3.14) (O3), y se han entrenado y evaluado clasificadores clásicos (SVM, *random forest*) sobre estos descriptores sobre el piloto real, con AUC por validación cruzada $\approx 0{,}85$ (Sección 7.4) (O4).

- Se ha migrado la CNN de referencia a PyTorch (DenseNet121 con *transfer learning*), se ha entrenado de forma determinista sobre el piloto real, y se ha implementado y evaluado la fusión de características topológicas y *embeddings* de la CNN, con AUC por CV $\approx 0{,}93$ (CNN) y $\approx 0{,}88$ (fusión) sobre el piloto actual (O5).

- Se han desarrollado utilidades de visualización (matriz de confusión, diagrama de persistencia, comparación visual benigno vs. maligno espiculado con datos reales) en `src/evaluate.py` y en el notebook interactivo (O6).

- Se ha diseñado la metodología de comparación longitudinal (señales de *anticipación* y *deriva* topológica entre exploraciones sucesivas) y se ha **validado con datos sintéticos**, incluido un análisis de sensibilidad que muestra que la deriva no es sensible a la sutileza del precursor mientras que la anticipación sí lo es — un hallazgo metodológico que condiciona qué señal priorizar sobre datos reales (O7).

- Queda **pendiente** la evaluación de la hipótesis de detección anticipada sobre datos longitudinales reales, bloqueada por el acceso a CSAW-CC o EMBED, ambos bajo solicitud formal de acceso, no descarga directa (O8).

8.2. Grado de cumplimiento de los objetivos

Tabla 8.1: Grado de cumplimiento de los objetivos específicos.

Obj.	Estado	Observaciones
O1	Cumplido	Revisión bibliográfica completa, incluida la línea longitudinal/predicción de riesgo (Cap. 3).
O2	Cumplido	*Pipeline* de datos y partición por paciente implementados y verificados sobre un piloto real de 30 pacientes; dataset longitudinal (CSAW-CC/EMBED) bajo solicitud de acceso (O8).
O3	Cumplido	Extracción de imágenes de persistencia H0+H1 implementada y ejecutada sobre el piloto real con dos backends (gudhi, giotto-tda).
O4	Cumplido	Clasificadores entrenados y evaluados sobre el piloto real (AUC por CV $\approx$ 0,85); tamaño de muestra todavía pequeño (issue #82).
O5	Cumplido	CNN (PyTorch/DenseNet121) y fusión entrenadas y comparadas sobre el piloto real.
O6	Cumplido (parcial)	Visualizaciones implementadas y aplicadas a casos reales; comparación con Grad-CAM/SHAP/LIME relegada a línea secundaria tras el pivote.
O7	Cumplido	Metodología de comparación longitudinal diseñada y validada con datos sintéticos (Sección 5.8).
O8	Pendiente	Bloqueado por el acceso a un dataset longitudinal real (CSAW-CC/EMBED, issue #92); es el objetivo más importante y el único que depende de un trámite externo, no de trabajo de implementación.

La principal desviación respecto a la planificación inicial ya no es logística (la descarga de CBIS-DDSM, que motivó el retraso inicial, está resuelta y automatizada), sino de **alcance**: la hipótesis central del trabajo (O8) depende de un recurso — un dataset longitudinal real — cuyo acceso no está bajo el control directo del proyecto, y cuyo trámite de solicitud formal sigue abierto (issue #92).

8.3. Limitaciones

Se identifican las siguientes limitaciones del trabajo en su estado actual:

- **La hipótesis principal no se ha evaluado todavía sobre datos reales.** La validación de la Sección 5.8 usa un generador sintético de precursores topológicos; confirma que la metodología de comparación funciona cuando la señal existe, pero no dice nada sobre si existe en mamografías reales.
- **Tamaño del piloto real.** 30 pacientes (40 casos de entrenamiento, 8 de test tras la partición por paciente) es suficiente para validar que el *pipeline* funciona de extremo a extremo, pero demasiado pequeño para que las métricas de la Tabla 7.2 sean concluyentes: el AUC de un único *split* de test con $n = 8$ resultó, en una ejecución, ser **peor que el azar por pura casualidad** (Sección 7.4.1), lo que ilustra por qué se reporta el AUC por validación cruzada como métrica principal y no el de un solo *split*.
- **Sesgos del conjunto de datos.** CBIS-DDSM, aunque curado, procede de un número limitado de centros y equipos de adquisición, lo que puede limitar la generalización a otras poblaciones o tecnologías de imagen; además, el piloto actual solo incluye casos de tipo masa, no de calcificación.
- **Alcance de la validación clínica.** Ninguna de las métricas obtenidas constituye una validación clínica: falta contraste con radiólogos y con conjuntos de datos externos antes de extraer conclusiones sobre utilidad diagnóstica real.

8.4. Trabajo futuro

A corto plazo, para completar el objetivo O8 (el único pendiente):

- Completar la solicitud formal de acceso a CSAW-CC o EMBED (issue #92) y, en cuanto se conceda, repetir sobre datos reales la validación longitudinal ya hecha con datos sintéticos (Sección 5.8), priorizando la señal de **anticipación** sobre la de **deriva** según el hallazgo de sensibilidad de esa misma sección.
- Ampliar el piloto real de CBIS-DDSM más allá de 30 pacientes (issue #82) para reducir la varianza de las métricas de la Tabla 7.2 e incorporar los casos de calcificación.

Como líneas de trabajo futuro de más largo alcance se proponen:

- Comparar la señal de anticipación topológica con modelos de predicción de riesgo basados en *deep learning* ya publicados sobre datos longitudinales reales (p. ej. LongiMam [14], STA-Risk [19]).
- Retomar, como línea secundaria, la métrica de acuerdo topológico-clínico (TDA vs. Grad-CAM/SHAP/LIME) sobre una mamografía aislada, descartada como

eje central tras el pivote a la hipótesis longitudinal pero no descartada como posible aportación adicional si el tiempo del TFG lo permite.

- Extender el estudio a otras filtraciones y descriptores topológicos (*multiparameter persistence*) para la señal de deriva entre exploraciones.
- Explorar la **consistencia topológica entre proyecciones CC/MLO** de la misma exploración (distancia de Wasserstein entre sus diagramas de persistencia) como señal de calidad/ambigüedad complementaria a la señal longitudinal: dos vistas de la misma lesión deberían ser topológicamente similares, y una discrepancia grande podría señalar casos donde el descriptor topológico es menos fiable.
- Validar el enfoque longitudinal en otros conjuntos de datos (además de CSAW-CC/EMBED) y, si procede, con radiólogos, para medir la utilidad clínica real de una ventana de detección anticipada.

Bibliografía

[1] A. Ali Eli y A. Ali, "Deep Learning Applications in Medical Image Analysis: Advancements, Challenges, and Future Directions", *arXiv preprint arXiv:2410.14131*, 2024. arXiv: 2410.14131 [eess.IV].

[2] J. Bai, A. Jin, M. Adams, C. Yang y S. Nabavi, "Unsupervised feature correlation model to predict breast abnormal variation maps in longitudinal mammograms", *arXiv preprint arXiv:2312.16772*, 2023. arXiv: 2312.16772 [eess.IV].

[3] G. Carlsson, "Topology and data", *Bulletin of the American Mathematical Society*, vol. 46, n.º 2, págs. 255-308, 2009. DOI: 10.1090/S0273-0979-09-01249-X

[4] S. Dadsetan, D. Arefan, W. A. Berg, M. L. Zuley, J. H. Sumkin y S. Wu, "Deep learning of longitudinal mammogram examinations for breast cancer risk prediction", *Pattern Recognition*, vol. 132, pág. 108 919, 2022. DOI: 10.1016/j.patcog.2022.108919

[5] H. Edelsbrunner y J. L. Harer, *Computational Topology: An Introduction*. American Mathematical Society, 2010, ISBN: 978-0-8218-4925-5.

[6] C. Fanning y M. E. Aktas, "Topological Conditioning for Mammography Models via a Stable Wavelet-Persistence Vectorization", *arXiv preprint arXiv:2512.10151 (sometido a IEEE Transactions on Medical Imaging)*, 2025. arXiv: 2512.10151 [eess.IV].

[7] J. J. Jeong, B. L. Vey, A. Bhimireddy et al., "The EMory BrEast imaging Dataset (EMBED): A Racially Diverse, Granular Dataset of 3.5 Million Screening and Diagnostic Mammograms", *Radiology: Artificial Intelligence*, 2023, Acceso controlado ("Controlled Access"): requiere solicitud formal a traves del portal data.hitilab.com; verificado empiricamente (boto3 sin firmar y HTTP directo) que el bucket de AWS Open Data no permite listado anonimo (AccessDenied). No existe un subconjunto publico sin autenticacion. DOI: 10.1148/ryai.220047

[8] B. Karimian, S. Belharbi y A. Guichemerre, "Single-Exam Mammography Risk Prediction with Privileged History Distillation", *arXiv preprint arXiv:2603.15814*, 2026. arXiv: 2603.15814 [eess.IV].

[9] Karolinska Institutet, *CSAW-CC (mammography) – a dataset for AI research to improve screening, diagnostics and prognostics of breast cancer*, Cohorte longitudinal real (8723 pacientes, 24694 examenes, 75.5 % con >=2 examenes); acceso a imagenes DICOM/PNG (2.5 TB) bajo solicitud formal, no descarga directa, 2021. DOI: 10.5878/45vm-t798

[10] T. Kooi y N. Karssemeijer, "Classifying Symmetrical Differences and Temporal Change for the Detection of Malignant Masses in Mammography Using Deep Neural Networks", *Journal of Medical Imaging*, vol. 4, n.º 4, pág. 044 501, 2017. DOI: 10.1117/1.JMI.4.4.044501

[11] R. S. Lee, F. Gimenez, A. Hoogi, K. K. Miyake, M. Gorovoy y D. L. Rubin, "A curated mammography data set for use in computer-aided detection and diagnosis research", *Scientific Data*, vol. 4, pág. 170 177, 2017. DOI: 10.1038/sdata.2017.177

[12] G. Litjens et al., "A survey on deep learning in medical image analysis", *Medical Image Analysis*, vol. 42, págs. 60-88, 2017. DOI: 10.1016/j.media.2017.07.005

[13] S. M. Lundberg y S.-I. Lee, "A Unified Approach to Interpreting Model Predictions", en *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, págs. 4765-4774.

[14] M. Rakez et al., "The LongiMam model for improved breast cancer risk prediction using longitudinal mammograms", *arXiv preprint arXiv:2509.21383*, 2025. arXiv: 2509.21383 [eess.IV].

[15] M. T. Ribeiro, S. Singh y C. Guestrin, ""Why Should I Trust You?": Explaining the Predictions of Any Classifier", en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, págs. 1135-1144. DOI: 10.1145/2939672.2939778

[16] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh y D. Batra, "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization", en *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, págs. 618-626. DOI: 10.1109/ICCV.2017.74

[17] S. Thrun et al., "The Impact of Longitudinal Mammogram Alignment on Breast Cancer Risk Assessment", *arXiv preprint arXiv:2511.08328*, 2025. arXiv: 2511.08328 [eess.IV].

[18] A. Yala, C. Lehman, T. Schuster, T. Portnoi y R. Barzilay, "A Deep Learning Mammography-based Model for Improved Breast Cancer Risk Prediction", *Radiology*, vol. 292, n.º 1, págs. 60-66, 2019. DOI: 10.1148/radiol.2019182716

[19] Z. Zhou, D. Arefan, M. Zuley, J. Sumkin y S. Wu, "STA-Risk: A Deep Dive of Spatio-Temporal Asymmetries for Breast Cancer Risk Prediction", *arXiv preprint arXiv:2505.21699*, 2025. arXiv: 2505.21699 [eess.IV].

Apéndice A

Material adicional

A.1. Instalación del entorno

Instrucciones para reproducir el entorno de desarrollo:

```
python -m venv .venv
source .venv/bin/activate          # En Windows: .venv\Scripts\activate
pip install -r requirements.txt
```

A.2. Descripción de los campos de CBIS-DDSM

A.2.1. Manifiesto de TCIA (incluido en el repositorio)

El fichero `CBIS-DDSM-All-doiJNLP-zzWs5zfZ-nbia-digest.xlsx` es el manifiesto que genera TCIA al exportar una colección: identifica las series DICOM disponibles pero **no incluye la etiqueta de patología**. Sus campos más relevantes para el *pipeline* son:

Tabla A.1: Campos relevantes del manifiesto de TCIA.

Campo	Descripción
`Patient ID`	Identificador largo, p. ej. `Mass-Training_P_01009_RIGHT_CC_1`. `src.data.load_manifest` extrae de aquí el id real de paciente (`P_01009`) con una expresión regular, base de la partición por paciente.
`Series Description`	Tipo de imagen de la serie: `full mammogram images`, `ROI mask images` o `cropped images`.
`Modality`	Modalidad DICOM; `MG` (mamografía) en todos los casos.
`Body Part Examined`	Región anatómica (`BREAST`).
`Image Count`	Número de imágenes DICOM de la serie.
`File Size`	Tamaño en bytes de la serie (para estimar la descarga total).
`Collection URI`	DOI de la colección en TCIA [11].
`License Name`	*Creative Commons Attribution 3.0 Unported.*

A.2.2. CSV de descripción de casos (a descargar de TCIA)

Los ficheros `mass_/calc_case_description_{train,test}_set.csv` — no incluidos en el repositorio, véase la Sección 7.4.4 — sí contienen la etiqueta clínica. La función `load_case_descriptions` de `src/data.py` espera, entre otros, los campos `patient_id`, `breast_density` (densidad BI-RADS, 1–4), `left or right breast`, `image view` (CC/MLO), `abnormality type` (masa o calcificación), `assessment` (BI-RADS 0–5), `subtlety` y, sobre todo, `pathology` (`BENIGN`, `BENIGN_WITHOUT_CALLBACK`, `MALIGNANT`), que `src.data.to_binary_label` convierte en la etiqueta binaria 0/1 usada en todo el trabajo.

A.3. Fragmentos de código adicionales

A.3.1. Selección automática de backend de homología persistente

Como `giotto-tda` no publica binarios para Python 3.13+ (Sección 7.2.1), `src/topology.py` detecta en tiempo de importación qué backend usar, sin que el resto del *pipeline* necesite saberlo:

```
try:
    from gtda.homology import CubicalPersistence
    _HAS_GIOTTO = True
```

```
except ImportError:
    _HAS_GIOTTO = False

try:
    import gudhi
    _HAS_GUDHI = True
except ImportError:
    _HAS_GUDHI = False

def backend() -> str:
    if _HAS_GIOTTO:
        return "giotto-tda"
    if _HAS_GUDHI:
        return "gudhi"
    return "none"
```

Listing A.1: Deteccion de backend en src/topology.py (fragmento).

A.3.2. Imagen de persistencia sin giotto-tda

Cuando el backend activo es `gudhi`, la imagen de persistencia se calcula a mano con un núcleo gaussiano ponderado por persistencia, sobre la rejilla fija $[0,1] \times [0,1]$ (las imágenes ya están normalizadas por `preprocessing.to_grayscale_float`, Sección 5):

```
grid = np.linspace(0.0, 1.0, n_bins)
birth_grid, pers_grid = np.meshgrid(grid, grid, indexing="ij")
sigma = 1.0 / n_bins

for birth, pers, weight in zip(births, persistences, weights):
    image += weight * np.exp(
        -((birth_grid - birth) ** 2 + (pers_grid - pers) ** 2) / (2 *
           sigma ** 2)
    )
```

Listing A.2: Imagen de persistencia manual (nucleo gaussiano), src/topology.py (fragmento).

Al fijar la rejilla de antemano (en vez de ajustarla, *fit*, por lote como hace `giotto-tda`), todas las imágenes del conjunto de datos producen vectores de la misma longitud y directamente comparables entre sí, sin necesitar un paso de ajuste previo sobre el conjunto de entrenamiento.